



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی
مهندسی کامپیوتر

تشخیص توضیح پذیر سلامت روان با بهره گیری از
مدل های زبانی بزرگ و گراف های دانش دامنه ای

نگارش

علیرضا هوشیاری

استاد راهنما

دکتر محمد رحمتی

شهریور ۱۴۰۵

به نام خدا

تاریخ: شهریور ۱۴۰۵

تعهدنامه اصالت اثر



اینجانب **علیرضا هوشیاری** متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است. در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

علیرضا هوشیاری

سپاسگزاری

با تشکر فراوان از جناب آقای دکتر محمد رحمتی، استاد راهنمای محترم این پایان نامه، که با راهنمایی‌ها و نظرات ارزشمند خود نقشی اساسی در شکل‌گیری و پیشبرد این پژوهش داشته‌اند.

علیرضا هوشیاری
شهریور ۱۴۰۵

چکیده

افزایش شیوع اختلالات روانی، ضرورت توسعه ابزارهای دقیق، قابل اعتماد و توضیح‌پذیر برای پشتیبانی از فرایند تشخیص را برجسته ساخته است. مدل‌های زبانی بزرگ می‌توانند هم‌زمان برچسب تشخیصی و توضیح متنی تولید کنند؛ با این حال، توهم اطلاعاتی و فقدان پشتوانه دانشی صریح، استفاده از آن‌ها را در حوزه حساس سلامت روان با چالش مواجه می‌کند. هدف این پژوهش، بازپیاپی‌سازی، انطباق و مقایسه روش‌های گراف‌محور برای تشخیص توضیح‌پذیر سلامت روان است. روش‌های منتخب از سه الگوی بازپای‌محور، عامل‌محور و قیدگذارانه استفاده می‌کنند و نقش گراف دانش دامنه‌ای در پشتیبانی از استدلال و کاهش ادعاهای بدون پشتوانه در آن‌ها بررسی می‌شود. آزمایش‌ها بر روی وظایف منتخب مجموعه داده IMHI انجام خواهند شد و روش‌ها از نظر درستی پیش‌بینی، کیفیت و اتکاپذیری توضیح، زمان پاسخ و هزینه متنی مقایسه می‌شوند. همچنین، توضیحات تولیدشده با استفاده از چارچوب GraphEval در سطح ادعا و روابط ساختاری تحلیل خواهند شد.

واژه‌های کلیدی:

سلامت روان، تشخیص توضیح‌پذیر، مدل‌های زبانی بزرگ، گراف دانش، ارزیابی گراف‌محور

فهرست مطالب

عنوان

صفحه

۱	کلیات و مبانی تشخیص توضیح‌پذیر سلامت روان	۱
۱-۱	مقدمه و بیان مسئله	۱
۲-۱	تشخیص توضیح‌پذیر سلامت روان از داده‌های متنی	۲
۳-۱	مدل‌های زبانی بزرگ، توضیح‌پذیری و توهم اطلاعاتی	۳
۴-۱	بازیابی افزوده: تعریف، سازوکار و مزایا	۴
۵-۱	محدودیت‌های بازیابی متنی و ضرورت ساختار گرافی	۵
۶-۱	گراف دانش، الگوهای ادغام و جهت‌گیری پژوهش	۷
۷-۱	جمع‌بندی	۸
۲	پژوهش‌های مرتبط و روش‌های مبنا	۹
۱-۲	مقدمه و چارچوب طبقه‌بندی	۹
۲-۲	پژوهش‌های تشخیص توضیح‌پذیر سلامت روان	۱۰
۱-۲-۲	از روش‌های پیش‌بینی تا مدل‌های زبانی بزرگ	۱۰
۲-۲-۲	تنظیم دامنه‌ای و استفاده از دانش برای تولید توضیح	۱۱
۳-۲	از بازیابی افزوده متنی تا بازیابی افزوده گراف‌محور	۱۲
۴-۲	ساخت گراف دانش از متن: روش KGGen	۱۳
۵-۲	روش‌های گرافی بازیابی‌محور: سازوکار و ویژگی‌ها	۱۴
۶-۲	روش‌های گرافی عامل‌محور: سازوکار و ویژگی‌ها	۱۶
۷-۲	مقایسه روش‌های بازیابی‌محور و عامل‌محور	۱۸
۸-۲	استدلال مقید به گراف: روش GCR	۱۹
۹-۲	کاربرد در سلامت روان و مبنای ارزیابی	۲۰
۳	روش تحقیق و طراحی چارچوب آزمایش	۲۳
۱-۳	طرح کلی پژوهش	۲۳
۲-۳	تعریف وظیفه و خروجی‌های مورد انتظار	۲۴

۳-۳	منابع داده و گراف دانش دامنه‌ای	۲۵
۴-۳	روش‌های مورد مقایسه	۲۶
۱-۴-۳	استدلال زنجیره‌ای و بازیابی افزوده متعارف	۲۷
۲-۴-۳	روش‌های گراف‌محور	۲۷
۵-۳	چارچوب اجرای آزمایش‌ها	۲۸
۶-۳	معیارهای ارزیابی	۲۹
۷-۳	مقایسه منصفانه، بازتولیدپذیری و جمع‌بندی	۲۹
۴	بازپیاده‌سازی و انطباق روش‌های منتخب	۳۰
۱-۴	معماری چارچوب اجرایی و آماده‌سازی داده‌ها	۳۰
۲-۴	آماده‌سازی گراف دانش دامنه‌ای	۳۰
۳-۴	بازپیاده‌سازی خطوط پایه و روش بازیابی‌محور	۳۰
۴-۴	بازپیاده‌سازی روش‌های عامل‌محور و قیدگذارانه	۳۰
۵-۴	پیاده‌سازی ارزیابی GraphEval	۳۰
۶-۴	انطباق روش‌ها با وظیفه سلامت روان	۳۱
۷-۴	تنظیمات فنی، چالش‌ها و جمع‌بندی	۳۱
۵	نتایج و تحلیل مقایسه‌ای	۳۲
۱-۵	تنظیمات نهایی آزمایش‌ها	۳۲
۲-۵	نتایج پیش‌بینی‌های تشخیصی	۳۲
۳-۵	کیفیت توضیحات و تحلیل توهم	۳۲
۴-۵	کارایی محاسباتی و هزینه متنی	۳۲
۵-۵	مطالعات حذف مؤلفه و تحلیل حساسیت	۳۲
۶-۵	تحلیل خطا و بحث نهایی	۳۳
۷-۵	تهدیدهای اعتبار و جمع‌بندی	۳۳
۶	جمع‌بندی، محدودیت‌ها و مسیرهای آینده	۳۴
۱-۶	مرور پژوهش انجام‌شده	۳۴

۳۴	۲-۶ پاسخ به پرسش‌های پژوهش
۳۴	۳-۶ جمع‌بندی یافته‌های اصلی
۳۴	۴-۶ محدودیت‌های پژوهش
۳۴	۵-۶ پیشنهادهایی برای پژوهش‌های آینده
۳۵	۶-۶ سخن پایانی
۳۶	منابع و مراجع

فهرست شکل‌ها

صفحه

شکل

فهرست جدول‌ها

صفحه

جدول

فصل ۱

کلیات و مبانی تشخیص توضیح‌پذیر سلامت روان

۱-۱ مقدمه و بیان مسئله

سلامت روان بخشی جدایی‌ناپذیر از سلامت عمومی است و اختلال در آن می‌تواند کیفیت زندگی، روابط اجتماعی، تحصیل و اشتغال فرد را تحت تأثیر قرار دهد. در بسیاری از جوامع، نیاز به خدمات سلامت روان بیش از ظرفیت پاسخ‌گویی نظام‌های درمانی است [۱]. این فاصله، ضرورت توسعه ابزارهایی را نشان می‌دهد که شناسایی اولیه و بررسی شواهد را برای متخصصان تسهیل کنند، بدون آن‌که جایگزین ارزیابی بالینی شوند.

تشخیص اختلالات روانی بر پایه مصاحبه بالینی، مشاهده، سابقه فرد و معیارهای تشخیصی انجام می‌شود و به مدت و شدت نشانه‌ها و اثر آن‌ها بر زندگی روزمره وابسته است [۲]. در کنار این منابع، نوشته‌های منتشرشده در فضای مجازی حاوی گزارش‌هایی از تجربه‌ها و حالات هیجانی کاربران هستند و می‌توان از آن‌ها برای مطالعه الگوهای مرتبط با افسردگی، اضطراب و تنیدگی استفاده کرد [۳، ۴]. با این حال، چنین متنی معادل پرونده بالینی نیست و نتیجه حاصل از آن باید یک برآورد محاسباتی تلقی شود.

روش‌های طبقه‌بندی معمولاً یک برچسب مانند وجود یا نبود افسردگی تولید می‌کنند، اما نشان نمی‌دهند کدام شواهد متنی در تصمیم نقش داشته‌اند. این محدودیت در سلامت روان مهم است؛ زیرا

باید بتوان برداشت نادرست از کنایه، نادیده گرفتن بافت یا تعمیم از یک نشانه منفرد را تشخیص داد. از این رو، توضیح‌پذیری^۱ بخشی از ارزیابی مسئولانه سامانه است، نه صرفاً یک قابلیت جانبی [۵].

مدل‌های زبانی بزرگ^۲ می‌توانند همراه با برچسب، توضیحی متنی نیز تولید کنند. با وجود این، روان بودن توضیح درستی آن را تضمین نمی‌کند و مدل ممکن است نشانه یا رابطه‌ای را بیان کند که در ورودی وجود ندارد. این مسئله که توهم اطلاعاتی^۳ نامیده می‌شود، در حوزه سلامت روان می‌تواند به نتیجه‌گیری قطعی بر پایه شواهد ناکافی بینجامد. به همین دلیل، شفافیت، ارزیابی دقیق و نظارت انسانی در کاربردهای سلامت ضروری است [۶، ۷].

بازیابی افزوده^۴ با قراردادن اطلاعات بیرونی در اختیار مدل، راهی برای کاهش وابستگی به دانش درونی آن فراهم می‌کند [۸]. اگر این اطلاعات در قالب گراف دانش^۵ سازمان‌دهی شوند، روابط میان مفاهیم نیز در بازیابی و استدلال قابل استفاده خواهند بود. مسئله این پژوهش، بازپیاپی‌سازی و انطباق چند روش گراف‌محور و مقایسه آن‌ها در یک وظیفه مشترک سلامت روان است. روش‌ها از نظر درستی پیش‌بینی، اتکال‌پذیری توضیح، زمان پاسخ و هزینه متنی بررسی می‌شوند؛ هدف نیز ارائه یک روش گرافی تازه نیست، بلکه روشن کردن مزایا و محدودیت‌های الگوهای موجود است.

۲-۱ تشخیص توضیح‌پذیر سلامت روان از داده‌های متنی

در این پایان‌نامه، تشخیص از متن به معنای نگاشت یک نوشته خوداظهاری به برچسبی از پیش تعریف‌شده است. ورودی می‌تواند یک پیام کوتاه یا نوشته‌ای منتشرشده در شبکه اجتماعی باشد و خروجی شامل برچسب وضعیت روانی یا عامل مورد بررسی و توضیح شواهد مؤثر در آن است. منظور از تشخیص توضیح‌پذیر، صدور حکم بالینی نیست؛ سامانه باید تصمیم محاسباتی خود را به شکلی ارائه دهد که قابل بازبینی باشد.

زبان این نوشته‌ها اغلب غیررسمی، استعاری یا غیرمستقیم است و معنای یک عبارت می‌تواند به جمله‌های پیشین و پسین وابسته باشد. افزون بر این، نشانه‌هایی مانند اختلال خواب، خستگی و کاهش تمرکز به یک اختلال خاص محدود نیستند. بنابراین، مدل باید میان شواهد صریح، برداشت احتمالی و

^۱ Explainability

^۲ Large Language Models (LLMs)

^۳ Factual Hallucination

^۴ Retrieval-Augmented Generation (RAG)

^۵ Knowledge Graph (KG)

اطلاعاتی که در متن وجود ندارد تمایز بگذارد.

مجموعه‌داده IMHI^۶ داده‌های چند مجموعه پیشین را در قالب تعامل‌های دستور و پاسخ گردآوری کرده است [۹، ۱۰]. وظایف آن شامل تشخیص دودویی، تشخیص چندکلاسه، شناسایی علت یا عامل زمینه‌ای و تشخیص عوامل خطر یا ابعاد بهزیستی است. در این پژوهش، از هر گروه یک تنظیم نماینده انتخاب می‌شود تا روش‌ها در صورت‌های متفاوت مسئله و در عین حال در دامنه‌ای قابل کنترل مقایسه شوند.

توضیح مطلوب باید به متن ورودی وفادار باشد و از افزودن نشانه، رویداد یا رابطه‌ای که در متن دیده نمی‌شود پرهیز کند. ممکن است برچسب‌نهایی درست باشد، اما مسیر استدلال شامل ادعایی نادرست باشد؛ از این رو، ارزیابی برچسب و توضیح باید جداگانه انجام شود. همچنین، خطا تنها به کاهش یک معیار عددی محدود نیست: مثبت کاذب می‌تواند متن عادی را نشانه اختلال تلقی کند و منفی کاذب ممکن است شواهد مهم را نادیده بگیرد.

گراف دانش دامنه‌ای در این پژوهش منبعی صریح برای نگهداری مفاهیمی مانند اختلال، نشانه و عامل خطر و روابط میان آن‌هاست. روش گراف‌محور می‌تواند اطلاعات مرتبط را بازیابی یا مسیرهای میان مفاهیم را دنبال کند، اما وجود گراف به‌تنهایی درستی پاسخ را تضمین نمی‌کند؛ کیفیت بازیابی، پوشش گراف و نحوه استفاده مدل از شواهد بر نتیجه اثر دارند. سامانه نیز صرفاً یک ابزار تصمیم‌یار است و نتایج آن در محدوده داده‌ها و تنظیمات آزمایشی تفسیر می‌شود. حریم خصوصی، رضایت، سوگیری داده و تفاوت‌های زبانی و فرهنگی نیز باید در استفاده از داده‌های سلامت روان در نظر گرفته شوند [۶].

۳-۱ مدل‌های زبانی بزرگ، توضیح‌پذیری و توهم اطلاعاتی

مدل زبانی، توزیع احتمال دنباله‌های زبانی را می‌آموزد و در زمان تولید، هر جزء متن را با توجه به اجزای پیشین پیش‌بینی می‌کند. مدل‌های زبانی بزرگ این سازوکار را با تعداد زیادی پارامتر و بر پیکره‌های گسترده به کار می‌گیرند؛ در نتیجه، می‌توانند متن ورودی را خلاصه کنند، به پرسش پاسخ دهند و برای یک تصمیم توضیح زبانی بسازند. در این پایان‌نامه، اهمیت این مدل‌ها در توانایی انجام هم‌زمان تشخیص و تولید توضیح است، نه در استفاده از آن‌ها به عنوان منبع مستقل دانش بالینی.

دانش مدل در پارامترهای آن ذخیره شده و دسترسی مستقیم به منشأ هر گزاره آسان نیست. پاسخ

^۶Interpretable Mental Health Instruction

نیز به صورت پرسش، اطلاعات موجود در بافت ورودی و شیوه تنظیم مدل وابسته است. این ویژگی انعطاف‌پذیری زیادی ایجاد می‌کند، اما سبب می‌شود دو پاسخ زبانی مشابه از نظر پشتوانه دانشی یکسان نباشند. مدل ممکن است از یک عبارت مبهم نتیجه‌ای فراتر از متن بگیرد یا دانشی کلی را بدون مشخص کردن منبع وارد پاسخ کند.

در تشخیص توضیح‌پذیر، توضیح باید نشان دهد چه شواهدی به برجسب منتهی شده‌اند و این شواهد چگونه با نتیجه ارتباط دارند. توضیح روان یا متقاعدکننده لزوماً توضیح وفادار نیست؛ ممکن است پس از تولید برجسب ساخته شده باشد و روند واقعی تصمیم را منعکس نکند. بنابراین، کیفیت نگارش و وفاداری دو معیار متفاوت‌اند. اولی به وضوح و انسجام پاسخ مربوط است و دومی بررسی می‌کند که ادعاهای توضیح با متن ورودی و دانش معتبر پشتیبانی می‌شوند یا نه [۵].

توهم اطلاعاتی زمانی رخ می‌دهد که مدل گزاره‌ای فاقد پشتوانه در ورودی یا منبع معتبر تولید کند. در مسئله این پژوهش، این خطا می‌تواند به شکل افزودن نشانه‌ای گزارش‌نشده، نسبت‌دادن علت به یک وضعیت، یا بیان رابطه‌ای نادرست میان نشانه و اختلال ظاهر شود. چنین خطایی حتی با وجود برجسب درست نیز اعتبار توضیح را کاهش می‌دهد. حساسیت داده‌های سلامت روان نیز سبب می‌شود ادعاهای قطعی و بدون شاهد با دقت بیشتری کنترل شوند [۷].

برای کاهش این مسئله، لازم است شواهد مورد استفاده مدل تا حد امکان صریح و قابل ردیابی باشند. قرار دادن اطلاعات بازیابی‌شده در بافت ورودی، امکان مقایسه ادعاهای پاسخ با یک منبع بیرونی را فراهم می‌کند؛ هرچند انتخاب شواهد نامرتب یا استفاده نادرست از آن‌ها همچنان می‌تواند پاسخ را منحرف کند. بخش بعدی سازوکار بازیابی افزوده و نقش آن در پیوند مدل زبانی با منابع دانشی را بررسی می‌کند.

۴-۱ بازیابی افزوده: تعریف، سازوکار و مزایا

بازیابی افزوده روشی برای پیوند مدل زبانی با یک منبع دانشی بیرونی است. در این روش، مدل پاسخ را تنها بر پایه دانشی که هنگام آموزش در پارامترهای آن ذخیره شده است تولید نمی‌کند؛ ابتدا اطلاعات مرتبط با پرسش از یک مجموعه اسناد بازیابی می‌شود و سپس پرسش همراه با اطلاعات بازیابی‌شده در اختیار مدل قرار می‌گیرد. به این ترتیب، مرحله بازیابی مسئول یافتن شواهد و مرحله تولید مسئول ترکیب شواهد و ساخت پاسخ است [۸].

در آماده‌سازی منبع دانش، اسناد معمولاً به قطعه‌های کوچک‌تر تقسیم می‌شوند. این فرایند که

قطعه‌بندی^۷ نام دارد، امکان جست‌وجوی بخش مرتبط یک سند طولانی را فراهم می‌کند. سپس هر قطعه با یک بردار نهفته^۸ نمایش داده و همراه با متن و اطلاعاتی مانند شناسه سند در یک نمایه ذخیره می‌شود. در زمان پرسش، پرسش نیز به همان فضای برداری نگاشت می‌شود و قطعه‌هایی که بیشترین شباهت معنایی را دارند به عنوان نامزد انتخاب می‌شوند.

قطعه‌های برگزیده به بافت ورودی مدل افزوده می‌شوند و دستور تولید پاسخ را تشکیل می‌دهند. مدل باید با اتکا به این بافت، اطلاعات پراکنده را کنار هم قرار دهد و پاسخ نهایی را بسازد. تعداد قطعه‌های بازیابی‌شده باید محدود باشد؛ زیرا افزودن شواهد کم، احتمال حذف اطلاعات لازم را افزایش می‌دهد و افزودن شواهد زیاد می‌تواند اطلاعات نامرتبط وارد پاسخ کند یا از ظرفیت بافت مدل فراتر رود. بنابراین، کیفیت پاسخ تنها به توان مدل زبانی وابسته نیست و انتخاب درست شواهد نقش تعیین‌کننده‌ای دارد. مزیت اصلی این رویکرد، جداسازی نسبی دانش از پارامترهای مدل است. منبع بیرونی را می‌توان بدون آموزش دوباره مدل اصلاح یا به‌روزرسانی کرد و در صورت نگهداری شناسه اسناد، منشأ شواهد را نیز بررسی نمود. همچنین، محدودکردن پاسخ به اطلاعات بازیابی‌شده می‌تواند از تولید برخی ادعاهای بدون پشتوانه بکاهد. این مزیت در حوزه سلامت روان مهم است؛ زیرا باید بتوان مشخص کرد هر بخش از توضیح به کدام داده متنی یا مفهوم دامنه‌ای متکی است.

با این حال، بازیابی افزوده تضمین نمی‌کند که پاسخ همواره درست باشد. اگر قطعه مرتبط بازیابی نشود، اگر متن بازیابی‌شده مبهم یا ناسازگار باشد، یا اگر مدل از شواهد به‌درستی استفاده نکند، خطا همچنان رخ می‌دهد. از این رو، بازیابی صرفاً مرحله‌ای پیش از تولید نیست، بلکه بخشی از زنجیره استدلال و یکی از مؤلفه‌های اصلی ارزیابی سامانه است. در ادامه، محدودیت‌های بازیابی صرفاً متنی و دلیل استفاده از ساختار گرافی بررسی می‌شود.

۵-۱ محدودیت‌های بازیابی متنی و ضرورت ساختار گرافی

بازیابی متنی معمولاً هر قطعه را مستقل از سایر قطعه‌ها رتبه‌بندی می‌کند. این سازوکار برای پرسش‌هایی که پاسخ آن‌ها در یک بخش مشخص از متن قرار دارد مناسب است، اما در پرسش‌های پیچیده‌تر ممکن است شواهد لازم میان چند سند پراکنده باشند. در چنین حالتی، شباهت معنایی میان پرسش و هر قطعه به‌تنهایی برای کشف ارتباط میان شواهد کافی نیست و قطعه‌ای که واژگان مشابهی ندارد، با وجود

Chunking^۷
Embedding^۸

نقش آن در پاسخ، کنار گذاشته می‌شود.

قطعه‌بندی نیز با یک مبادله همراه است. قطعه‌های بزرگ بافت بیشتری حفظ می‌کنند، اما بازیابی آن‌ها اطلاعات نامرتب بیشتری وارد ورودی مدل می‌کند. قطعه‌های کوچک دقیق‌ترند، ولی ممکن است رابطه میان جمله‌ها، بخش‌های یک سند یا چند سند را از بین ببرند. این مسئله در مجموعه‌های بزرگ که اطلاعات مربوط به یک مفهوم در نقاط مختلف توزیع شده است شدیدتر می‌شود و بازیابی متن را در دنبال کردن زنجیره‌های چندمرحله‌ای محدود می‌کند [۱۱، ۱۲].

بسیاری از پرسش‌ها به استدلال چندگامی^۹ نیاز دارند؛ یعنی رسیدن به پاسخ مستلزم عبور از چند رابطه میان اشخاص، رویدادها یا مفاهیم است. یک فهرست رتبه‌بندی شده از قطعه‌ها این روابط را به صورت صریح نمایش نمی‌دهد و مدل باید آن‌ها را پس از بازیابی بازسازی کند. این وابستگی احتمال نادیده ماندن یک حلقه از زنجیره یا ایجاد ارتباطی بدون پشتوانه را افزایش می‌دهد. پژوهش‌های گراف‌محور نیز ضعف بازیابی برداری را در بازنمایی ارتباط‌های ساختاری و حافظه تداعی‌گر گزارش کرده‌اند [۱۳].

ساختار گرافی این امکان را فراهم می‌کند که مفاهیم به صورت گره و ارتباط‌های میان آن‌ها به صورت یال نمایش داده شوند. پس از شناسایی یک مفهوم در پرسش، بازیابی می‌تواند به مفاهیم همسایه گسترش یابد و به جای چند قطعه مستقل، یک زیرگراف مرتبط در اختیار مدل قرار دهد. در نتیجه، هم محتوای متنی و هم مسیر ارتباط میان شواهد قابل استفاده خواهد بود. برای نمونه، G-Retriever مسئله انتخاب بخش مرتبط یک گراف متنی را به صورت یافتن یک زیرگراف متصل صورت‌بندی می‌کند تا حجم ورودی کاهش یابد و ساختار لازم برای پاسخ حفظ شود [۱۴].

با این همه، گراف راه‌حلی بدون خطا نیست. گراف دانش ممکن است ناقص باشد و استخراج خودکار موجودیت‌ها و روابط می‌تواند یال‌های نادرست یا ناسازگار ایجاد کند. بازیابی گرافی نامناسب نیز ممکن است نویز را از یک گره به بخش‌های دیگر گسترش دهد. بنابراین، ضرورت استفاده از گراف به معنای کنار گذاشتن متن نیست؛ هدف، افزودن سازمان ساختاری به شواهد متنی و فراهم کردن مسیرهای قابل ردیابی است. تفاوت روش‌های موجود عمدتاً به نحوه ساخت گراف، انتخاب زیرگراف و چگونگی ادغام آن با مدل زبانی بازمی‌گردد که در بخش بعد بررسی می‌شود.

^۹ Multi-hop Reasoning

۶-۱ گراف دانش، الگوهای ادغام و جهت‌گیری پژوهش

گراف دانش، اطلاعات را به صورت مجموعه‌ای از موجودیت‌ها و روابط میان آن‌ها نمایش می‌دهد. هر گزاره را می‌توان با یک سه‌تایی شامل موجودیت مبدأ، نوع رابطه و موجودیت مقصد بیان کرد. برای نمونه، ارتباط میان یک نشانه، عامل خطر و اختلال می‌تواند به صورت چند سه‌تایی مرتبط ذخیره شود. برخلاف متن پیوسته، این بازنمایی امکان جست‌وجوی مستقیم همسایه‌های یک مفهوم و دنبال کردن مسیرهای چندگامی را فراهم می‌کند. همچنین، افزودن یا اصلاح یک رابطه بدون آموزش دوباره مدل زبانی امکان‌پذیر است.

در روش‌های بازیابی محور^{۱۰}، یک بازیاب بیرونی بخش مرتبط گراف یا اسناد متصل به آن را انتخاب می‌کند و نتیجه را در اختیار مدل زبانی قرار می‌دهد. مزیت این الگو آن است که فرایند بازیابی از تولید پاسخ جداست و می‌توان کیفیت زیرگراف، میزان پوشش شواهد و هزینه بازیابی را مستقل ارزیابی کرد. در مقابل، عملکرد روش به دقت بازیاب وابسته است؛ حذف یک گره یا مسیر مهم در این مرحله ممکن است با توان استدلالی مدل جبران نشود. HippoRAG 2، G-Retriever و در مقیاسی محدودتر LinearRAG نمونه‌هایی از این جهت‌گیری‌اند که با سازوکارهای متفاوت، ارتباط ساختاری میان قطعه‌های متنی را در بازیابی وارد می‌کنند [۱۲، ۱۳، ۱۴].

در روش‌های عامل محور^{۱۱}، مدل زبانی تنها مصرف‌کننده نتیجه بازیابی نیست، بلکه در انتخاب گام بعدی جست‌وجو نقش دارد. مدل از مفاهیم اولیه شروع می‌کند، رابطه‌ها و موجودیت‌های محتمل را ارزیابی می‌کند و این چرخه تا یافتن شواهد کافی یا رسیدن به حد توقف ادامه می‌یابد. روش ToG این ایده را با پیمایش تکرارشونده مسیرهای گرافی به کار می‌گیرد و ToG-2 بازیابی گراف و متن را به صورت رفت‌وبرگشتی ترکیب می‌کند [۱۵، ۱۱]. این الگو برای پرسش‌های چندگامی انعطاف بیشتری دارد، اما به فراخوانی‌های متعدد مدل وابسته است و در نتیجه زمان پاسخ و هزینه آن افزایش می‌یابد. افزون بر این، انتخاب نادرست در یک گام می‌تواند ادامه پیمایش را به مسیر نامرتبط هدایت کند.

الگوی سوم، استدلال مقید به گراف^{۱۲} است. در این الگو، ساختار گراف تنها در ورودی مدل قرار نمی‌گیرد، بلکه گزینه‌های مجاز هنگام تولید مسیر استدلال را محدود می‌کند. روش GCR مسیرهای گراف را در نمایه‌ای به نام KG-Trie ذخیره می‌کند و مدل را وادار می‌سازد دنباله‌ای سازگار با مسیرهای

^{۱۰} Retrieval-based Methods

^{۱۱} Agent-based Methods

^{۱۲} Graph-constrained Reasoning

موجود در گراف تولید کند [۱۶]. این قید از ساخت رابطه‌ای که در گراف وجود ندارد جلوگیری می‌کند و ردیابی مسیر را دقیق‌تر می‌سازد؛ با این حال، اگر دانش لازم در گراف ثبت نشده باشد، محدودیت ساختاری نمی‌تواند آن را جبران کند.

تفاوت این سه الگو در محل اعمال ساختار گراف است. در روش بازیابی‌محور، گراف بر انتخاب شواهد اثر می‌گذارد؛ در روش عامل‌محور، گراف فضای جست‌وجوی تعاملی مدل را شکل می‌دهد؛ و در روش مقید، مسیر تولیدشده باید با ساختار گراف سازگار باشد. در نتیجه، هر الگو تعادل متفاوتی میان پوشش شواهد، انعطاف استدلال، وفاداری مسیر و هزینه محاسباتی برقرار می‌کند. مقایسه منصفانه آن‌ها نیازمند داده، گراف و معیارهای ارزیابی مشترک است.

جهت‌گیری این پژوهش، بازپیاپی‌سازی و انطباق نماینده‌هایی از این الگوها برای تشخیص توضیح‌پذیر سلامت روان است. همه روش‌ها بر وظایف منتخب IMHI و یک گراف دانش دامنه‌ای مشترک ارزیابی می‌شوند تا اثر سازوکار ادغام از تفاوت داده و دانش جدا شود. مقایسه بر درستی برچسب، وفاداری و کیفیت توضیح، زمان پاسخ و هزینه متنی متمرکز است. افزون بر معیارهای معمول، ادعاها و روابط بیان‌شده در توضیح با چارچوب GraphEval بررسی می‌شوند تا مشخص شود هر پاسخ تا چه اندازه به شواهد قابل ردیابی متکی است.

۷-۱ جمع‌بندی

در این فصل، مسئله تشخیص توضیح‌پذیر سلامت روان از داده‌های متنی و تفاوت آن با طبقه‌بندی صرف بیان شد. سپس نقش مدل‌های زبانی بزرگ در تولید هم‌زمان برچسب و توضیح، مسئله توهم اطلاعاتی و نیاز به سنجش مستقل وفاداری توضیح بررسی گردید. بازیابی افزوده به عنوان راهی برای اتصال مدل به دانش بیرونی معرفی شد و نشان داده شد که بازیابی متنی، به دلیل رتبه‌بندی مستقل قطعه‌ها و ناتوانی در نمایش صریح روابط، در پرسش‌های چندگامی با محدودیت روبه‌روست.

در ادامه، ساختار گرافی و سه الگوی بازیابی‌محور، عامل‌محور و استدلال مقید از یکدیگر تفکیک شدند. این الگوها از نظر نحوه انتخاب شواهد، میزان دخالت مدل در پیمایش، وفاداری مسیر و هزینه اجرایی تفاوت دارند و مبنای مقایسه این پژوهش را تشکیل می‌دهند. فصل بعد، پژوهش‌های مرتبط و روش‌های مبنا را بر پایه همین تقسیم‌بندی بررسی می‌کند و مزایا و محدودیت‌های هر خانواده را با جزئیات بیشتری توضیح می‌دهد.

فصل ۲

پژوهش‌های مرتبط و روش‌های مبنا

۱-۲ مقدمه و چارچوب طبقه‌بندی

هدف این فصل، مرور پژوهش‌های مرتبط با تشخیص توضیح‌پذیر سلامت روان و بررسی روش‌هایی است که مبنای بازپیاپی‌سازی و آزمایش‌های این پژوهش قرار می‌گیرند. ابتدا کارهای مرتبط با وظیفه، از طبقه‌بندی متن تا تولید توضیح و استفاده از دانش دامنه‌ای، مرور می‌شوند. سپس روش‌های بازپیاپی افزوده و گراف‌محور از نظر مسئله اولیه، نوع شواهد و نحوه تولید پاسخ بررسی می‌شوند تا شرایط لازم برای انطباق آن‌ها با سلامت روان روشن گردد.

روش‌های منتخب بر اساس محل دخالت گراف در فرایند پاسخ‌گویی به سه خانواده تقسیم می‌شوند. در خانواده بازپیاپی‌محور، بخشی از گراف یا اسناد مرتبط پیش از تولید پاسخ انتخاب و به مدل داده می‌شود؛ HippoRAG 2، G-Retriever و در مقیاسی محدودتر LinearRAG در این دسته بررسی می‌شوند. در خانواده عامل‌محور، مدل زبانی در چند مرحله با گراف تعامل می‌کند و مسیر جست‌وجو را شکل می‌دهد؛ ToG و ToG-2 نمایندگان این الگو هستند. در نهایت، روش GCR به عنوان یک الگوی قیدگذارانه بررسی می‌شود که ساختار گراف را در فرایند تولید مسیر استدلال وارد می‌کند.

این طبقه‌بندی به معنای برتری ذاتی یک خانواده بر خانواده دیگر نیست. هر الگو برای هدف و تنظیم آزمایشی متفاوتی طراحی شده و میان پوشش شواهد، انعطاف استدلال، وفاداری مسیر و هزینه اجرا تعادل خاصی برقرار می‌کند. از این رو، مقایسه روش‌ها علاوه بر کیفیت پاسخ، به نیاز آن‌ها به آموزش، تعداد تعامل‌ها با مدل زبانی، نحوه انتخاب زیرگراف یا متن مرتبط، امکان ردیابی شواهد، زمان پاسخ و هزینه

متنی توجه خواهد داشت. این معیارها مبنای تنظیم بنچمارک مشترک در فصل‌های بعد هستند. پس از مرور پژوهش‌های سلامت روان، بازیابی افزوده به عنوان راهی برای دسترسی مدل به دانش بیرونی معرفی می‌شود و گذار از بازیابی متنی به گراف‌محور توضیح داده می‌شود. پیش از بررسی شیوه‌های استفاده از گراف، روش KGGen برای ساخت گراف دانش از متن معرفی می‌شود. سپس روش‌های بازیابی‌محور و عامل‌محور معرفی و مقایسه می‌شوند و GCR از نظر قیدگذاری ساختاری بررسی می‌گردد. بخش پایانی نیز نحوه انتقال این روش‌ها به وظایف منتخب سلامت روان و معیارهای ارزیابی مشترک را جمع‌بندی می‌کند.

۲-۲ پژوهش‌های تشخیص توضیح‌پذیر سلامت روان

پژوهش‌های این حوزه از نظر نوع خروجی و نحوه استفاده از دانش متفاوت‌اند. برخی، متن یا سابقه فعالیت کاربر را به یک برچسب نگاشت می‌کنند؛ برخی همراه با برچسب، توضیح زبانی تولید می‌کنند؛ و گروهی نیز معیارهای تشخیصی یا منابع دانش را در پردازش وارد می‌کنند. مرور این کارها مشخص می‌کند که روش‌های گرافی در این پایان‌نامه قرار است در چه وظیفه‌ای و با چه خروجی‌هایی ارزیابی شوند.

۱-۲-۲ از روش‌های پیش‌بینی تا مدل‌های زبانی بزرگ

در کارهای اولیه، تشخیص افسردگی عمدتاً به صورت یک مسئله طبقه‌بندی از داده‌های شبکه‌های اجتماعی صورت‌بندی شده است. شن و همکاران از یادگیری فرهنگ‌نامه چندوجهی برای ترکیب اطلاعات کاربران استفاده کرده‌اند و اورابی و همکاران، یادگیری عمیق را برای تشخیص افسردگی کاربران تویتر بررسی کرده‌اند [۱۷، ۳]. پژوهش SenseMood نیز در همین مسیر به تشخیص افسردگی در شبکه‌های اجتماعی می‌پردازد [۱۸]. این مطالعات مبنایی برای یادگیری الگوهای مرتبط با برچسب فراهم می‌کنند، در حالی که تولید توضیح زبانی برای هر تصمیم، خروجی اصلی آن‌ها نیست.

روش AMMNet مسئله پیش‌بینی افسردگی و اضطراب در Reddit را با یادگیری چندوظیفه‌ای دنبال می‌کند [۴]. در این روش، نمایش‌های متنی مشترک با ویژگی‌های موضوعی اختصاصی وظایف ترکیب می‌شوند. استفاده از اطلاعات مشترک، امکان بهره‌گیری از ارتباط میان وظایف را فراهم می‌کند و ویژگی‌های موضوعی نیز به بررسی محتوای مؤثر در پیش‌بینی کمک می‌کنند. این نوع تفسیر ویژگی‌ها

با توضیح آزاد زبانی تفاوت دارد، اما برای مقایسه شیوه‌های ارائه شواهد تصمیم مفید است. با ورود مدل‌های زبانی بزرگ، امکان تولید هم‌زمان برچسب و توضیح مطرح شد. یانگ و همکاران در پژوهش «به سوی تحلیل تفسیرپذیر سلامت روان با مدل‌های زبانی بزرگ»، تنظیم‌های بدون نمونه، چندنمونه‌ای و استدلال زنجیره‌ای را بررسی کرده‌اند [۹]. مدل در این تنظیم‌ها با استفاده از دستور و نمونه‌های داخل ورودی به وظیفه هدایت می‌شود و برای هر وظیفه الزاماً آموزش مجدد نمی‌بیند. ارزیابی انسانی توضیح‌ها نیز بخشی از مطالعه است؛ بنابراین، این کار علاوه بر پیش‌بینی برچسب، کیفیت توضیح را به عنوان خروجی قابل سنجش مطرح می‌کند. چنین تنظیم‌هایی می‌توانند مبنای مقایسه با روش‌هایی باشند که دانش بیرونی دریافت می‌کنند.

۲-۲-۲ تنظیم دامنه‌ای و استفاده از دانش برای تولید توضیح

روش MentalLLaMA تحلیل توضیح‌پذیر سلامت روان را از طریق تنظیم دستوری مدل دنبال می‌کند [۱۰]. داده‌های چند وظیفه در مجموعه IMHI به قالب دستور و پاسخ تبدیل شده‌اند و پاسخ‌ها شامل برچسب و توضیح‌اند. توضیح‌ها با کمک مدل زبانی تولید و با ارزیابی‌های خودکار و انسانی بررسی شده‌اند. آموزش بر این داده‌ها، مدل را با صورت وظایف و نحوه پاسخ‌گویی آشنا می‌کند. ارتباط مستقیم این کار با پایان‌نامه حاضر، استفاده از IMHI و ارزیابی جداگانه پیش‌بینی و توضیح است؛ در اینجا نقش افزودن شواهد گرافی به همین نوع خروجی بررسی خواهد شد.

چارچوب DORIS بر تشخیص افسردگی از پست‌های کاربران تمرکز دارد و دانش تشخیصی را در استخراج ویژگی‌ها وارد می‌کند [۱۹]. مدل زبانی، متن‌ها را از نظر نشانه‌های مرتبط با معیارهای تشخیصی بررسی و روند زمانی حالات خلقی را خلاصه می‌کند. این اطلاعات همراه با نمایش محتوای پست‌ها برای آموزش یک طبقه‌بند به کار می‌روند. توضیح پیش‌بینی نیز بر پایه نشانه‌ها و تحلیل روند خلقی تولید می‌شود. در نتیجه، مدل زبانی هم در آماده‌سازی شواهد و هم در بیان توضیح نقش دارد و تصمیم نهایی از یک مؤلفه طبقه‌بندی حاصل می‌شود. این پژوهش نمونه‌ای از استفاده صریح از دانش دامنه‌ای است، هرچند ورودی آن سابقه پست‌های کاربر است و تنظیم آن با تمام وظایف IMHI یکسان نیست.

در سطح منابع دانش، گائو و همکاران گراف MDKG را با استفاده از متون علمی، پایگاه‌های زیست‌پزشکی و مدل‌های زبانی ساخته‌اند [۲۰]. این کار اطلاعات مرتبط با اختلالات روانی را در یک ساختار مشترک سازمان‌دهی می‌کند و کاربرد نمایش‌های حاصل را در پیش‌بینی نیز می‌سنجد. نقش آن در مرور حاضر، معرفی یک مسیر برای فراهم کردن دانش دامنه‌ای است؛ انتخاب و آماده‌سازی منبع

گراف برای آزمایش‌های این پایان‌نامه در فصل روش تحقیق مشخص خواهد شد. این پژوهش‌ها سه راه برای پشتیبانی از تصمیم را نشان می‌دهند: یادگیری از داده‌های برجسب‌دار، آموزش نحوه تولید توضیح و استفاده از دانش دامنه‌ای. بازیابی افزوده راه دیگری برای دسترسی به دانش فراهم می‌کند که در آن، شواهد متناسب با هر ورودی انتخاب و به مدل داده می‌شوند. بخش بعد این سازوکار را توضیح می‌دهد و سپس به نقش روابط گرافی در انتخاب و استفاده از شواهد می‌پردازد.

۲-۳ از بازیابی افزوده متنی تا بازیابی افزوده گراف‌محور

در الگوی متداول بازیابی افزوده، منبع بیرونی مجموعه‌ای از اسناد متنی است که پس از قطعه‌بندی و تبدیل به نمایش‌های برداری، نمایه‌سازی می‌شوند. برای هر پرسش، چند قطعه با بیشترین شباهت معنایی بازیابی و همراه با پرسش به مدل زبانی داده می‌شوند. این الگو امکان استفاده از اطلاعات بیرون از پارامترهای مدل را بدون آموزش دوباره فراهم می‌کند و به دلیل سادگی و قابلیت اجرا روی مجموعه‌های بزرگ، مبنای بسیاری از سامانه‌های بازیابی افزوده قرار گرفته است [۸].

بازیابی متنی بر دو فرض اصلی استوار است: نخست آن‌که قطعه مرتبط را بتوان با شباهت میان پرسش و متن تشخیص داد و دوم آن‌که اطلاعات لازم برای پاسخ در همان قطعه یا در تعداد محدودی از قطعه‌های برتر وجود داشته باشد. این فرض‌ها برای پرسش‌های مستقیم و واقعیت‌محور مناسب‌اند. افزون بر این، اسناد می‌توانند مستقل از یکدیگر به نمایه افزوده یا از آن حذف شوند و هزینه جست‌وجو نیز با استفاده از نمایه‌های برداری قابل کنترل است.

در پرسش‌های چندگامی، شواهد ممکن است میان چند قطعه یا سند توزیع شده باشند و ارتباط آن‌ها فقط از طریق یک یا چند مفهوم واسط آشکار شود. در این حالت، قطعه‌ای که به‌تنهایی شباهت زیادی با پرسش ندارد ممکن است یکی از حلقه‌های لازم برای رسیدن به پاسخ باشد. انتخاب مستقل قطعه‌ها چنین ارتباطی را مستقیماً نمایش نمی‌دهد و ترکیب آن‌ها به مدل زبانی واگذار می‌شود. همین مسئله سبب شده است برخی پژوهش‌ها ساختارهایی را به بازیابی اضافه کنند که پیوند میان بخش‌های مختلف دانش را نیز در مرحله جست‌وجو لحاظ می‌کنند [۱۱، ۱۳].

در بازیابی افزوده گراف‌محور، واحدهای اطلاعاتی به صورت گره و ارتباط میان آن‌ها به صورت یال نمایش داده می‌شوند. گره می‌تواند یک موجودیت، گزاره، جمله یا قطعه متن باشد و یال نیز رابطه دانشی، هم‌رخدادی یا پیوند معنایی میان دو گره را نشان دهد. بنابراین، خروجی بازیاب لزوماً مجموعه‌ای

از قطعه‌های مستقل نیست و می‌تواند شامل چند سه‌تایی، یک مسیر یا یک زیرگراف متصل باشد. برای نمونه، G-Retriever بخشی از گراف متنی را با توجه به پرسش انتخاب می‌کند و ساختار همان بخش را همراه با محتوای متنی در اختیار مدل قرار می‌دهد [۱۴].

گذار به بازیابی گراف‌محور به معنای جایگزینی کامل متن با گراف نیست. گراف روابط و مسیرهای ارتباطی را به صورت صریح نگهداری می‌کند، در حالی که متن جزئیات و زمینه‌ای را در بر دارد که ممکن است در سه‌تایی‌های گراف ثبت نشده باشد. به همین دلیل، برخی روش‌ها از گراف برای هدایت بازیابی متن استفاده می‌کنند و برخی دیگر، شواهد گرافی و متنی را به صورت ترکیبی به مدل می‌دهند. ToG-2 نمونه‌ای از ادغام رفت‌وبرگشتی این دو منبع است که در آن نتایج پیمایش گراف، بازیابی متن را هدایت می‌کند و متن بازیابی‌شده نیز بر ادامه پیمایش اثر می‌گذارد [۱۱].

در نتیجه، بازیابی متنی و گراف‌محور در نحوه سازمان‌دهی دانش، واحد بازیابی و میزان استفاده از روابط ساختاری تفاوت دارند. برای استفاده از روابط، ابتدا باید مشخص شود گراف چگونه از منابع متنی ساخته می‌شود و صورت‌های مختلف یک مفهوم چگونه در آن یکسان می‌شوند. از این رو، بخش بعد روش KGGen را برای ساخت گراف دانش از متن معرفی می‌کند. پس از آن، شیوه‌های انتخاب شواهد و پیمایش گراف در روش‌های بازیابی‌محور و عامل‌محور بررسی خواهند شد.

۴-۲ ساخت گراف دانش از متن: روش KGGen

ساخت گراف از متن، مرحله آماده‌سازی دانش برای بازیابی و استدلال است. در این مرحله باید مفاهیم و روابط متن استخراج شوند و اطلاعات اسناد مختلف در یک ساختار قابل جست‌وجو قرار گیرند. برای مثال، ثبت یک مفهوم با چند نام مستقل می‌تواند ارتباط شواهد پراکنده را مخفی کند. در مقابل، ادغام دو مفهوم متمایز ممکن است رابطه‌ای گمراه‌کننده ایجاد کند. بنابراین، کیفیت گراف تنها به تعداد سه‌تایی‌های استخراج‌شده وابسته نیست و نحوه یکسان‌سازی آن‌ها نیز اهمیت دارد.

روش KGGen سه مرحله دارد: استخراج، تجمیع و یکسان‌سازی موجودیت‌ها و روابط [۲۱]. ابتدا مدل زبانی فهرست موجودیت‌های هر متن را استخراج می‌کند و سپس با دریافت متن و این فهرست، سه‌تایی‌ها را می‌سازد. در مرحله تجمیع، گراف‌های حاصل از منابع مختلف ترکیب و موارد تکراری یکسان حذف می‌شوند. این مرحله به فراخوانی مدل زبانی نیاز ندارد.

در مرحله سوم، نام‌های متفاوتی که به یک موجودیت یا رابطه اشاره دارند شناسایی می‌شوند. در نسخه

دوم مقاله، نمایش‌های برداری برای خوشه‌بندی به کار می‌روند و نامزدهای مشابه با ترکیب جست‌وجوی واژگانی و معنایی پیدا می‌شوند. مدل زبانی هم‌ارزی نامزدها را بررسی و برای موارد تکراری یک نام نماینده انتخاب می‌کند. این فرایند جداگانه بر موجودیت‌ها و روابط اعمال می‌شود تا تنوع نام‌گذاری، گراف را بی‌جهت پراکنده نکند؛ صرف شباهت معنایی نیز نباید به ادغام مفاهیم متفاوت منجر شود.

مقاله برای ارزیابی استخراج، بنچمارک MINE را معرفی می‌کند که حفظ اطلاعات متن و کاربرد گراف در بازیابی افزوده را می‌سنجد. در این پایان‌نامه، KGGen به عنوان یک روش ساخت گراف بررسی می‌شود؛ انتخاب منابع سلامت روان و کنترل کیفیت گراف حاصل، بخشی از طراحی آزمایش خواهد بود. پس از آماده‌سازی چنین ساختاری، مسئله بعدی انتخاب بخش مرتبط آن برای هر ورودی است که در بخش بعد بررسی می‌شود.

۵-۲ روش‌های گرافی بازیابی‌محور: سازوکار و ویژگی‌ها

در روش‌های گرافی بازیابی‌محور، انتخاب شواهد پیش از تولید پاسخ و به وسیله یک مؤلفه بازیاب انجام می‌شود. مدل زبانی زیرگراف یا قطعه‌های متنی حاصل از بازیابی را دریافت می‌کند، اما مستقیماً درباره گام بعدی پیمایش تصمیم نمی‌گیرد. روش‌های این خانواده در سه مؤلفه با یکدیگر تفاوت دارند: گراف از پیش موجود است یا از متن ساخته می‌شود، امتیاز ارتباط پرسش با گره‌ها و یال‌ها چگونه محاسبه می‌گردد، و خروجی بازیاب به صورت زیرگراف یا مجموعه‌ای از قطعه‌های متن در اختیار مدل قرار می‌گیرد.

روش G-Retriever برای پرسش و پاسخ روی گراف‌های متنی طراحی شده است؛ یعنی گراف‌هایی که گره‌ها و یال‌های آن‌ها ویژگی متنی دارند [۱۴]. فرایند این روش چهار مرحله دارد. ابتدا متن گره‌ها و یال‌ها رمزگذاری و برای جست‌وجوی نزدیک‌ترین همسایه نمایه‌سازی می‌شود. سپس پرسش با همان رمزگذار به یک بردار تبدیل می‌گردد و مرتبط‌ترین گره‌ها و یال‌ها بر اساس شباهت با پرسش انتخاب می‌شوند. این امتیازها مشخص می‌کنند کدام اجزای گراف برای پاسخ اهمیت بیشتری دارند.

پس از امتیازدهی اولیه، انتخاب نهایی زیرگراف به صورت مسئله درخت اشتاینر جایزه‌جمع‌کن^۱ صورت‌بندی می‌شود. در این صورت‌بندی، گره‌ها و یال‌های مرتبط جایزه بیشتری دارند و افزودن اجزای دیگر به زیرگراف با هزینه همراه است. نتیجه، زیرگرافی متصل است که میان پوشش اجزای مرتبط و

^۱ Prize-Collecting Steiner Tree (PCST)

محدود نگه داشتن اندازه ورودی تعادل برقرار می‌کند. زیرگراف به متن تبدیل و همراه با پرسش و نمایش حاصل از رمزگذار گراف به مدل زبانی داده می‌شود. بازگرداندن همین زیرگراف، امکان مشاهده شواهد انتخاب‌شده را نیز فراهم می‌کند.

مزیت ساختار G-Retriever آن است که می‌تواند روی گرافی بزرگ‌تر از ظرفیت ورودی مدل عمل کند و تنها بخش مرتبط و متصل آن را وارد مرحله تولید نماید. در مقابل، استفاده از آن مستلزم وجود یک گراف متنی و محاسبه امتیاز مناسب برای گره‌ها و یال‌هاست. همچنین، کیفیت پاسخ به زیرگراف استخراج‌شده وابسته است؛ اگر جزء لازم در مرحله بازیابی امتیاز کافی نگیرد، در ورودی مدل نیز حضور نخواهد داشت. بنابراین، در بازپیاپی‌سازی این روش باید عملکرد بازیاب و مولد به صورت جداگانه ثبت شود.

روش HippoRAG 2 با فرض متفاوتی آغاز می‌کند و گراف را از مجموعه اسناد می‌سازد [۱۳]. در مرحله نمایه‌سازی برون‌خط، یک مدل زبانی با استخراج اطلاعات باز^۲ از هر قطعه، سه‌تایی‌های بدون شمای ثابت تولید می‌کند. موضوع و مفعول این سه‌تایی‌ها به صورت گره‌های عبارتی و رابطه میان آن‌ها به صورت یال ذخیره می‌شود. سپس پیوندهای هم‌معنا بر پایه شباهت برداری افزوده می‌شوند. نسخه دوم HippoRAG علاوه بر این مفاهیم، خود قطعه‌های متن را نیز به عنوان گره نگه می‌دارد و آن‌ها را به عبارت‌های استخراج‌شده متصل می‌کند؛ در نتیجه، ساختار مفهومی و زمینه اصلی متن در یک نمایه مشترک قرار می‌گیرند.

در زمان بازیابی، پرسش با سه‌تایی‌ها و قطعه‌های متن مقایسه می‌شود و نامزدهای اولیه برای شروع جست‌وجوی گرافی شکل می‌گیرند. یک مرحله بازشناسی با استفاده از مدل زبانی، سه‌تایی‌های نامرتبط را از میان نامزدهای برتر حذف می‌کند. سپس الگوریتم رتبه صفحه شخصی‌سازی شده^۳ با وزن‌دهی اولیه به گره‌های عبارتی و متنی اجرا می‌شود و قطعه‌ها بر اساس امتیاز نهایی رتبه‌بندی می‌گردند. خروجی بازیاب در این روش خود گراف نیست، بلکه قطعه‌های متنی برتری است که برای پاسخ‌گویی به مدل زبانی داده می‌شوند.

این طراحی، بازیابی واقعیت‌های مستقیم و پیوندهای چندگامی میان قطعه‌ها را در یک فرایند واحد دنبال می‌کند. با این حال، بخشی از هزینه در زمان ساخت گراف و اجرای مدل زبانی برای استخراج سه‌تایی‌ها صرف می‌شود و مرحله پالایش برخط نیز یک فراخوانی اضافی ایجاد می‌کند. در نتیجه، هنگام

^۲ Open Information Extraction (OpenIE)

^۳ Personalized PageRank (PPR)

ارزیابی HippoRAG 2 باید هزینه آماده‌سازی نمایه از هزینه هر پرسش جدا شود. کیفیت سه‌تایی‌های استخراج‌شده و نحوه تنظیم وزن آغازین گره‌ها نیز بر رتبه نهایی قطعه‌ها اثر می‌گذارند.

روش LinearRAG مسیر سبک‌تری برای ساخت گراف از متن در نظر می‌گیرد و به جای استخراج رابطه، سه نوع گره موجودیت، جمله و قطعه متن را در ساختاری به نام Tri-Graph به هم متصل می‌کند [۱۲]. بازیابی آن در دو مرحله انجام می‌شود: ابتدا موجودیت‌های مرتبط از طریق پیوندهای معنایی فعال می‌شوند و سپس اهمیت قطعه‌ها با انتشار امتیاز روی گراف محاسبه می‌گردد. این روش از جزئیات رابطه صرف‌نظر می‌کند تا ساخت نمایه ساده‌تر و کم‌هزینه‌تر باشد. با توجه به دامنه این پایان‌نامه، LinearRAG بیشتر به عنوان نمونه‌ای از گراف‌سازی بدون رابطه صریح در نظر گرفته می‌شود و بررسی اصلی بر دو روش پیشین متمرکز خواهد بود.

در مجموع، G-Retriever گراف را ورودی مسئله فرض می‌کند و یک زیرگراف متصل تحویل می‌دهد، در حالی که HippoRAG 2 و LinearRAG ابتدا از پیکره متنی ساختار گرافی می‌سازند و در پایان قطعه‌های متن را بازیابی می‌کنند. تفاوت دیگر در سازوکار انتخاب است: اولی از بهینه‌سازی اتصال زیرگراف استفاده می‌کند و دو روش دیگر امتیاز را روی گراف منتشر می‌سازند. این تفاوت‌ها بر نوع داده مورد نیاز، هزینه نمایه‌سازی، امکان مشاهده مسیر بازیابی و حجم اطلاعات ورودی مدل اثر دارند. بخش بعد، خانواده عامل‌محور را بررسی می‌کند که در آن مدل زبانی در انتخاب گام‌های پیمایش نقش مستقیم‌تری دارد.

۶-۲ روش‌های گرافی عامل‌محور: سازوکار و ویژگی‌ها

در روش‌های عامل‌محور، مدل زبانی در یک چرخه جست‌وجو و ارزیابی شواهد قرار می‌گیرد. پرس‌وجو از گراف، همسایه‌ها و روابط موجود را مشخص می‌کند و مدل از میان این گزینه‌ها، ادامه‌های مرتبط با پرسش را برمی‌گزیند. پس از هر مرحله، اطلاعات گردآوری‌شده برای پاسخ‌گویی بررسی می‌شوند و در صورت ناکافی بودن، کاوش ادامه می‌یابد. دو روش ToG و ToG-2 این الگو را به‌ترتیب با تکیه بر مسیرهای گرافی و با ترکیب گراف و متن به کار می‌گیرند.

روش ToG جست‌وجو را از موجودیت‌های شناسایی‌شده در پرسش آغاز می‌کند و چند مسیر محتمل را به‌طور هم‌زمان نگه می‌دارد [۱۵]. این فرایند بر جست‌وجوی پرتوی^۴ استوار است؛ یعنی در هر مرحله،

^۴ Beam Search

تنها تعداد محدودی از مسیرهای برتر برای گسترش بعدی حفظ می‌شوند. دو پارامتر اصلی، عرض جست‌وجو و بیشینه عمق هستند: اولی تعداد مسیرهای نگه‌داشته‌شده و دومی حداکثر تعداد گام‌های پیمایش را تعیین می‌کند. این محدودیت‌ها اندازه فضای جست‌وجو و هزینه تعامل با مدل را کنترل می‌کنند.

کاوش در ToG دو مرحله دارد. ابتدا روابط متصل به انتهای هر مسیر از گراف خوانده می‌شوند و مدل، روابط مرتبط با پرسش را امتیازدهی و انتخاب می‌کند. سپس موجودیت‌های متصل از طریق روابط منتخب بازیابی می‌شوند و مدل از میان آن‌ها نامزدهای مناسب را برمی‌گزیند. بدین ترتیب، مسیرهای باقی‌مانده با یک سه‌تایی جدید گسترش می‌یابند. انتخاب رابطه پیش از موجودیت، تعداد نامزدهایی را که مدل باید بررسی کند کاهش می‌دهد؛ جهت یال نیز در بازیابی همسایه‌ها لحاظ می‌شود.

پس از گسترش مسیرها، مدل بررسی می‌کند که آیا اطلاعات موجود برای پاسخ کافی است. در صورت کفایت، پاسخ با استفاده از پرسش و مسیرها تولید می‌شود و در غیر این صورت، چرخه تا رسیدن به حد عمق ادامه می‌یابد. در نسخه اصلی، اگر جست‌وجو در این حد نیز شواهد کافی نیابد، پاسخ با اتکا به دانش درونی مدل تولید می‌شود. این حالت باید هنگام ارزیابی از پاسخ‌های متکی بر مسیر تفکیک شود. مسیرهای صریح، امکان مشاهده و بازیابی روابط پیموده‌شده را فراهم می‌کنند؛ اجرای روش نیز به تنظیم مجدد پارامترهای مدل زبانی نیاز ندارد.

روش ToG-2 همین جهت‌گیری تعاملی را با اسناد متنی متصل به موجودیت‌ها گسترش می‌دهد [۱۱]. پس از پیونددهی موجودیت‌های پرسش و انتخاب نقطه‌های شروع، ابتدا قطعه‌هایی از اسناد مرتبط بازیابی می‌شوند. اگر همین اطلاعات برای پاسخ کافی باشند، نیازی به پیمایش بیشتر نیست. در غیر این صورت، جست‌وجوی روابط و موجودیت‌های همسایه آغاز می‌شود تا منابع متنی تازه‌ای در دسترس قرار گیرند. در این طراحی، گراف محدوده بازیابی را هدایت می‌کند و متن، جزئیاتی را فراهم می‌سازد که لزوماً در سه‌تایی‌ها ثبت نشده‌اند.

تعامل متن و گراف در ToG-2 دوطرفه است. قطعه‌های مربوط به موجودیت‌های نامزد با در نظر گرفتن پرسش و رابطه‌ای که به آن‌ها منتهی شده رتبه‌بندی می‌شوند. سپس امتیاز قطعه‌ها برای انتخاب موجودیت‌های مرحله بعد به کار می‌رود؛ بنابراین، ادامه پیمایش فقط بر نام موجودیت یا رابطه متکی نیست. در پایان هر دور، مسیرها، قطعه‌های برتر و سرخ‌های مراحل پیشین به مدل داده می‌شوند. مدل یا پاسخ را تولید می‌کند، یا سرخ‌های مفید را خلاصه می‌سازد و با بازتنظیم پرسش، جست‌وجو را تا حد تعیین‌شده ادامه می‌دهد.

در مجموع، ToG ساختاری ساده‌تر برای کاوش مسیرهای دانشی فراهم می‌کند و ToG-2 از متن برای تکمیل شواهد و هدایت دقیق‌تر کاوش بهره می‌گیرد. استفاده از نسخه دوم مستلزم ارتباط مشخص میان گراف و اسناد است و کیفیت این پیوندها بر بازیابی اثر دارد. در هر دو روش، افزایش عرض یا عمق می‌تواند شواهد بیشتری در دسترس قرار دهد، اما هزینه و زمان پاسخ را نیز تغییر می‌دهد. برای مقایسه در این پایان‌نامه، مسیرهای پیموده‌شده، شرط توقف، تعداد فراخوانی‌ها و شواهد نهایی ثبت خواهند شد تا کیفیت پاسخ در کنار نحوه دستیابی به آن بررسی شود.

۷-۲ مقایسه روش‌های بازیابی محور و عامل محور

تفاوت اصلی این دو خانواده در نحوه هدایت جست‌وجو است. در روش‌های بازیابی محور، الگوریتم بازیابی بر اساس پرسش، شواهد را انتخاب می‌کند و سپس آن‌ها را به مولد می‌سپارد. در روش‌های عامل محور، مدل زبانی با مشاهده شواهد هر مرحله درباره ادامه پیمایش و کافی بودن اطلاعات تصمیم می‌گیرد. بنابراین، صرف استفاده از مدل زبانی در ساخت گراف یا پالایش نامزدها، یک روش را عامل محور نمی‌کند؛ برای نمونه، مرحله بازشناسی در HippoRAG 2 بخشی از فرایند بازیابی است، اما در ToG-2 تصمیم‌های مدل بر ادامه کاوش گراف و متن اثر می‌گذارند [۱۱، ۱۳].

از نظر پوشش شواهد، بازیابی محور بودن به معنای محدود شدن به روابط مستقیم نیست. انتشار امتیاز در گراف یا استخراج یک زیرگراف متصل می‌تواند اطلاعات چندگامی را نیز گردآوری کند. مزیت روش عامل محور، امکان هدایت مرحله بعد با توجه به یافته‌های مرحله قبل است؛ این ویژگی زمانی مفید است که مفهوم واسط از ابتدا آشکار نباشد. در مقابل، انتخاب نامناسب یک رابطه یا حذف زود هنگام یک موجودیت می‌تواند ادامه جست‌وجو را محدود کند. در هر دو خانواده، پوشش گراف و کیفیت شناسایی مفاهیم اولیه بر شواهد قابل دسترس اثر دارند.

در توضیح‌پذیری نیز باید میان «شواهد انتخاب‌شده»، «مسیر پیمایش» و «توضیح پاسخ» تمایز گذاشت. زیرگراف خروجی G-Retriever نشان می‌دهد چه اطلاعاتی در اختیار مدل بوده است و مسیرهای ToG ترتیب روابط دنبال‌شده را آشکار می‌کنند [۱۴، ۱۵]. این آثار ثبت‌شده بازبینی پاسخ را آسان‌تر می‌کنند، اما به‌تنهایی نشان نمی‌دهند که تمام ادعاهای توضیح از همان شواهد نتیجه شده‌اند. همچنین، وجود یک مسیر در گراف با مرتبط بودن آن به پرسش یکسان نیست. از این رو، ردیابی‌پذیری جست‌وجو و وفاداری توضیح باید جداگانه ارزیابی شوند.

هزینه اجرا نیز به پیاده‌سازی هر روش وابسته است. در روش‌های بازیابی‌محور، بخشی از هزینه به ساخت نمایه یا آموزش مؤلفه گراف اختصاص دارد؛ روش‌های عامل‌محور معمولاً با افزایش گام‌های کاوش، فراخوانی‌های بیشتری در زمان پاسخ‌گویی دارند. تعداد فراخوانی به‌تنهایی معیار کافی نیست و طول ورودی و خروجی، اندازه مدل و زمان پردازش گراف نیز باید ثبت شوند. در مقایسه این پژوهش، داده و منابع دانش مشترک خواهند بود و تفاوت‌های لازم در نمایش گراف، آموزش و بودجه جست‌وجو گزارش می‌شوند. نتیجه مورد انتظار، مشخص شدن تناسب هر روش با نوع وظیفه و منابع در دسترس است؛ رتبه‌بندی نهایی به نتایج آزمایش‌ها وابسته خواهد بود.

۸-۲ استدلال مقید به گراف: روش GCR

روش GCR قید ساختاری را در زمان تولید مسیر اعمال می‌کند: مدل فقط می‌تواند دنباله‌ای بسازد که با یکی از مسیرهای مجاز گراف سازگار باشد [۱۶]. این روش، الگویی مستقل برای استدلال روی گراف دانش است و نباید آن را نسخه بعدی ToG-2 تلقی کرد. ارتباط آن با بحث پیشین در این است که انتخاب مسیر و تولید نمایش زبانی آن را به یکدیگر پیوند می‌دهد. چارچوب اصلی سه مرحله دارد: ساخت نمایه مسیرها، تولید مقید مسیر و پاسخ‌های نامزد، و ترکیب آن‌ها برای رسیدن به پاسخ نهایی. در مرحله نخست، موجودیت‌های مطرح‌شده در پرسش به گراف پیوند داده می‌شوند و مسیرهای آغازشده از آن‌ها تا عمقی مشخص استخراج می‌گردند. مقاله برای این کار از جست‌وجوی سطح‌اول استفاده می‌کند. مسیرها پس از تبدیل به رشته‌های قالب‌بندی‌شده و نشانه‌های زبانی، در یک درخت پیشوندی^۵ با نام KG-Trie ذخیره می‌شوند. پیشوندهای مشترک تنها یک بار در این ساختار قرار می‌گیرند و برای هر دنباله ناقص، ادامه‌های مجاز قابل بازیابی‌اند. بنابراین، نمایه شامل مسیرهای انتخاب‌شده در محدوده جست‌وجو است و لازم نیست همه مسیرهای ممکن گراف را در بر گیرد.

در مرحله رمزگشایی مقید^۶، مدل زبانی احتمال نشانه بعدی را محاسبه می‌کند، اما تنها نشانه‌هایی امکان انتخاب دارند که ادامه‌ای معتبر در KG-Trie بسازند. این قید در طول تولید مسیر حفظ می‌شود تا رابطه یا موجودیتی خارج از مسیرهای نمایه‌شده وارد آن نشود. پس از پایان مسیر، رمزگشایی عادی برای تولید یک پاسخ نامزد از سر گرفته می‌شود. در نتیجه، دامنه قید ساختاری مشخص است: قید مستقیماً بر مسیر اعمال می‌شود و تمام متن پاسخ را در بر نمی‌گیرد.

^۵Trie

^۶Constrained Decoding

در طراحی مقاله، یک مدل زبانی سبک‌تر با نمونه‌های پرسش، مسیر و پاسخ برای این مرحله تنظیم می‌شود. سپس چند مسیر و پاسخ نامزد با جست‌وجوی پرتوی تولید و به یک مدل زبانی عمومی داده می‌شوند تا پاسخ نهایی را با استفاده از آن‌ها بسازد. مدل تخصصی، انتخاب مسیرهای مرتبط را می‌آموزد و مدل عمومی ترکیب شواهد را انجام می‌دهد. این تفکیک نیازمند دسترسی به فرایند رمزگشایی مدل نخست است؛ از این رو، امکانات اجرایی آن با روشی که صرفاً از طریق ارسال درخواست متنی به مدل کار می‌کند متفاوت است.

تعبیر «نبود توهم» در این مقاله به انطباق کامل مسیر تولیدشده با گراف اشاره دارد. این ویژگی برای کنترل روابط ساختگی مفید است، اما صحت خود گراف، ارتباط مسیر با پرسش یا درستی پاسخ نهایی را تضمین نمی‌کند. گراف ناقص، پیوندهای نادرست موجودیت‌ها و محدودیت عمق جست‌وجو همچنان می‌توانند شواهد لازم را از دسترس خارج کنند. افزون بر این، توضیح نهایی ممکن است برداشتی فراتر از مسیرها داشته باشد. بنابراین، در انطباق با سلامت روان، اعتبار ساختاری مسیر و پشتیبانی ادعاهای توضیح از متن ورودی دو موضوع مجزا خواهند بود.

آزمایش‌های مقاله عمدتاً بر پرسش و پاسخ گراف دانش انجام شده‌اند و قابلیت انتقال به گراف‌های دیگر نیز بررسی شده است. این نتایج مبنایی برای انتخاب GCR در مقایسه حاضر فراهم می‌کنند، اما عملکرد آن روی وظایف IMHI باید مستقلاً سنجیده شود. هزینه ساخت KG-Trie، تنظیم مدل تخصصی و اجرای دو مدل نیز در تحلیل کارایی منظور خواهد شد تا کاهش احتمالی رفت‌وبرگشت‌های جست‌وجو در کنار هزینه آماده‌سازی و تولید پاسخ بررسی شود.

۹-۲ کاربرد در سلامت روان و مبنای ارزیابی

کاربرد روش‌های مرور شده در این پژوهش، تولید برچسب و توضیح برای متن‌های سلامت روان است. در این وظیفه، پاسخ معمولاً یک موجودیت انتهایی در گراف نیست و باید با مجموعه برچسب‌های هر داده هماهنگ شود. مجموعه IMHI چنین مسئله‌ای را در قالب دستور و پاسخ سازمان‌دهی می‌کند و مبنای آموزش و ارزیابی مدل‌های MentalLLaMA بوده است [۱۰]. وظایف منتخب شامل تشخیص استرس در Dreddit، طبقه‌بندی وضعیت در T-SID، شناسایی عامل استرس در SAD و بررسی ابعاد بهزیستی در MultiWD هستند. این تنوع، امکان مقایسه روش‌ها در طبقه‌بندی دودویی و چندکلاسه، شناسایی عامل و تشخیص ابعاد بهزیستی را فراهم می‌کند.

در انتقال روش‌ها به این وظایف، متن فرد و دانش دامنه‌ای نقش‌های متفاوتی دارند. متن مشخص می‌کند چه تجربه یا نشانه‌ای گزارش شده است و گراف، روابط دانشی مربوط به مفاهیم آن را فراهم می‌کند. یک رابطه عمومی در گراف نمی‌تواند به‌تنهایی شهادی بر وجود همان وضعیت در فرد باشد. برای مثال، اگر متن فقط به دشواری خواب اشاره کند، وجود روابط مربوط به خستگی در گراف مجوز نسبت دادن خستگی گزارش‌نشده به نویسنده نیست. بنابراین، حفظ بافت، نفی و میزان قطعیت عبارت‌ها در استخراج مفاهیم و تولید توضیح اهمیت دارد.

ارزیابی برچسب‌ها با امتیاز F1 وزن‌دار و بازخوانی^۷ انجام خواهد شد. امتیاز وزن‌دار، سهم هر کلاس را متناسب با فراوانی آن محاسبه می‌کند؛ از این رو، بررسی نتایج هر کلاس نیز لازم است تا ضعف عملکرد روی کلاس‌های کم‌نمونه پنهان نماند. در وظایف دودویی، بازخوانی کلاس هدف میزان شناسایی نمونه‌های مثبت را نشان می‌دهد. این معیارها توافق خروجی با برچسب‌های مجموعه داده را می‌سنجند و نباید معادل اعتبار تشخیص بالینی تفسیر شوند.

برای توضیح‌ها، کیفیت کلی متن و پشتیبانی ادعاها جداگانه بررسی می‌شوند. در امتداد طرح پروپوزال، BARTScore برای سنجش توضیح تولیدشده نسبت به توضیح مرجع در نظر گرفته می‌شود؛ این معیار از احتمال تولید متن شرطی بر متن دیگر استفاده می‌کند [۲۲]. توضیح‌های مرجع IMHI با کمک مدل زبانی تولید و ارزیابی شده‌اند، بنابراین شباهت به آن‌ها به‌تنهایی شاهد صحت همه ادعاها نیست. تطابق با متن فرد و دانش پشتیبان باید مستقل از این امتیاز سنجیده شود.

چارچوب GraphEval برای این بررسی، خروجی مدل را به سه‌تایی‌های ادعایی تبدیل می‌کند و سازگاری هر سه‌تایی را با متن پشتیبان، با استفاده از مدل استنتاج زبان طبیعی، می‌سنجد [۲۳]. سه‌تایی‌های ناسازگار نیز مشخص می‌شوند تا محل خطا قابل بازبینی باشد. در کاربرد حاضر، ادعاهای مربوط به فرد باید با متن ورودی و ادعاهای دانشی با منابع دامنه‌ای مربوط بررسی شوند. این سازوکار با کنترل وجود یال‌های مسیر در گراف تفاوت دارد و نتیجه آن به دقت استخراج ادعا و ارزیاب وابسته است. نمونه‌هایی از خطاها نیز برای بررسی نفی، ابهام و تعمیم فراتر از شواهد به صورت کیفی تحلیل خواهند شد.

محور سوم، زمان پاسخ از دریافت ورودی تا تولید برچسب و توضیح، و مجموع نشانه‌های ورودی و خروجی در تمام فراخوانی‌هاست. هزینه ساخت گراف، نمایه‌سازی و آموزش از هزینه هر نمونه جدا گزارش می‌شود. استفاده از تقسیم‌های داده یکسان، حفظ مرز آموزش و آزمون و مشخص کردن بودجه

Recall^۷

منابع هر روش، مبنای مقایسه خواهد بود. این چارچوب نشان می‌دهد هر روش با چه هزینه‌ای به چه کیفیتی در برچسب و توضیح می‌رسد.

مرور این فصل نشان داد که روش‌های منتخب، نقش‌های متفاوتی به گراف می‌دهند: انتخاب شواهد در روش‌های بازیابی‌محور، هدایت جست‌وجوی مرحله‌ای در روش‌های عامل‌محور و محدود کردن تولید مسیر در GCR. این تفاوت‌ها مبنای بازپیاده‌سازی و ارزیابی مشترک در سلامت روان خواهند بود. هدف آزمایش‌ها، سنجش اثر هر سازوکار بر درستی برچسب، پشتیبانی توضیح و هزینه اجراست. فصل بعد، جزئیات داده‌ها، آماده‌سازی گراف و پروتکل اجرای این مقایسه را مشخص می‌کند.

فصل ۳

روش تحقیق و طراحی چارچوب آزمایش

۱-۳ طرح کلی پژوهش

این پژوهش یک مطالعه تجربی و مقایسه‌ای برای بررسی روش‌های گراف‌محور در تشخیص توضیح‌پذیر سلامت روان است. هدف، مقایسه روش‌ها در یک وظیفه و با منابع داده و دانش مشترک است تا تفاوت مشاهده‌شده تا حد امکان ناشی از سازوکار بازیابی و استدلال هر روش باشد، نه تفاوت در داده یا معیار ارزیابی. چارچوب آزمایش برای دو مجموعه داده DR و SWMH اجرا می‌شود و روش‌های ToG-1، ToG-2، HippoRAG 2، بازیابی افزوده متعارف (Vanilla RAG) و استدلال زنجیره‌ای (CoT) را در بر می‌گیرد. ورودی هر آزمایش یک متن از مجموعه داده به همراه مجموعه کامل برچسب‌های ممکن آن وظیفه است. متن در صورت نیاز به موجودیت‌ها و مفاهیم مرتبط پیوند داده می‌شود و شواهد دانشی و متنی از گراف دانش و مخزن قطعه‌ها بازیابی می‌گردند. گراف دانش دامنه‌ای از داده‌های مورد استفاده در این پژوهش ساخته شده و سه‌تایی‌ها، موجودیت‌ها و روابط آن در پایگاه داده PostgreSQL نگهداری می‌شوند؛ نمایش‌های برداری موجودیت‌ها و قطعه‌های متنی نیز در Milvus در دسترس روش‌های بازیابی قرار دارند.

هر روش پس از دریافت ورودی، خروجی خود را در قالب یک پیش‌بینی از میان برچسب‌های مجاز تولید می‌کند. افزون بر برچسب، توضیح متنی دلیل تصمیم و شواهد مورد استفاده نیز ثبت می‌شود. در روش‌های گراف‌محور، مسیر یا زیرساختارهای گرافی، موجودیت‌ها، روابط و قطعه‌های انتخاب‌شده ثبت می‌شوند؛ در روش‌های بازیابی‌محور، قطعه‌ها و شواهد بازیابی‌شده؛ و در روش CoT، متن استدلال و پاسخ

نهایی ذخیره می‌گردد. بنابراین، خروجی آزمایش فقط یک برچسب نیست، بلکه شامل پاسخ قابل ارزیابی و ردپای شواهدی است که به تولید آن پاسخ منجر شده‌اند.

برای هر اجرا، پیش‌بینی با برچسب واقعی مقایسه می‌شود و مراحل داخلی، تصمیم‌های انتخاب و حذف نامزدها، تعداد فراخوانی‌های مدل زبانی، توکن‌های مصرف‌شده و زمان اجرا ثبت می‌گردند. این ثبت مشترک امکان ارزیابی سه جنبه را فراهم می‌کند: درستی پیش‌بینی، قابلیت بازبینی و پشتیبانی توضیح با شواهد، و هزینه محاسباتی و متنی روش. جزئیات آماده‌سازی داده و گراف، تنظیمات هر روش، پروتکل اجرای آزمایش و معیارهای عددی در بخش‌های بعدی این فصل ارائه می‌شوند.

۲-۳ تعریف وظیفه و خروجی‌های مورد انتظار

وظیفه اصلی پژوهش، نگاشت یک متن مرتبط با سلامت روان به یکی از برچسب‌های از پیش تعیین‌شده و ارائه توضیحی برای این تصمیم است. هر نمونه شامل یک متن یا پست، شناسه نمونه و برچسب واقعی است. متن خام، همراه با دستور مسئله و فهرست کامل کلاس‌های مجاز، به هر روش داده می‌شود تا مدل فقط یکی از برچسب‌های تعریف‌شده برای همان مجموعه‌داده را انتخاب کند. این محدودیت برای جلوگیری از تولید نام کلاس‌های جدید و قابل مقایسه بودن خروجی روش‌ها اعمال می‌شود.

دو مجموعه‌داده از نظر صورت‌بندی مسئله متفاوت‌اند. در مجموعه‌داده DR، مسئله دودویی است و خروجی باید دقیقاً یکی از دو کلاس yes یا no باشد؛ این دو کلاس به ترتیب وجود یا نبود وضعیت هدف در نمونه را نشان می‌دهند. در مجموعه‌داده SWMH، مسئله چندکلاسه است و مدل باید یکی از پنج کلاس anxiety، bipolar disorder، depression، no mental disorders یا suicide را انتخاب کند. برچسب واقعی هر نمونه از فایل داده خوانده و پس از اجرای روش با برچسب پیش‌بینی‌شده مقایسه می‌شود.

خروجی هر اجرا فقط به یک برچسب محدود نیست. بخش نخست خروجی، پاسخ نهایی شامل برچسب پیش‌بینی‌شده و توضیح متنی دلیل انتخاب آن است. بخش دوم، شواهدی است که روش برای رسیدن به پاسخ استفاده کرده است. در روش‌های گراف‌محور، این شواهد شامل موجودیت‌های آغازین، روابط و مسیرهای انتخاب‌شده و قطعه‌های متنی متصل به آن‌هاست. در روش‌های بازبازی‌محور، قطعه‌های متنی بازبازی‌شده و در روش CoT، متن استدلال و پاسخ تولیدشده ثبت می‌شود. این اطلاعات امکان بررسی این موضوع را فراهم می‌کند که پاسخ بر چه شواهدی تکیه داشته است.

برای هر نمونه، علاوه بر خروجی محتوایی، برچسب واقعی، وضعیت درستی پیش‌بینی و اطلاعات اجرای روش نیز ذخیره می‌شود. اطلاعات اجرایی شامل فراخوانی‌های مدل زبانی، مسیر مراحل بازیابی یا پیمایش، توکن‌های ورودی و خروجی، زمان هر فراخوانی و زمان کل اجراست. در صورتی که مدل پاسخی خارج از قالب مورد انتظار تولید کند یا اجرای روش با خطای زیرساختی متوقف شود، این وضعیت جداگانه ثبت می‌شود تا با یک پیش‌بینی عادی اشتباه نشود.

لازم است تأکید شود که برچسب تولیدشده در این پژوهش معادل تشخیص قطعی بالینی نیست. خروجی، پیش‌بینی محاسباتی مدل بر اساس متن نمونه و شواهد در دسترس است و توضیح تولیدشده نیز باید به عنوان توضیح قابل بازبینی تصمیم مدل تفسیر شود، نه جایگزین ارزیابی متخصص. معیار مقایسه در این پژوهش، توافق برچسب با داده مرجع، پشتیبانی توضیح از شواهد و هزینه تولید پاسخ است.

۳-۳ منابع داده و گراف دانش دامنه‌ای

منبع دانش دامنه‌ای پژوهش از دو مرجع تخصصی حوزه اختلال‌های روانی تهیه شده است: Diag-nostic and Statistical Manual of Mental Disorders, Fifth Edition, Text Revision (DSM-5-TR) منتشرشده توسط انجمن روان‌پزشکی آمریکا و کتاب DSM-5-TR Made Easy: The Clinician's Guide to Diagnosis نوشته جیمز موريسون [۲۴، ۲۵]. مرجع نخست چارچوب رسمی طبقه‌بندی و معیارهای تشخیصی را فراهم می‌کند و مرجع دوم همان مفاهیم و معیارها را با بیان آموزشی و ساختار مناسب‌تر برای استخراج روابط توضیح می‌دهد. محتوای این دو منبع پس از استخراج مفاهیم و روابط، در گراف دانش دامنه‌ای یکپارچه شده است.

گراف حاصل، مفاهیمی مانند اختلال‌ها، نشانه‌ها، رفتارها، معیارها و مشخصه‌های مرتبط و روابط میان آن‌ها را نگهداری می‌کند. نمایش اصلی گراف به صورت سه‌تایی‌های (subject, predicate, object) است. موجودیت‌ها و نوع آن‌ها، سه‌تایی‌ها و رابطه‌ها، و پیوند میان سه‌تایی‌ها و قطعه‌های منبع در پایگاه داده رابطه‌ای PostgreSQL ذخیره شده‌اند. شناسه‌های موجودیت و قطعه در لایه‌های مختلف حفظ می‌شوند تا هر شاهد بازیابی‌شده به رکورد گراف و متن منبع آن قابل ردیابی باشد.

متن‌های منبع به قطعه‌های مستقل تقسیم شده‌اند و برای هر قطعه شناسه و محتوای متنی ثبت شده است. جدول پیوندِ ذکرها مشخص می‌کند هر قطعه از کدام سه‌تایی‌ها پشتیبانی می‌کند. در نتیجه،

بازیابی یک موجودیت یا یک مسیر گرافی می‌تواند به قطعه‌های متنی مرتبط برسد و روش‌های ToG-1 و ToG-2 قادرند هم ساختار رابطه‌ای و هم زمینه متنی را در اختیار مدل قرار دهند. هنگام حذف نامزدهای تکراری، شناسه قطعه و شناسه سه‌تایی به عنوان شناسه‌های مستقل حفظ می‌شوند؛ بنابراین، یک قطعه مشترک می‌تواند به چند موجودیت یا چند رابطه متصل باشد، بدون آن که به اشتباه چند قطعه متفاوت تلقی شود.

برای پیوند موجودیت‌های استخراج‌شده از پرسش، از نمایش‌های برداری ذخیره‌شده در Milvus استفاده می‌شود. متن موجودیت یا عبارت استخراج‌شده با مدل embedding سرویس Jina به بردار تبدیل و با جست‌وجوی شباهت کسینوسی با موجودیت‌های نمایه‌شده مقایسه می‌شود. شناسه‌های موجود در مجموعه‌های Milvus با شناسه‌های موجودیت در PostgreSQL یکسان نگه داشته شده‌اند تا نتیجه جست‌وجوی برداری مستقیماً به گره گراف قابل اتصال باشد. بردارهای قطعه‌های متنی نیز در مجموعه جداگانه‌ای ذخیره شده‌اند و برای رتبه‌بندی شواهد با بردار پرسش به کار می‌روند. این جداسازی سه لایه دارد: PostgreSQL منبع ساختاری گراف و رابطه‌های اتصال‌دهنده است؛ Milvus نمایه جست‌وجوی برداری موجودیت‌ها و قطعه‌هاست؛ و سرویس embedding تبدیل متن به بردار را انجام می‌دهد. مدل زبانی از طریق OpenRouter فقط در مراحل استخراج موجودیت، انتخاب یا ارزیابی نامزدها و تولید پاسخ به کار می‌رود. جزئیات نحوه استفاده هر روش از این منابع در بخش روش‌های مورد مقایسه و پروتکل اجرای آزمایش شرح داده می‌شود.

۴-۳ روش‌های مورد مقایسه

در این پژوهش پنج روش برای تولید پیش‌بینی و توضیح روی دو مجموعه داده با یکدیگر مقایسه می‌شوند. روش‌ها از نظر میزان استفاده از گراف دانش، نحوه بازیابی شواهد و میزان دخالت مدل زبانی در فرایند استدلال متفاوت‌اند، اما همگی در نهایت باید یک کلاس مجاز و توضیح مرتبط با همان نمونه تولید کنند. اجرای روش‌ها با منابع داده و گراف دامنه‌ای یکسان انجام می‌شود تا مقایسه بر تفاوت سازوکار روش‌ها متمرکز باشد.

۳-۴-۱ استدلال زنجیره‌ای و بازیابی افزوده متعارف

روش CoT به عنوان خط پایه‌ی زبانی، متن نمونه و دستور طبقه‌بندی را در اختیار مدل قرار می‌دهد و از مدل می‌خواهد ابتدا درباره‌ی شواهد موجود استدلال و سپس یک کلاس نهایی انتخاب کند. در این روش، پیمایش صریح گراف وجود ندارد و شواهد اصلی از متن ورودی و دانش درونی مدل به دست می‌آیند. خروجی شامل متن استدلال، پاسخ نهایی و اطلاعات اجرای فراخوانی مدل است.

در روش Vanilla RAG، پیش از تولید پاسخ، قطعه‌های متنی مرتبط با پرسش از نمایه برداری بازیابی می‌شوند. قطعه‌های منتخب همراه با پرسش به مدل داده می‌شوند و مدل با اتکا به این بافت، لیبل و توضیح را تولید می‌کند. این روش نقش گراف را در هدایت چندمرحله‌ای جست‌وجو وارد نمی‌کند و مبنایی برای سنجش اثر افزودن ساختار گرافی به بازیابی فراهم می‌آورد.

۳-۴-۲ روش‌های گراف‌محور

ToG-1 روش عامل‌محوری است که جست‌وجو را از موجودیت‌های مرتبط با پرسش آغاز می‌کند و در هر مرحله، روابط و موجودیت‌های نامزد را با کمک مدل زبانی پالایش می‌کند. مسیرهای برتر برای گسترش مرحله بعد حفظ می‌شوند و در صورت کافی بودن شواهد، مدل پاسخ نهایی و توضیح آن را تولید می‌کند. در این روش، مسیرهای گرافی نقش اصلی را در سازمان‌دهی شواهد دارند.

ToG-2 نسخه‌ای توسعه‌یافته از این الگوست که بازیابی گراف و بازیابی متن را در یک چرخه‌ی مشترک قرار می‌دهد. ابتدا موجودیت‌های آغازین از متن استخراج و به گره‌های گراف پیوند داده می‌شوند. سپس قطعه‌های متنی مرتبط با seedها و نامزدهای گراف بر اساس شباهت با پرسش رتبه‌بندی می‌شوند. مدل در هر دور درباره‌ی کافی بودن شواهد تصمیم می‌گیرد؛ در صورت ناکافی بودن، روابط، موجودیت‌ها و chunkهای دور بعد انتخاب می‌شوند و این فرایند تا رسیدن به پاسخ یا حد عمق ادامه می‌یابد.

HippoRAG 2 به عنوان روش بازیابی‌محور گرافی، از ساختار گراف و ارتباط میان مفاهیم برای انتشار یا تجمیع شواهد مرتبط استفاده می‌کند. در این روش، گراف نقش حافظه‌ی غیرپارامتری را دارد و بازیابی صرفاً بر شباهت مستقل پرسش با یک قطعه متکی نیست. خروجی بازیابی‌شده به مدل داده می‌شود تا برچسب و توضیح نهایی را تولید کند. بنابراین، این روش در مقایسه با Vanilla RAG اثر استفاده از پیوندهای گرافی را نشان می‌دهد، اما مانند ToG-2 چرخه‌ی تصمیم‌گیری عامل‌محور برای ادامه پیمایش ندارد.

این پنج روش یک طیف از استدلال صرفاً زبانی تا بازیابی متنی، بازیابی گرافی و پیمایش عامل محور گراف را پوشش می‌دهند. در تمام روش‌ها، متن پرسش، مجموعه برچسب‌های مجاز و تعریف خروجی یکسان نگه داشته می‌شود؛ تفاوت اصلی در منبع شواهد و نحوه انتخاب و سازمان‌دهی آن‌هاست. جزئیات تنظیمات مدل، پارامترهای بازیابی، بودجه جست‌وجو و ترتیب اجرای هر روش در بخش پروتکل آزمایش ارائه خواهد شد.

۳-۵ چارچوب اجرای آزمایش‌ها

آزمایش‌ها بر روی نسخه‌ی ثابت مجموعه داده‌ی مورد استفاده انجام شدند. مجموعه‌ی آزمون شامل دو وظیفه‌ی DR و SWMH است و در اجرای مقایسه‌ای، به ترتیب ۷۰ و ۶۵ نمونه از آن‌ها بررسی شد. برای همه‌ی روش‌ها متن ورودی، برچسب واقعی و مجموعه‌ی کامل برچسب‌های مجاز یکسان بود. مقایسه میان پنج روش CoT، Vanilla RAG، HippoRAG 2، ToG-1 و ToG-2 انجام شد. مدل زبانی مشترک، Gemma 4 31B [۲۶] و مدل تولیدکننده‌ی نمایش برداری، jina-embeddings-v4 [۲۷] بود. گراف دانش از طریق PostgreSQL و نمایه‌ی برداری از طریق Milvus در اختیار روش‌های مربوط قرار گرفتند.

در CoT، پاسخ مستقیماً بر اساس متن ورودی تولید شد. در Vanilla RAG، ابتدا ۵۰ قطعه‌ی متنی بازیابی و پس از رتبه‌بندی، حداکثر ۸ قطعه به مدل داده شد. در HippoRAG 2، سه تایی‌های حقیقت از گراف بازیابی و امتیاز آن‌ها با استفاده از رتبه‌بندی صفحه‌ی شخصی‌سازی شده^۱ به قطعه‌های متنی منتقل شد. در ToG-1، عرض جست‌وجو ۵ و عمق آن ۵ و در ToG-2، عرض جست‌وجو ۵ و عمق آن ۵ در نظر گرفته شد.

برای هر نمونه، علاوه بر برچسب و توضیح، شواهد بازیابی شده، مسیرهای گرافی، زمان اجرا، تعداد فراخوانی‌های مدل و تعداد توکن‌های ورودی و خروجی ثبت شد. پاسخ خارج از مجموعه‌ی برچسب‌های مجاز یا پاسخ غیرقابل تجزیه، معتبر در نظر گرفته نشد. سپس عملکرد روش‌ها با استفاده از معیارهای درستی پیش‌بینی، کیفیت توضیح و هزینه‌ی اجرا مقایسه شد. در اجرای ToG-2، دو نمونه خروجی کامل نداشتند؛ بنابراین نتایج این روش بر اساس ۱۳۳ نمونه‌ی معتبر گزارش شد.

^۱ Personalized PageRank (PPR)

۳-۶ معیارهای ارزیابی

۳-۷ مقایسه منصفانه، بازتولیدپذیری و جمع‌بندی

فصل ۴

بازپیاذهسازی و انطباق روش‌های منتخب

۱-۴ معماری چارچوب اجرایی و آماده‌سازی داده‌ها

۲-۴ آماده‌سازی گراف دانش دامنه‌ای

۳-۴ بازپیاذهسازی خطوط پایه و روش بازیابی محور

۴-۴ بازپیاذهسازی روش‌های عامل محور و قیدگذارانه

۵-۴ پیاذهسازی ارزیابی GraphEval

۴-۶ انطباق روش‌ها با وظیفه سلامت روان

۴-۷ تنظیمات فنی، چالش‌ها و جمع‌بندی

فصل ۵

نتایج و تحلیل مقایسه‌ای

۱-۵ تنظیمات نهایی آزمایش‌ها

۲-۵ نتایج پیش‌بینی‌های تشخیصی

۳-۵ کیفیت توضیحات و تحلیل توهم

۴-۵ کارایی محاسباتی و هزینه متنی

۵-۵ مطالعات حذف مؤلفه و تحلیل حساسیت

۵-۶ تحلیل خطا و بحث نهایی

۵-۷ تهدیدهای اعتبار و جمع‌بندی

فصل ۶

جمع‌بندی، محدودیت‌ها و مسیرهای آینده

۱-۶ مرور پژوهش انجام‌شده

۲-۶ پاسخ به پرسش‌های پژوهش

۳-۶ جمع‌بندی یافته‌های اصلی

۴-۶ محدودیت‌های پژوهش

۵-۶ پیشنهادهایی برای پژوهش‌های آینده

۶-۶ سخن پایانی

منابع و مراجع

- [1] World Health Organization. World Mental Health Report: Transforming Mental Health for All. World Health Organization, Geneva, 2022.
- [2] Kupfer, David J., Kuhl, Emily A., and Regier, Darrel A. Dsm-5: Classification and criteria changes. World Psychiatry, 12(2):92–98, 2013.
- [3] Shen, Guangyao, Jia, Jia, Nie, Liqiang, Feng, Fuli, Zhang, Cunjun, Hu, Tianrui, Chua, Tat-Seng, and Zhu, Wenwu. Depression detection via harvesting social media: A multimodal dictionary learning solution. in Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, pp. 3838–3844, 2017.
- [4] Sarkar, Somayeh, Alhamadani, Ali, Alkulaib, Lulwa, and Lu, Cheng-Te. Predicting depression and anxiety on reddit: A multi-task learning approach. in Proceedings of the 2022 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining, pp. 427–435, 2023.
- [5] Joyce, Daniel W., Kormilitzin, Andrey, Smith, Katherine A., and Cipriani, Andrea. Explainable artificial intelligence for mental health through transparency and interpretability for understandability. npj Digital Medicine, 6(1):6, 2023.
- [6] World Health Organization. Ethics and Governance of Artificial Intelligence for Health. World Health Organization, Geneva, 2021.

- [7] World Health Organization. Who calls for safe and ethical ai for health. WHO News Release, 2023.
- [8] Lewis, Patrick, Perez, Ethan, Piktus, Aleksandra, Petroni, Fabio, Karpukhin, Vladimir, Goyal, Naman, Kuttler, Heinrich, Lewis, Mike, Yih, Wen-tau, Rocktaschel, Tim, Riedel, Sebastian, and Kiela, Douwe. Retrieval-augmented generation for knowledge-intensive nlp tasks. in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [9] Yang, Kailai, Ji, Shaoxiong, Zhang, Tianlin, Xie, Qianqian, Kuang, Ziyang, and Ananiadou, Sophia. Towards interpretable mental health analysis with large language models. in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 6056–6077, 2023.
- [10] Yang, Kailai, Zhang, Tianlin, Kuang, Ziyang, Xie, Qianqian, Huang, Jimin, and Ananiadou, Sophia. Mentalllama: Interpretable mental health analysis on social media with large language models. in *Proceedings of the ACM Web Conference 2024*, pp. 4489–4500, 2024.
- [11] Ma, Shengjie, Xu, Chengjin, Jiang, Xuhui, Li, Muzhi, Qu, Huaren, Yang, Cehao, Mao, Jiaxin, and Guo, Jian. Think-on-graph 2.0: Deep and faithful large language model reasoning with knowledge-guided retrieval augmented generation. in *International Conference on Learning Representations*, 2025.
- [12] Zhuang, Luyao, Chen, Shengyuan, Xiao, Yilin, Zhou, Huachi, Zhang, Yujing, Chen, Hao, Zhang, Qinggang, and Huang, Xiao. Linearrag: Linear graph retrieval augmented generation on large-scale corpora. in *International Conference on Learning Representations*, 2026.
- [13] Gutiérrez, Bernal Jiménez, Shu, Yiheng, Qi, Weijian, Zhou, Sizhe, and Su, Yu. From rag to memory: Non-parametric continual learning for large language models. in *Pro-*

- ceedings of the 42nd International Conference on Machine Learning, vol. 267 of Proceedings of Machine Learning Research, 2025.
- [14] He, Xiaoxin, Tian, Yijun, Sun, Yifei, Chawla, Nitesh V., Laurent, Thomas, LeCun, Yann, Bresson, Xavier, and Hooi, Bryan. G-retriever: Retrieval-augmented generation for textual graph understanding and question answering. in Advances in Neural Information Processing Systems, vol. 37, pp. 132876–132907, 2024.
- [15] Sun, Jiashuo, Xu, Chengjin, Tang, Luming, Wang, Saizhuo, Lin, Chen, Gong, Yao, Ni, Lionel M., Shum, Heung-Yeung, and Guo, Jian. Think-on-graph: Deep and responsible reasoning of large language model on knowledge graph. in International Conference on Learning Representations, 2024.
- [16] Luo, Linhao, Zhao, Zicheng, Haffari, Gholamreza, Li, Yuan-Fang, Gong, Chen, and Pan, Shirui. Graph-constrained reasoning: Faithful reasoning on knowledge graphs with large language models. in Proceedings of the 42nd International Conference on Machine Learning, vol. 267 of Proceedings of Machine Learning Research, 2025.
- [17] Orabi, Ahmed Hussein, Buddhitha, Prasadith, Orabi, Mahmoud Hussein, and Inkpen, Diana. Deep learning for depression detection of twitter users. in Proceedings of the Fifth Workshop on Computational Linguistics and Clinical Psychology, pp. 88–97, 2018.
- [18] Lin, Chenhao, Hu, Pengwei, Su, Hui, Li, Shaochun, Mei, Jing, Zhou, Jie, and Leung, Henry. SenseMood: Depression detection on social media. in Proceedings of the 2020 International Conference on Multimedia Retrieval, pp. 407–411, 2020.
- [19] Lan, Xiaochong, Han, Zhiguang, Cheng, Yiming, Sheng, Li, Feng, Jie, Gao, Chen, and Li, Yong. Depression detection on social media with large language models. in Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: Industry Track, pp. 2155–2171, 2025.

- [20] Gao, Shan, Yu, Kaixian, Yang, Yue, Yu, Sheng, Shi, Chenglong, Wang, Xueqin, Tang, Niansheng, and Zhu, Hongtu. Large language model powered knowledge graph construction for mental health exploration. *Nature Communications*, 16:7526, 2025.
- [21] Mo, Belinda, Yu, Kyssen, Kazdan, Joshua, Cabezas, Joan, Mpala, Proud, Yu, Lisa, Cundy, Chris, Kanatsoulis, Charilaos, and Koyejo, Sanmi. KGGen: Extracting knowledge graphs from plain text with language models. *arXiv preprint arXiv:2502.09956*, version 2, 2025.
- [22] Yuan, Weizhe, Neubig, Graham, and Liu, Pengfei. BARTScore: Evaluating generated text as text generation. in *Advances in Neural Information Processing Systems*, vol. 34, pp. 27263–27277, 2021.
- [23] Sansford, Hannah, Richardson, Nicholas, Petric Maretic, Hermina, and Nait Saada, Juba. GraphEval: A knowledge-graph based LLM hallucination evaluation framework. *arXiv preprint arXiv:2407.10793*, 2024.
- [24] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders: DSM-5-TR*. American Psychiatric Association Publishing, 5th, text revision ed., 2022.
- [25] Morrison, James. *DSM-5-TR Made Easy: The Clinician’s Guide to Diagnosis*. The Guilford Press, 2022.
- [26] Gemma Team. *Gemma 4 technical report*, 2026.
- [27] Günther, Michael, Sturua, Saba, Akram, Mohammad Kalim, Mohr, Isabelle, Ungureanu, Andrei, Eslami, Sedigheh, Martens, Scott, Wang, Bo, Wang, Nan, and Xiao, Han. *jina-embeddings-v4: Universal embeddings for multimodal multilingual retrieval*, 2025.

Abstract

The increasing prevalence of mental disorders highlights the need for accurate, reliable, and explainable tools that support the detection process. Large language models can generate diagnostic labels together with textual explanations; however, factual hallucinations and the lack of explicit knowledge grounding limit their use in this sensitive domain. This study reproduces, adapts, and compares graph-based methods for explainable mental health detection. The selected methods represent retrieval-based, agent-based, and constrained reasoning paradigms, allowing the role of domain knowledge graphs in supporting reasoning and reducing unsupported claims to be examined. Experiments will be conducted on selected tasks from the IMHI dataset. The methods will be compared in terms of prediction accuracy, explanation quality and faithfulness, response time, and token cost. The generated explanations will also be analyzed at the claim and structural-relation levels using the GraphEval framework.

Keywords:

Mental Health, Explainable Detection, Large Language Models, Knowledge Graphs, Graph-based Evaluation



**Amirkabir University of Technology
(Tehran Polytechnic)**

Department of Computer Engineering

Bachelor Thesis

Explainable Mental Health Detection via Large Language Models and Domain Knowledge Graphs

By

Alireza Hooshyari

Supervisor

Dr. Mohammad Rahmati

September 2026