



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی
مهندسی کامپیوتر

تشخیص توضیح پذیر سلامت روان با بهره گیری از
مدل های زبانی بزرگ و گراف های دانش دامنه ای

نگارش

علیرضا هوشیاری

استاد راهنما

دکتر محمد رحمتی

شهریور ۱۴۰۵

به نام خدا

تاریخ: شهریور ۱۴۰۵

تعهدنامه اصالت اثر



اینجانب **علیرضا هوشیاری** متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است. در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

علیرضا هوشیاری

سپاسگزاری

با تشکر فراوان از جناب آقای دکتر محمد رحمتی، استاد راهنمای محترم این پایان نامه، که با راهنمایی‌ها و نظرات ارزشمند خود نقشی اساسی در شکل‌گیری و پیشبرد این پژوهش داشته‌اند.

علیرضا هوشیاری
شهریور ۱۴۰۵

چکیده

افزایش شیوع اختلالات روانی، ضرورت توسعه ابزارهای دقیق، قابل اعتماد و توضیح‌پذیر برای پشتیبانی از فرایند تشخیص را برجسته ساخته است. مدل‌های زبانی بزرگ می‌توانند هم‌زمان برچسب تشخیصی و توضیح متنی تولید کنند؛ با این حال، توهم اطلاعاتی و فقدان پشتوانه دانشی صریح، استفاده از آن‌ها را در حوزه حساس سلامت روان با چالش مواجه می‌کند. هدف این پژوهش، بازپیاده‌سازی، انطباق و مقایسه روش‌های گراف‌محور برای تشخیص توضیح‌پذیر سلامت روان است. روش‌های منتخب از سه الگوی بازیابی‌محور، عامل‌محور و قیدگذارانه استفاده می‌کنند و نقش گراف دانش دامنه‌ای در پشتیبانی از استدلال و کاهش ادعاهای بدون پشتوانه در آن‌ها بررسی می‌شود. آزمایش‌ها بر روی وظایف منتخب مجموعه داده IMHI انجام خواهند شد و روش‌ها از نظر درستی پیش‌بینی، کیفیت و اتکاپذیری توضیح، زمان پاسخ و هزینه متنی مقایسه می‌شوند. همچنین، توضیحات تولیدشده با استفاده از چارچوب GraphEval در سطح ادعا و روابط ساختاری تحلیل خواهند شد.

واژه‌های کلیدی:

سلامت روان، تشخیص توضیح‌پذیر، مدل‌های زبانی بزرگ، گراف دانش، ارزیابی گراف‌محور

فهرست مطالب

عنوان

صفحه

۱	کلیات و مبانی تشخیص توضیح‌پذیر سلامت روان	۱
۱-۱	مقدمه و بیان مسئله	۲
۲-۱	تشخیص توضیح‌پذیر سلامت روان از داده‌های متنی	۳
۳-۱	مدل‌های زبانی بزرگ، توضیح‌پذیری و توهم اطلاعاتی	۴
۴-۱	بازیابی افزوده: تعریف، سازوکار و مزایا	۵
۵-۱	محدودیت‌های بازیابی متنی و ضرورت ساختار گرافی	۶
۶-۱	گراف دانش، الگوهای ادغام و جهت‌گیری پژوهش	۷
۷-۱	جمع‌بندی	۹
۲	پژوهش‌های مرتبط و روش‌های مبنا	۱۰
۱-۲	مقدمه و چارچوب طبقه‌بندی	۱۱
۲-۲	پژوهش‌های تشخیص توضیح‌پذیر سلامت روان	۱۲
۱-۲-۲	از روش‌های پیش‌بینی تا مدل‌های زبانی بزرگ	۱۲
۲-۲-۲	تنظیم دامنه‌ای و استفاده از دانش برای تولید توضیح	۱۳
۳-۲	از بازیابی افزوده متنی تا بازیابی افزوده گراف‌محور	۱۴
۴-۲	ساخت گراف دانش از متن: روش KGGen	۱۵
۵-۲	روش‌های گرافی بازیابی‌محور: سازوکار و ویژگی‌ها	۱۶
۶-۲	روش‌های گرافی عامل‌محور: سازوکار و ویژگی‌ها	۱۸
۷-۲	مقایسه روش‌های بازیابی‌محور و عامل‌محور	۲۰
۸-۲	استدلال مقید به گراف: روش GCR	۲۱
۹-۲	کاربرد در سلامت روان و مبنای ارزیابی	۲۲
۳	چارچوب و پیاده‌سازی روش‌ها	۲۵
۱-۳	چارچوب مشترک آزمایش‌ها	۲۶
۲-۳	ساخت گراف دانش و نمایه‌سازی برداری	۲۷

۲۸	۳-۳ پیاده‌سازی روش‌های مورد مقایسه
۲۹	۱-۳-۳ زنجیره فکر (CoT)
۲۹	۲-۳-۳ Vanilla RAG
۲۹	۳-۳-۳ HippoRAG 2
۳۰	۴-۳-۳ ToG-1
۳۱	۵-۳-۳ ToG-2
۳۲	۴ نتایج و تحلیل مقایسه‌ای
۳۳	۱-۴ آمار گراف دانش و نمایه‌سازی برداری
۳۴	۲-۴ مقایسه نتایج پیش‌بینی در مجموعه‌داده‌ها
۳۶	۳-۴ مقایسه توضیح‌پذیری روش‌ها
۳۶	۱-۳-۴ شباهت معنایی توضیح‌ها
۳۷	۲-۳-۴ ارزیابی سازگاری ادعاهای بالینی مبتنی بر گراف دانش
۳۸	۴-۴ مقایسه هزینه محاسباتی و زمان اجرا
۳۹	۵-۴ جمع‌بندی
۴۰	۵ جمع‌بندی، محدودیت‌ها و مسیرهای آینده
۴۱	۱-۵ مرور پژوهش انجام‌شده
۴۱	۲-۵ محدودیت‌ها و ضعف‌های پژوهش
۴۳	۳-۵ پیشنهادهایی برای پژوهش‌های آینده
۴۳	۱-۳-۵ گسترش و بهبود مجموعه‌داده‌های تشخیص اختلالات روانی
۴۳	۲-۳-۵ تولید توضیح‌های بالینی با پشتیبانی علمی
۴۴	۳-۳-۵ گسترش دامنه برچسب‌ها و تشخیص باز
۴۴	۴-۳-۵ کاهش نویز در بازیابی و بهبود HippoRAG 2
۴۴	۵-۳-۵ کاهش هزینه و تعداد فراخوانی‌های ToG
۴۵	۶-۳-۵ ارزیابی عمومی ادعا و ارتباط شواهد
۴۵	۴-۵ سخن پایانی

آ	امضاهای ساختاریافته و دستورهای مدل	۴۶
آ-۱	زنجیره فکر و بازیابی متن	۴۷
آ-۲	امضاهای روش HippoRAG 2	۴۷
آ-۳	امضاهای روش ToG-1	۴۸
آ-۴	امضاهای روش ToG-2	۴۸
آ-۵	ارزیابی ادعاهای بالینی	۵۰
ب	نمونه اجرای گام به گام روش ها	۵۱
ب-۱	نمونه مشترک	۵۲
ب-۲	روش Vanilla RAG	۵۲
ب-۳	روش HippoRAG 2	۵۲
ب-۴	روش زنجیره فکر CoT	۵۳
ب-۵	روش ToG-1	۵۳
ب-۶	روش ToG-2	۵۴
ب-۷	نمونه استخراج ادعا از توضیح ToG-2	۵۴
	منابع و مراجع	۵۶

فهرست شکل‌ها

صفحه

شکل

فهرست جدول‌ها

صفحه

جدول

۳۳	۱-۴ توزیع موجودیت‌های گراف دانش بر اساس نوع
۳۴	۲-۴ آمار مجموعه‌های برداری Milvus
۳۴	۳-۴ مقایسه نتایج پیش‌بینی روش‌ها در مجموعه داده DR
۳۵	۴-۴ مقایسه نتایج پیش‌بینی روش‌ها در مجموعه داده SWMH
۳۵	۵-۴ معیارهای تفکیک‌شده برچسب‌ها در مجموعه داده DR
۳۶	۶-۴ معیارهای تفکیک‌شده برچسب‌ها در مجموعه داده SWMH
۳۷	۷-۴ شباهت برداری توضیح‌های تولیدشده با توضیح مرجع
۳۸	۸-۴ نتایج ارزیابی سازگاری ادعاهای بالینی با گراف دانش
۳۹	۹-۴ میانگین مصرف توکن، تأخیر و فراخوانی مدل زبانی در هر نمونه

فصل اول

کلیات و مبانی تشخیص توضیح‌پذیر سلامت

روان

۱-۱ مقدمه و بیان مسئله

سلامت روان بخشی جدایی‌ناپذیر از سلامت عمومی است و اختلال در آن می‌تواند کیفیت زندگی، روابط اجتماعی، تحصیل و اشتغال فرد را تحت تأثیر قرار دهد. در بسیاری از جوامع، نیاز به خدمات سلامت روان بیش از ظرفیت پاسخ‌گویی نظام‌های درمانی است [۱]. این فاصله، ضرورت توسعه ابزارهایی را نشان می‌دهد که شناسایی اولیه و بررسی شواهد را برای متخصصان تسهیل کنند، بدون آن‌که جایگزین ارزیابی بالینی شوند.

تشخیص اختلالات روانی بر پایه مصاحبه بالینی، مشاهده، سابقه فرد و معیارهای تشخیصی انجام می‌شود و به مدت و شدت نشانه‌ها و اثر آن‌ها بر زندگی روزمره وابسته است [۲]. در کنار این منابع، نوشته‌های منتشرشده در فضای مجازی حاوی گزارش‌هایی از تجربه‌ها و حالات هیجانی کاربران هستند و می‌توان از آن‌ها برای مطالعه الگوهای مرتبط با افسردگی، اضطراب و تنیدگی استفاده کرد [۳، ۴]. با این حال، چنین متنی معادل پرونده بالینی نیست و نتیجه حاصل از آن باید یک برآورد محاسباتی تلقی شود.

روش‌های طبقه‌بندی معمولاً یک برچسب مانند وجود یا نبود افسردگی تولید می‌کنند، اما نشان نمی‌دهند کدام شواهد متنی در تصمیم نقش داشته‌اند. این محدودیت در سلامت روان مهم است؛ زیرا باید بتوان برداشت نادرست از کنایه، نادیده گرفتن بافت یا تعمیم از یک نشانه منفرد را تشخیص داد. از این رو، توضیح‌پذیری^۱ بخشی از ارزیابی مسئولانه سامانه است، نه صرفاً یک قابلیت جانبی [۵].

مدل‌های زبانی بزرگ^۲ می‌توانند همراه با برچسب، توضیحی متنی نیز تولید کنند. با وجود این، روان بودن توضیح درستی آن را تضمین نمی‌کند و مدل ممکن است نشانه یا رابطه‌ای را بیان کند که در ورودی وجود ندارد. این مسئله که توهم اطلاعاتی^۳ نامیده می‌شود، در حوزه سلامت روان می‌تواند به نتیجه‌گیری قطعی بر پایه شواهد ناکافی بینجامد. به همین دلیل، شفافیت، ارزیابی دقیق و نظارت انسانی در کاربردهای سلامت ضروری است [۶، ۷].

بازیابی افزوده^۴ با قراردادن اطلاعات بیرونی در اختیار مدل، راهی برای کاهش وابستگی به دانش درونی آن فراهم می‌کند [۸]. اگر این اطلاعات در قالب گراف دانش^۵ سازمان‌دهی شوند، روابط میان

^۱ Explainability

^۲ Large Language Models (LLMs)

^۳ Factual Hallucination

^۴ Retrieval-Augmented Generation (RAG)

^۵ Knowledge Graph (KG)

مفاهیم نیز در بازیابی و استدلال قابل استفاده خواهند بود. مسئله این پژوهش، بازپیاپی‌سازی و انطباق چند روش گراف‌محور و مقایسه آن‌ها در یک وظیفه مشترک سلامت روان است. روش‌ها از نظر درستی پیش‌بینی، اتکاپذیری توضیح، زمان پاسخ و هزینه متنی بررسی می‌شوند؛ هدف نیز ارائه یک روش گرافی تازه نیست، بلکه روشن کردن مزایا و محدودیت‌های الگوهای موجود است.

۲-۱ تشخیص توضیح‌پذیر سلامت روان از داده‌های متنی

در این پایان‌نامه، تشخیص از متن به معنای نگاشت یک نوشته خوداظهاری به برجستگی از پیش تعریف‌شده است. ورودی می‌تواند یک پیام کوتاه یا نوشته‌ای منتشرشده در شبکه اجتماعی باشد و خروجی شامل برجستگی وضعیت روانی یا عامل مورد بررسی و توضیح شواهد مؤثر در آن است. منظور از تشخیص توضیح‌پذیر، صدور حکم بالینی نیست؛ سامانه باید تصمیم محاسباتی خود را به شکلی ارائه دهد که قابل بازبینی باشد.

زبان این نوشته‌ها اغلب غیررسمی، استعاری یا غیرمستقیم است و معنای یک عبارت می‌تواند به جمله‌های پیشین و پسین وابسته باشد. افزون بر این، نشانه‌هایی مانند اختلال خواب، خستگی و کاهش تمرکز به یک اختلال خاص محدود نیستند. بنابراین، مدل باید میان شواهد صریح، برداشت احتمالی و اطلاعاتی که در متن وجود ندارد تمایز بگذارد.

مجموعه داده IMHI^۶ داده‌های چند مجموعه پیشین را در قالب تعامل‌های دستور و پاسخ گردآوری کرده است [۹، ۱۰]. وظایف آن شامل تشخیص دودویی، تشخیص چندکلاسه، شناسایی علت یا عامل زمینه‌ای و تشخیص عوامل خطر یا ابعاد بهزیستی است. در این پژوهش، از هر گروه یک تنظیم نماینده انتخاب می‌شود تا روش‌ها در صورت‌های متفاوت مسئله و در عین حال در دامنه‌ای قابل کنترل مقایسه شوند.

توضیح مطلوب باید به متن ورودی وفادار باشد و از افزودن نشانه، رویداد یا رابطه‌ای که در متن دیده نمی‌شود پرهیز کند. ممکن است برجستگی نهایی درست باشد، اما مسیر استدلال شامل ادعایی نادرست باشد؛ از این رو، ارزیابی برجستگی و توضیح باید جداگانه انجام شود. همچنین، خطا تنها به کاهش یک معیار عددی محدود نیست: مثبت کاذب می‌تواند متن عادی را نشانه اختلال تلقی کند و منفی کاذب ممکن است شواهد مهم را نادیده بگیرد.

^۶Interpretable Mental Health Instruction

گراف دانش دامنه‌ای در این پژوهش منبعی صریح برای نگهداری مفاهیمی مانند اختلال، نشانه و عامل خطر و روابط میان آن‌هاست. روش گراف‌محور می‌تواند اطلاعات مرتبط را بازبایی یا مسیرهای میان مفاهیم را دنبال کند، اما وجود گراف به تنهایی درستی پاسخ را تضمین نمی‌کند؛ کیفیت بازبایی، پوشش گراف و نحوه استفاده مدل از شواهد بر نتیجه اثر دارند. سامانه نیز صرفاً یک ابزار تصمیم‌یار است و نتایج آن در محدوده داده‌ها و تنظیمات آزمایشی تفسیر می‌شود. حریم خصوصی، رضایت، سوگیری داده و تفاوت‌های زبانی و فرهنگی نیز باید در استفاده از داده‌های سلامت روان در نظر گرفته شوند [۶].

۳-۱ مدل‌های زبانی بزرگ، توضیح‌پذیری و توهم اطلاعاتی

مدل زبانی، توزیع احتمال دنباله‌های زبانی را می‌آموزد و در زمان تولید، هر جزء متن را با توجه به اجزای پیشین پیش‌بینی می‌کند. مدل‌های زبانی بزرگ این سازوکار را با تعداد زیادی پارامتر و بر پیکره‌های گسترده به کار می‌گیرند؛ در نتیجه، می‌توانند متن ورودی را خلاصه کنند، به پرسش پاسخ دهند و برای یک تصمیم توضیح زبانی بسازند. در این پایان‌نامه، اهمیت این مدل‌ها در توانایی انجام هم‌زمان تشخیص و تولید توضیح است، نه در استفاده از آن‌ها به عنوان منبع مستقل دانش بالینی.

دانش مدل در پارامترهای آن ذخیره شده و دسترسی مستقیم به منشأ هر گزاره آسان نیست. پاسخ نیز به صورت پرسش، اطلاعات موجود در بافت ورودی و شیوه تنظیم مدل وابسته است. این ویژگی انعطاف‌پذیری زیادی ایجاد می‌کند، اما سبب می‌شود دو پاسخ زبانی مشابه از نظر پشتوانه دانشی یکسان نباشند. مدل ممکن است از یک عبارت مبهم نتیجه‌ای فراتر از متن بگیرد یا دانشی کلی را بدون مشخص کردن منبع وارد پاسخ کند.

در تشخیص توضیح‌پذیر، توضیح باید نشان دهد چه شواهدی به برجسب منتهی شده‌اند و این شواهد چگونه با نتیجه ارتباط دارند. توضیح روان یا متقاعدکننده لزوماً توضیح وفادار نیست؛ ممکن است پس از تولید برجسب ساخته شده باشد و روند واقعی تصمیم را منعکس نکند. بنابراین، کیفیت نگارش و وفاداری دو معیار متفاوت‌اند. اولی به وضوح و انسجام پاسخ مربوط است و دومی بررسی می‌کند که ادعاهای توضیح با متن ورودی و دانش معتبر پشتیبانی می‌شوند یا نه [۵].

توهم اطلاعاتی زمانی رخ می‌دهد که مدل گزاره‌ای فاقد پشتوانه در ورودی یا منبع معتبر تولید کند. در مسئله این پژوهش، این خطا می‌تواند به شکل افزودن نشانه‌ای گزارش نشده، نسبت دادن علت به یک وضعیت، یا بیان رابطه‌ای نادرست میان نشانه و اختلال ظاهر شود. چنین خطایی حتی با وجود برجسب

درست نیز اعتبار توضیح را کاهش می‌دهد. حساسیت داده‌های سلامت روان نیز سبب می‌شود ادعاهای قطعی و بدون شاهد با دقت بیشتری کنترل شوند [۷].

برای کاهش این مسئله، لازم است شواهد مورد استفاده مدل تا حد امکان صریح و قابل ردیابی باشند. قرار دادن اطلاعات بازیابی‌شده در بافت ورودی، امکان مقایسه ادعاهای پاسخ با یک منبع بیرونی را فراهم می‌کند؛ هرچند انتخاب شواهد نامرتب یا استفاده نادرست از آن‌ها همچنان می‌تواند پاسخ را منحرف کند. بخش بعدی سازوکار بازیابی افزوده و نقش آن در پیوند مدل زبانی با منابع دانشی را بررسی می‌کند.

۴-۱ بازیابی افزوده: تعریف، سازوکار و مزایا

بازیابی افزوده روشی برای پیوند مدل زبانی با یک منبع دانشی بیرونی است. در این روش، مدل پاسخ را تنها بر پایه دانشی که هنگام آموزش در پارامترهای آن ذخیره شده است تولید نمی‌کند؛ ابتدا اطلاعات مرتبط با پرسش از یک مجموعه اسناد بازیابی می‌شود و سپس پرسش همراه با اطلاعات بازیابی‌شده در اختیار مدل قرار می‌گیرد. به این ترتیب، مرحله بازیابی مسئول یافتن شواهد و مرحله تولید مسئول ترکیب شواهد و ساخت پاسخ است [۸].

در آماده‌سازی منبع دانش، اسناد معمولاً به قطعه‌های کوچک‌تر تقسیم می‌شوند. این فرایند که قطعه‌بندی^۷ نام دارد، امکان جست‌وجوی بخش مرتبط یک سند طولانی را فراهم می‌کند. سپس هر قطعه با یک بردار نهفته^۸ نمایش داده و همراه با متن و اطلاعاتی مانند شناسه سند در یک نمایه ذخیره می‌شود. در زمان پرسش، پرسش نیز به همان فضای برداری نگاشت می‌شود و قطعه‌هایی که بیشترین شباهت معنایی را دارند به عنوان نامزد انتخاب می‌شوند.

قطعه‌های برگزیده به بافت ورودی مدل افزوده می‌شوند و دستور تولید پاسخ را تشکیل می‌دهند. مدل باید با اتکا به این بافت، اطلاعات پراکنده را کنار هم قرار دهد و پاسخ نهایی را بسازد. تعداد قطعه‌های بازیابی‌شده باید محدود باشد؛ زیرا افزودن شواهد کم، احتمال حذف اطلاعات لازم را افزایش می‌دهد و افزودن شواهد زیاد می‌تواند اطلاعات نامرتب وارد پاسخ کند یا از ظرفیت بافت مدل فراتر رود. بنابراین، کیفیت پاسخ تنها به توان مدل زبانی وابسته نیست و انتخاب درست شواهد نقش تعیین‌کننده‌ای دارد. مزیت اصلی این رویکرد، جداسازی نسبی دانش از پارامترهای مدل است. منبع بیرونی را می‌توان بدون آموزش دوباره مدل اصلاح یا به‌روزرسانی کرد و در صورت نگهداری شناسه اسناد، منشأ شواهد را

Chunking^۷
Embedding^۸

نیز بررسی نمود. همچنین، محدود کردن پاسخ به اطلاعات بازبایی شده می‌تواند از تولید برخی ادعاهای بدون پشتوانه بکاهد. این مزیت در حوزه سلامت روان مهم است؛ زیرا باید بتوان مشخص کرد هر بخش از توضیح به کدام داده متنی یا مفهوم دامنه‌ای متکی است.

با این حال، بازبایی افزوده تضمین نمی‌کند که پاسخ همواره درست باشد. اگر قطعه مرتبط بازبایی نشود، اگر متن بازبایی شده مبهم یا ناسازگار باشد، یا اگر مدل از شواهد به‌درستی استفاده نکند، خطا همچنان رخ می‌دهد. از این رو، بازبایی صرفاً مرحله‌ای پیش از تولید نیست، بلکه بخشی از زنجیره استدلال و یکی از مؤلفه‌های اصلی ارزیابی سامانه است. در ادامه، محدودیت‌های بازبایی صرفاً متنی و دلیل استفاده از ساختار گرافی بررسی می‌شود.

۵-۱ محدودیت‌های بازبایی متنی و ضرورت ساختار گرافی

بازبایی متنی معمولاً هر قطعه را مستقل از سایر قطعه‌ها رتبه‌بندی می‌کند. این سازوکار برای پرسش‌هایی که پاسخ آن‌ها در یک بخش مشخص از متن قرار دارد مناسب است، اما در پرسش‌های پیچیده‌تر ممکن است شواهد لازم میان چند سند پراکنده باشند. در چنین حالتی، شباهت معنایی میان پرسش و هر قطعه به‌تنهایی برای کشف ارتباط میان شواهد کافی نیست و قطعه‌ای که واژگان مشابهی ندارد، با وجود نقش آن در پاسخ، کنار گذاشته می‌شود.

قطعه‌بندی نیز با یک مبادله همراه است. قطعه‌های بزرگ بافت بیشتری حفظ می‌کنند، اما بازبایی آن‌ها اطلاعات نامرتبب بیشتری وارد ورودی مدل می‌کند. قطعه‌های کوچک دقیق‌ترند، ولی ممکن است رابطه میان جمله‌ها، بخش‌های یک سند یا چند سند را از بین ببرند. این مسئله در مجموعه‌های بزرگ که اطلاعات مربوط به یک مفهوم در نقاط مختلف توزیع شده است شدیدتر می‌شود و بازبایی متن را در دنبال کردن زنجیره‌های چندمرحله‌ای محدود می‌کند [۱۱، ۱۲].

بسیاری از پرسش‌ها به استدلال چندگامی^۹ نیاز دارند؛ یعنی رسیدن به پاسخ مستلزم عبور از چند رابطه میان اشخاص، رویدادها یا مفاهیم است. یک فهرست رتبه‌بندی شده از قطعه‌ها این روابط را به‌صورت صریح نمایش نمی‌دهد و مدل باید آن‌ها را پس از بازبایی بازسازی کند. این وابستگی احتمال نادیده‌ماندن یک حلقه از زنجیره یا ایجاد ارتباطی بدون پشتوانه را افزایش می‌دهد. پژوهش‌های گراف‌محور نیز ضعف بازبایی برداری را در بازنمایی ارتباط‌های ساختاری و حافظه تداعی‌گر گزارش کرده‌اند [۱۳].

^۹ Multi-hop Reasoning

ساختار گرافی این امکان را فراهم می‌کند که مفاهیم به صورت گره و ارتباط‌های میان آن‌ها به صورت یال نمایش داده شوند. پس از شناسایی یک مفهوم در پرسش، بازیابی می‌تواند به مفاهیم همسایه گسترش یابد و به جای چند قطعه مستقل، یک زیرگراف مرتبط در اختیار مدل قرار دهد. در نتیجه، هم محتوای متنی و هم مسیر ارتباط میان شواهد قابل استفاده خواهد بود. برای نمونه، G-Retriever مسئله انتخاب بخش مرتبط یک گراف متنی را به صورت یافتن یک زیرگراف متصل صورت‌بندی می‌کند تا حجم ورودی کاهش یابد و ساختار لازم برای پاسخ حفظ شود [۱۴].

با این همه، گراف راه‌حلی بدون خطا نیست. گراف دانش ممکن است ناقص باشد و استخراج خودکار موجودیت‌ها و روابط می‌تواند یال‌های نادرست یا ناسازگار ایجاد کند. بازیابی گرافی نامناسب نیز ممکن است نویز را از یک گره به بخش‌های دیگر گسترش دهد. بنابراین، ضرورت استفاده از گراف به معنای کنارگذاشتن متن نیست؛ هدف، افزودن سازمان ساختاری به شواهد متنی و فراهم کردن مسیرهای قابل ردیابی است. تفاوت روش‌های موجود عمدتاً به نحوه ساخت گراف، انتخاب زیرگراف و چگونگی ادغام آن با مدل زبانی بازمی‌گردد که در بخش بعد بررسی می‌شود.

۱-۶ گراف دانش، الگوهای ادغام و جهت‌گیری پژوهش

گراف دانش، اطلاعات را به صورت مجموعه‌ای از موجودیت‌ها و روابط میان آن‌ها نمایش می‌دهد. هر گزاره را می‌توان با یک سه‌تایی شامل موجودیت مبدأ، نوع رابطه و موجودیت مقصد بیان کرد. برای نمونه، ارتباط میان یک نشانه، عامل خطر و اختلال می‌تواند به صورت چند سه‌تایی مرتبط ذخیره شود. برخلاف متن پیوسته، این بازنمایی امکان جست‌وجوی مستقیم همسایه‌های یک مفهوم و دنبال کردن مسیرهای چندگامی را فراهم می‌کند. همچنین، افزودن یا اصلاح یک رابطه بدون آموزش دوباره مدل زبانی امکان‌پذیر است.

در روش‌های بازیابی‌محور^{۱۰}، یک بازیاب بیرونی بخش مرتبط گراف یا اسناد متصل به آن را انتخاب می‌کند و نتیجه را در اختیار مدل زبانی قرار می‌دهد. مزیت این الگو آن است که فرایند بازیابی از تولید پاسخ جداست و می‌توان کیفیت زیرگراف، میزان پوشش شواهد و هزینه بازیابی را مستقل ارزیابی کرد. در مقابل، عملکرد روش به دقت بازیاب وابسته است؛ حذف یک گره یا مسیر مهم در این مرحله ممکن است با توان استدلالی مدل جبران نشود. HippoRAG 2، G-Retriever و در مقیاسی محدودتر LinearRAG

^{۱۰} Retrieval-based Methods

نمونه‌هایی از این جهت‌گیری‌اند که با سازوکارهای متفاوت، ارتباط ساختاری میان قطعه‌های متنی را در بازیابی وارد می‌کنند [۱۲، ۱۳، ۱۴].

در روش‌های عامل‌محور^{۱۱}، مدل زبانی تنها مصرف‌کننده نتیجه بازیابی نیست، بلکه در انتخاب گام بعدی جست‌وجو نقش دارد. مدل از مفاهیم اولیه شروع می‌کند، رابطه‌ها و موجودیت‌های محتمل را ارزیابی می‌کند و این چرخه تا یافتن شواهد کافی یا رسیدن به حد توقف ادامه می‌یابد. روش ToG این ایده را با پیمایش تکرارشونده مسیرهای گرافی به کار می‌گیرد و ToG-2 بازیابی گراف و متن را به صورت رفت‌وبرگشتی ترکیب می‌کند [۱۵، ۱۱]. این الگو برای پرسش‌های چندگامی انعطاف بیشتری دارد، اما به فراخوانی‌های متعدد مدل وابسته است و در نتیجه زمان پاسخ و هزینه آن افزایش می‌یابد. افزون بر این، انتخاب نادرست در یک گام می‌تواند ادامه پیمایش را به مسیر نامرتبط هدایت کند.

الگوی سوم، استدلال مقید به گراف^{۱۲} است. در این الگو، ساختار گراف تنها در ورودی مدل قرار نمی‌گیرد، بلکه گزینه‌های مجاز هنگام تولید مسیر استدلال را محدود می‌کند. روش GCR مسیرهای گراف را در نمایه‌ای به نام KG-Trie ذخیره می‌کند و مدل را وادار می‌سازد دنباله‌ای سازگار با مسیرهای موجود در گراف تولید کند [۱۶]. این قید از ساخت رابطه‌ای که در گراف وجود ندارد جلوگیری می‌کند و ردیابی مسیر را دقیق‌تر می‌سازد؛ با این حال، اگر دانش لازم در گراف ثبت نشده باشد، محدودیت ساختاری نمی‌تواند آن را جبران کند.

تفاوت این سه الگو در محل اعمال ساختار گراف است. در روش بازیابی‌محور، گراف بر انتخاب شواهد اثر می‌گذارد؛ در روش عامل‌محور، گراف فضای جست‌وجوی تعاملی مدل را شکل می‌دهد؛ و در روش مقید، مسیر تولیدشده باید با ساختار گراف سازگار باشد. در نتیجه، هر الگو تعادل متفاوتی میان پوشش شواهد، انعطاف استدلال، وفاداری مسیر و هزینه محاسباتی برقرار می‌کند. مقایسه منصفانه آن‌ها نیازمند داده، گراف و معیارهای ارزیابی مشترک است.

جهت‌گیری این پژوهش، بازپیاپی‌سازی و انطباق نماینده‌هایی از این الگوها برای تشخیص توضیح‌پذیر سلامت روان است. همه روش‌ها بر وظایف منتخب IMHI و یک گراف دانش دامنه‌ای مشترک ارزیابی می‌شوند تا اثر سازوکار ادغام از تفاوت داده و دانش جدا شود. مقایسه بر درستی برچسب، وفاداری و کیفیت توضیح، زمان پاسخ و هزینه متنی متمرکز است. افزون بر معیارهای معمول، ادعاها و روابط بیان‌شده در توضیح با چارچوب GraphEval بررسی می‌شوند تا مشخص شود هر پاسخ تا چه اندازه به

^{۱۱} Agent-based Methods

^{۱۲} Graph-constrained Reasoning

شواهد قابل ردیابی متکی است.

۷-۱ جمع‌بندی

در این فصل، مسئله تشخیص توضیح‌پذیر سلامت روان از داده‌های متنی و تفاوت آن با طبقه‌بندی صرف بیان شد. سپس نقش مدل‌های زبانی بزرگ در تولید هم‌زمان برچسب و توضیح، مسئله توهم اطلاعاتی و نیاز به سنجش مستقل وفاداری توضیح بررسی گردید. بازیابی افزوده به عنوان راهی برای اتصال مدل به دانش بیرونی معرفی شد و نشان داده شد که بازیابی متنی، به دلیل رتبه‌بندی مستقل قطعه‌ها و ناتوانی در نمایش صریح روابط، در پرسش‌های چندگامی با محدودیت روبه‌روست.

در ادامه، ساختار گرافی و سه الگوی بازیابی‌محور، عامل‌محور و استدلال مقید از یکدیگر تفکیک شدند. این الگوها از نظر نحوه انتخاب شواهد، میزان دخالت مدل در پیمایش، وفاداری مسیر و هزینه اجرایی تفاوت دارند و مبنای مقایسه این پژوهش را تشکیل می‌دهند. فصل بعد، پژوهش‌های مرتبط و روش‌های مبنا را بر پایه همین تقسیم‌بندی بررسی می‌کند و مزایا و محدودیت‌های هر خانواده را با جزئیات بیشتری توضیح می‌دهد.

فصل دوم

پژوهش‌های مرتبط و روش‌های مبنا

۱-۲ مقدمه و چارچوب طبقه‌بندی

هدف این فصل، مرور پژوهش‌های مرتبط با تشخیص توضیح‌پذیر سلامت روان و بررسی روش‌هایی است که مبنای بازپیاپی‌سازی و آزمایش‌های این پژوهش قرار می‌گیرند. ابتدا کارهای مرتبط با وظیفه، از طبقه‌بندی متن تا تولید توضیح و استفاده از دانش دامنه‌ای، مرور می‌شوند. سپس روش‌های بازیابی افزوده و گراف‌محور از نظر مسئله اولیه، نوع شواهد و نحوه تولید پاسخ بررسی می‌شوند تا شرایط لازم برای انطباق آن‌ها با سلامت روان روشن گردد.

روش‌های منتخب بر اساس محل دخالت گراف در فرایند پاسخ‌گویی به سه خانواده تقسیم می‌شوند. در خانواده بازیابی‌محور، بخشی از گراف یا اسناد مرتبط پیش از تولید پاسخ انتخاب و به مدل داده می‌شود؛ HippoRAG 2، G-Retriever و در مقیاسی محدودتر LinearRAG در این دسته بررسی می‌شوند. در خانواده عامل‌محور، مدل زبانی در چند مرحله با گراف تعامل می‌کند و مسیر جست‌وجو را شکل می‌دهد؛ ToG و ToG-2 نمایندگان این الگو هستند. در نهایت، روش GCR به عنوان یک الگوی قیدگذارانه بررسی می‌شود که ساختار گراف را در فرایند تولید مسیر استدلال وارد می‌کند.

این طبقه‌بندی به معنای برتری ذاتی یک خانواده بر خانواده دیگر نیست. هر الگو برای هدف و تنظیم آزمایشی متفاوتی طراحی شده و میان پوشش شواهد، انعطاف استدلال، وفاداری مسیر و هزینه اجرا تعادل خاصی برقرار می‌کند. از این رو، مقایسه روش‌ها علاوه بر کیفیت پاسخ، به نیاز آن‌ها به آموزش، تعداد تعامل‌ها با مدل زبانی، نحوه انتخاب زیرگراف یا متن مرتبط، امکان ردیابی شواهد، زمان پاسخ و هزینه متنی توجه خواهد داشت. این معیارها مبنای تنظیم مجموعه ارزیابی مشترک در فصل‌های بعد هستند. پس از مرور پژوهش‌های سلامت روان، بازیابی افزوده به عنوان راهی برای دسترسی مدل به دانش بیرونی معرفی می‌شود و گذار از بازیابی متنی به گراف‌محور توضیح داده می‌شود. پیش از بررسی شیوه‌های استفاده از گراف، روش KGGen برای ساخت گراف دانش از متن معرفی می‌شود. سپس روش‌های بازیابی‌محور و عامل‌محور معرفی و مقایسه می‌شوند و GCR از نظر قیدگذاری ساختاری بررسی می‌گردد. بخش پایانی نیز نحوه انتقال این روش‌ها به وظایف منتخب سلامت روان و معیارهای ارزیابی مشترک را جمع‌بندی می‌کند.

۲-۲ پژوهش‌های تشخیص توضیح‌پذیر سلامت روان

پژوهش‌های این حوزه از نظر نوع خروجی و نحوه استفاده از دانش متفاوت‌اند. برخی، متن یا سابقه فعالیت کاربر را به یک برچسب نگاشت می‌کنند؛ برخی همراه با برچسب، توضیح زبانی تولید می‌کنند؛ و گروهی نیز معیارهای تشخیصی یا منابع دانش را در پردازش وارد می‌کنند. مرور این کارها مشخص می‌کند که روش‌های گرافی در این پایان‌نامه قرار است در چه وظیفه‌ای و با چه خروجی‌هایی ارزیابی شوند.

۱-۲-۲ از روش‌های پیش‌بینی تا مدل‌های زبانی بزرگ

در کارهای اولیه، تشخیص افسردگی عمدتاً به صورت یک مسئله طبقه‌بندی از داده‌های شبکه‌های اجتماعی صورت‌بندی شده است. شن و همکاران از یادگیری فرهنگ‌نامه چندوجهی برای ترکیب اطلاعات کاربران استفاده کرده‌اند و اورایی و همکاران، یادگیری عمیق را برای تشخیص افسردگی کاربران تویتر بررسی کرده‌اند [۳، ۱۷]. پژوهش SenseMood نیز در همین مسیر به تشخیص افسردگی در شبکه‌های اجتماعی می‌پردازد [۱۸]. این مطالعات مبنایی برای یادگیری الگوهای مرتبط با برچسب فراهم می‌کنند، در حالی که تولید توضیح زبانی برای هر تصمیم، خروجی اصلی آن‌ها نیست.

روش AMMNet مسئله پیش‌بینی افسردگی و اضطراب در Reddit را با یادگیری چندوظیفه‌ای دنبال می‌کند [۴]. در این روش، نمایش‌های متنی مشترک با ویژگی‌های موضوعی اختصاصی وظایف ترکیب می‌شوند. استفاده از اطلاعات مشترک، امکان بهره‌گیری از ارتباط میان وظایف را فراهم می‌کند و ویژگی‌های موضوعی نیز به بررسی محتوای مؤثر در پیش‌بینی کمک می‌کنند. این نوع تفسیر ویژگی‌ها با توضیح آزاد زبانی تفاوت دارد، اما برای مقایسه شیوه‌های ارائه شواهد تصمیم مفید است.

با ورود مدل‌های زبانی بزرگ، امکان تولید هم‌زمان برچسب و توضیح مطرح شد. یانگ و همکاران در پژوهش «به سوی تحلیل تفسیرپذیر سلامت روان با مدل‌های زبانی بزرگ»، تنظیم‌های بدون نمونه، چندنمونه‌ای و استدلال زنجیره‌ای را بررسی کرده‌اند [۹]. مدل در این تنظیم‌ها با استفاده از دستور و نمونه‌های داخل ورودی به وظیفه هدایت می‌شود و برای هر وظیفه الزاماً آموزش مجدد نمی‌بیند. ارزیابی انسانی توضیح‌ها نیز بخشی از مطالعه است؛ بنابراین، این کار علاوه بر پیش‌بینی برچسب، کیفیت توضیح را به عنوان خروجی قابل سنجش مطرح می‌کند. چنین تنظیم‌هایی می‌توانند مبنای مقایسه با روش‌هایی باشند که دانش بیرونی دریافت می‌کنند.

۲-۲-۲ تنظیم دامنه‌ای و استفاده از دانش برای تولید توضیح

روش MentalLLaMA تحلیل توضیح‌پذیر سلامت روان را از طریق تنظیم دستوری مدل دنبال می‌کند [۱۰]. داده‌های چند وظیفه در مجموعه IMHI به قالب دستور و پاسخ تبدیل شده‌اند و پاسخ‌ها شامل برچسب و توضیح‌اند. توضیح‌ها با کمک مدل زبانی تولید و با ارزیابی‌های خودکار و انسانی بررسی شده‌اند. آموزش بر این داده‌ها، مدل را با صورت وظایف و نحوه پاسخ‌گویی آشنا می‌کند. ارتباط مستقیم این کار با پایان‌نامه حاضر، استفاده از IMHI و ارزیابی جداگانه پیش‌بینی و توضیح است؛ در اینجا نقش افزودن شواهد گرافی به همین نوع خروجی بررسی خواهد شد.

چارچوب DORIS بر تشخیص افسردگی از پست‌های کاربران تمرکز دارد و دانش تشخیصی را در استخراج ویژگی‌ها وارد می‌کند [۱۹]. مدل زبانی، متن‌ها را از نظر نشانه‌های مرتبط با معیارهای تشخیصی بررسی و روند زمانی حالات خلقی را خلاصه می‌کند. این اطلاعات همراه با نمایش محتوای پست‌ها برای آموزش یک طبقه‌بند به کار می‌روند. توضیح پیش‌بینی نیز بر پایه نشانه‌ها و تحلیل روند خلقی تولید می‌شود. در نتیجه، مدل زبانی هم در آماده‌سازی شواهد و هم در بیان توضیح نقش دارد و تصمیم‌نهایی از یک مؤلفه طبقه‌بندی حاصل می‌شود. این پژوهش نمونه‌ای از استفاده صریح از دانش دامنه‌ای است، هرچند ورودی آن سابقه پست‌های کاربر است و تنظیم آن با تمام وظایف IMHI یکسان نیست.

در سطح منابع دانش، گائو و همکاران گراف MDKG را با استفاده از متون علمی، پایگاه‌های زیست‌پزشکی و مدل‌های زبانی ساخته‌اند [۲۰]. این کار اطلاعات مرتبط با اختلالات روانی را در یک ساختار مشترک سازمان‌دهی می‌کند و کاربرد نمایش‌های حاصل را در پیش‌بینی نیز می‌سنجد. نقش آن در مرور حاضر، معرفی یک مسیر برای فراهم کردن دانش دامنه‌ای است؛ انتخاب و آماده‌سازی منبع گراف برای آزمایش‌های این پایان‌نامه در فصل روش تحقیق مشخص خواهد شد.

این پژوهش‌ها سه راه برای پشتیبانی از تصمیم را نشان می‌دهند: یادگیری از داده‌های برچسب‌دار، آموزش نحوه تولید توضیح و استفاده از دانش دامنه‌ای. ارزیابی افزوده راه دیگری برای دسترسی به دانش فراهم می‌کند که در آن، شواهد متناسب با هر ورودی انتخاب و به مدل داده می‌شوند. بخش بعد این سازوکار را توضیح می‌دهد و سپس به نقش روابط گرافی در انتخاب و استفاده از شواهد می‌پردازد.

۳-۲ از بازیابی افزوده متنی تا بازیابی افزوده گراف‌محور

در الگوی متداول بازیابی افزوده، منبع بیرونی مجموعه‌ای از اسناد متنی است که پس از قطعه‌بندی و تبدیل به نمایش‌های برداری، نمایه‌سازی می‌شوند. برای هر پرسش، چند قطعه با بیشترین شباهت معنایی بازیابی و همراه با پرسش به مدل زبانی داده می‌شوند. این الگو امکان استفاده از اطلاعات بیرون از پارامترهای مدل را بدون آموزش دوباره فراهم می‌کند و به دلیل سادگی و قابلیت اجرا روی مجموعه‌های بزرگ، مبنای بسیاری از سامانه‌های بازیابی افزوده قرار گرفته است [۸].

بازیابی متنی بر دو فرض اصلی استوار است: نخست آن که قطعه مرتبط را بتوان با شباهت میان پرسش و متن تشخیص داد و دوم آن که اطلاعات لازم برای پاسخ در همان قطعه یا در تعداد محدودی از قطعه‌های برتر وجود داشته باشد. این فرض‌ها برای پرسش‌های مستقیم و واقعیت‌محور مناسب‌اند. افزون بر این، اسناد می‌توانند مستقل از یکدیگر به نمایه افزوده یا از آن حذف شوند و هزینه جست‌وجو نیز با استفاده از نمایه‌های برداری قابل کنترل است.

در پرسش‌های چندگامی، شواهد ممکن است میان چند قطعه یا سند توزیع شده باشند و ارتباط آن‌ها فقط از طریق یک یا چند مفهوم واسط آشکار شود. در این حالت، قطعه‌ای که به تنهایی شباهت زیادی با پرسش ندارد ممکن است یکی از حلقه‌های لازم برای رسیدن به پاسخ باشد. انتخاب مستقل قطعه‌ها چنین ارتباطی را مستقیماً نمایش نمی‌دهد و ترکیب آن‌ها به مدل زبانی واگذار می‌شود. همین مسئله سبب شده است برخی پژوهش‌ها ساختارهایی را به بازیابی اضافه کنند که پیوند میان بخش‌های مختلف دانش را نیز در مرحله جست‌وجو لحاظ می‌کنند [۱۱، ۱۳].

در بازیابی افزوده گراف‌محور، واحدهای اطلاعاتی به صورت گره و ارتباط میان آن‌ها به صورت یال نمایش داده می‌شوند. گره می‌تواند یک موجودیت، گزاره، جمله یا قطعه متن باشد و یال نیز رابطه دانشی، هم‌رخدادی یا پیوند معنایی میان دو گره را نشان دهد. بنابراین، خروجی بازیاب لزوماً مجموعه‌ای از قطعه‌های مستقل نیست و می‌تواند شامل چند سه‌تایی، یک مسیر یا یک زیرگراف متصل باشد. برای نمونه، G-Retriever بخشی از گراف متنی را با توجه به پرسش انتخاب می‌کند و ساختار همان بخش را همراه با محتوای متنی در اختیار مدل قرار می‌دهد [۱۴].

گذار به بازیابی گراف‌محور به معنای جایگزینی کامل متن با گراف نیست. گراف روابط و مسیرهای ارتباطی را به صورت صریح نگهداری می‌کند، در حالی که متن جزئیات و زمینه‌ای را در بر دارد که ممکن است در سه‌تایی‌های گراف ثبت نشده باشد. به همین دلیل، برخی روش‌ها از گراف برای هدایت بازیابی

متن استفاده می‌کنند و برخی دیگر، شواهد گرافی و متنی را به صورت ترکیبی به مدل می‌دهند. ToG-2 نمونه‌ای از ادغام رفت‌وبرگشتی این دو منبع است که در آن نتایج پیمایش گراف، بازیابی متن را هدایت می‌کند و متن بازیابی‌شده نیز بر ادامه پیمایش اثر می‌گذارد [۱۱].

در نتیجه، بازیابی متنی و گراف‌محور در نحوه سازمان‌دهی دانش، واحد بازیابی و میزان استفاده از روابط ساختاری تفاوت دارند. برای استفاده از روابط، ابتدا باید مشخص شود گراف چگونه از منابع متنی ساخته می‌شود و صورت‌های مختلف یک مفهوم چگونه در آن یکسان می‌شوند. از این رو، بخش بعد روش KGGen را برای ساخت گراف دانش از متن معرفی می‌کند. پس از آن، شیوه‌های انتخاب شواهد و پیمایش گراف در روش‌های بازیابی‌محور و عامل‌محور بررسی خواهند شد.

۴-۲ ساخت گراف دانش از متن: روش KGGen

ساخت گراف از متن، مرحله آماده‌سازی دانش برای بازیابی و استدلال است. در این مرحله باید مفاهیم و روابط متن استخراج شوند و اطلاعات اسناد مختلف در یک ساختار قابل جست‌وجو قرار گیرند. برای مثال، ثبت یک مفهوم با چند نام مستقل می‌تواند ارتباط شواهد پراکنده را مخفی کند. در مقابل، ادغام دو مفهوم متمایز ممکن است رابطه‌ای گمراه‌کننده ایجاد کند. بنابراین، کیفیت گراف تنها به تعداد سه‌تایی‌های استخراج‌شده وابسته نیست و نحوه یکسان‌سازی آن‌ها نیز اهمیت دارد.

روش KGGen سه مرحله دارد: استخراج، تجمیع و یکسان‌سازی موجودیت‌ها و روابط [۲۱]. ابتدا مدل زبانی فهرست موجودیت‌های هر متن را استخراج می‌کند و سپس با دریافت متن و این فهرست، سه‌تایی‌ها را می‌سازد. در مرحله تجمیع، گراف‌های حاصل از منابع مختلف ترکیب و موارد تکراری یکسان حذف می‌شوند. این مرحله به فراخوانی مدل زبانی نیاز ندارد.

در مرحله سوم، نام‌های متفاوتی که به یک موجودیت یا رابطه اشاره دارند شناسایی می‌شوند. در نسخه دوم مقاله، نمایش‌های برداری برای خوشه‌بندی به کار می‌روند و نامزدهای مشابه با ترکیب جست‌وجوی واژگانی و معنایی پیدا می‌شوند. مدل زبانی هم‌ارزی نامزدها را بررسی و برای موارد تکراری یک نام نماینده انتخاب می‌کند. این فرایند جداگانه بر موجودیت‌ها و روابط اعمال می‌شود تا تنوع نام‌گذاری، گراف را بی‌جهت پراکنده نکند؛ صرف شباهت معنایی نیز نباید به ادغام مفاهیم متفاوت منجر شود.

مقاله برای ارزیابی استخراج، مجموعه ارزیابی MINE را معرفی می‌کند که حفظ اطلاعات متن و کاربرد گراف در بازیابی افزوده را می‌سنجد. در این پایان‌نامه، KGGen به عنوان یک روش ساخت گراف

بررسی می‌شود؛ انتخاب منابع سلامت روان و کنترل کیفیت گراف حاصل، بخشی از طراحی آزمایش خواهد بود. پس از آماده‌سازی چنین ساختاری، مسئله بعدی انتخاب بخش مرتبط آن برای هر ورودی است که در بخش بعد بررسی می‌شود.

۲-۵ روش‌های گرافی بازیابی‌محور: سازوکار و ویژگی‌ها

در روش‌های گرافی بازیابی‌محور، انتخاب شواهد پیش از تولید پاسخ و به وسیله یک مؤلفه بازیاب انجام می‌شود. مدل زبانی زیرگراف یا قطعه‌های متنی حاصل از بازیابی را دریافت می‌کند، اما مستقیماً درباره گام بعدی پیمایش تصمیم نمی‌گیرد. روش‌های این خانواده در سه مؤلفه با یکدیگر تفاوت دارند: گراف از پیش موجود است یا از متن ساخته می‌شود، امتیاز ارتباط پرسش با گره‌ها و یال‌ها چگونه محاسبه می‌گردد، و خروجی بازیاب به صورت زیرگراف یا مجموعه‌ای از قطعه‌های متن در اختیار مدل قرار می‌گیرد.

روش G-Retriever برای پرسش و پاسخ روی گراف‌های متنی طراحی شده است؛ یعنی گراف‌هایی که گره‌ها و یال‌های آن‌ها ویژگی متنی دارند [۱۴]. فرایند این روش چهار مرحله دارد. ابتدا متن گره‌ها و یال‌ها رمزگذاری و برای جست‌وجوی نزدیک‌ترین همسایه نمایه‌سازی می‌شود. سپس پرسش با همان رمزگذار به یک بردار تبدیل می‌گردد و مرتبط‌ترین گره‌ها و یال‌ها بر اساس شباهت با پرسش انتخاب می‌شوند. این امتیازها مشخص می‌کنند کدام اجزای گراف برای پاسخ اهمیت بیشتری دارند.

پس از امتیازدهی اولیه، انتخاب نهایی زیرگراف به صورت مسئله درخت اشتاینر جایزه‌جمع‌کن^۱ صورت‌بندی می‌شود. در این صورت‌بندی، گره‌ها و یال‌های مرتبط جایزه بیشتری دارند و افزودن اجزای دیگر به زیرگراف با هزینه همراه است. نتیجه، زیرگرافی متصل است که میان پوشش اجزای مرتبط و محدود نگه‌داشتن اندازه ورودی تعادل برقرار می‌کند. زیرگراف به متن تبدیل و همراه با پرسش و نمایش حاصل از رمزگذار گراف به مدل زبانی داده می‌شود. بازگرداندن همین زیرگراف، امکان مشاهده شواهد انتخاب‌شده را نیز فراهم می‌کند.

مزیت ساختار G-Retriever آن است که می‌تواند روی گرافی بزرگ‌تر از ظرفیت ورودی مدل عمل کند و تنها بخش مرتبط و متصل آن را وارد مرحله تولید نماید. در مقابل، استفاده از آن مستلزم وجود یک گراف متنی و محاسبه امتیاز مناسب برای گره‌ها و یال‌هاست. همچنین، کیفیت پاسخ به زیرگراف

^۱Prize-Collecting Steiner Tree (PCST)

استخراج‌شده وابسته است؛ اگر جزء لازم در مرحله بازیابی امتیاز کافی نگیرد، در ورودی مدل نیز حضور نخواهد داشت. بنابراین، در بازپیاپی‌سازی این روش باید عملکرد بازیاب و مولد به صورت جداگانه ثبت شود.

روش HippoRAG 2 با فرض متفاوتی آغاز می‌کند و گراف را از مجموعه اسناد می‌سازد [۱۳]. در مرحله نمایه‌سازی برون‌خط، یک مدل زبانی با استخراج اطلاعات باز^۲ از هر قطعه، سه‌تایی‌های بدون شمای ثابت تولید می‌کند. موضوع و مفعول این سه‌تایی‌ها به صورت گره‌های عبارتی و رابطه میان آن‌ها به صورت یال ذخیره می‌شود. سپس پیوندهای هم‌معنا بر پایه شباهت برداری افزوده می‌شوند. نسخه دوم HippoRAG علاوه بر این مفاهیم، خود قطعه‌های متن را نیز به عنوان گره نگه می‌دارد و آن‌ها را به عبارت‌های استخراج‌شده متصل می‌کند؛ در نتیجه، ساختار مفهومی و زمینه اصلی متن در یک نمایه مشترک قرار می‌گیرند.

در زمان بازیابی، پرسش با سه‌تایی‌ها و قطعه‌های متن مقایسه می‌شود و نامزدهای اولیه برای شروع جست‌وجوی گرافی شکل می‌گیرند. یک مرحله بازنمایی با استفاده از مدل زبانی، سه‌تایی‌های نامرتبط را از میان نامزدهای برتر حذف می‌کند. سپس الگوریتم رتبه صفحه شخصی‌سازی‌شده^۳ با وزن‌دهی اولیه به گره‌های عبارتی و متنی اجرا می‌شود و قطعه‌ها بر اساس امتیاز نهایی رتبه‌بندی می‌گردند. خروجی بازیاب در این روش خود گراف نیست، بلکه قطعه‌های متنی برتری است که برای پاسخ‌گویی به مدل زبانی داده می‌شوند.

این طراحی، بازیابی واقعیت‌های مستقیم و پیوندهای چندگامی میان قطعه‌ها را در یک فرایند واحد دنبال می‌کند. با این حال، بخشی از هزینه در زمان ساخت گراف و اجرای مدل زبانی برای استخراج سه‌تایی‌ها صرف می‌شود و مرحله پالایش برخط نیز یک فراخوانی اضافی ایجاد می‌کند. در نتیجه، هنگام ارزیابی HippoRAG 2 باید هزینه آماده‌سازی نمایه از هزینه هر پرسش جدا شود. کیفیت سه‌تایی‌های استخراج‌شده و نحوه تنظیم وزن آغازین گره‌ها نیز بر رتبه نهایی قطعه‌ها اثر می‌گذارند.

روش LinearRAG مسیر سبک‌تری برای ساخت گراف از متن در نظر می‌گیرد و به جای استخراج رابطه، سه نوع گره موجودیت، جمله و قطعه متن را در ساختاری به نام Tri-Graph به هم متصل می‌کند [۱۲]. بازیابی آن در دو مرحله انجام می‌شود: ابتدا موجودیت‌های مرتبط از طریق پیوندهای معنایی فعال می‌شوند و سپس اهمیت قطعه‌ها با انتشار امتیاز روی گراف محاسبه می‌گردد. این روش از جزئیات رابطه

^۲ Open Information Extraction (OpenIE)

^۳ Personalized PageRank (PPR)

صرف نظر می‌کند تا ساخت نمایه ساده‌تر و کم‌هزینه‌تر باشد. با توجه به دامنه این پایان‌نامه، LinearRAG بیشتر به عنوان نمونه‌ای از گراف‌سازی بدون رابطه صریح در نظر گرفته می‌شود و بررسی اصلی بر دو روش پیشین متمرکز خواهد بود.

در مجموع، G-Retriever گراف را ورودی مسئله فرض می‌کند و یک زیرگراف متصل تحویل می‌دهد، در حالی که HippoRAG 2 و LinearRAG ابتدا از پیکره متنی ساختار گرافی می‌سازند و در پایان قطعه‌های متن را بازیابی می‌کنند. تفاوت دیگر در سازوکار انتخاب است: اولی از بهینه‌سازی اتصال زیرگراف استفاده می‌کند و دو روش دیگر امتیاز را روی گراف منتشر می‌سازند. این تفاوت‌ها بر نوع داده مورد نیاز، هزینه نمایه‌سازی، امکان مشاهده مسیر بازیابی و حجم اطلاعات ورودی مدل اثر دارند. بخش بعد، خانواده عامل‌محور را بررسی می‌کند که در آن مدل زبانی در انتخاب گام‌های پیمایش نقش مستقیم‌تری دارد.

۶-۲ روش‌های گرافی عامل‌محور: سازوکار و ویژگی‌ها

در روش‌های عامل‌محور، مدل زبانی در یک چرخه جست‌وجو و ارزیابی شواهد قرار می‌گیرد. پرس‌وجو از گراف، همسایه‌ها و روابط موجود را مشخص می‌کند و مدل از میان این گزینه‌ها، ادامه‌های مرتبط با پرسش را برمی‌گزیند. پس از هر مرحله، اطلاعات گردآوری‌شده برای پاسخ‌گویی بررسی می‌شوند و در صورت ناکافی بودن، کاوش ادامه می‌یابد. دو روش ToG و ToG-2 این الگو را به ترتیب با تکیه بر مسیرهای گرافی و با ترکیب گراف و متن به کار می‌گیرند.

روش ToG جست‌وجو را از موجودیت‌های شناسایی‌شده در پرسش آغاز می‌کند و چند مسیر محتمل را به‌طور هم‌زمان نگه می‌دارد [۱۵]. این فرایند بر جست‌وجوی پرتوی^۴ استوار است؛ یعنی در هر مرحله، تنها تعداد محدودی از مسیرهای برتر برای گسترش بعدی حفظ می‌شوند. دو پارامتر اصلی، عرض جست‌وجو و بیشینه عمق هستند: اولی تعداد مسیرهای نگه‌داشته‌شده و دومی حداکثر تعداد گام‌های پیمایش را تعیین می‌کند. این محدودیت‌ها اندازه فضای جست‌وجو و هزینه تعامل با مدل را کنترل می‌کنند.

کاوش در ToG دو مرحله دارد. ابتدا روابط متصل به انتهای هر مسیر از گراف خوانده می‌شوند و مدل، روابط مرتبط با پرسش را امتیازدهی و انتخاب می‌کند. سپس موجودیت‌های متصل از طریق روابط

^۴ Beam Search

منتخب بازیابی می‌شوند و مدل از میان آن‌ها نامزدهای مناسب را برمی‌گزینند. بدین ترتیب، مسیرهای باقی‌مانده با یک سه‌تایی جدید گسترش می‌یابند. انتخاب رابطه پیش از موجودیت، تعداد نامزدهایی را که مدل باید بررسی کند کاهش می‌دهد؛ جهت یال نیز در بازیابی همسایه‌ها لحاظ می‌شود.

پس از گسترش مسیرها، مدل بررسی می‌کند که آیا اطلاعات موجود برای پاسخ کافی است. در صورت کفایت، پاسخ با استفاده از پرسش و مسیرها تولید می‌شود و در غیر این صورت، چرخه تا رسیدن به حد عمق ادامه می‌یابد. در نسخه اصلی، اگر جست‌وجو در این حد نیز شواهد کافی نیابد، پاسخ با اتکا به دانش درونی مدل تولید می‌شود. این حالت باید هنگام ارزیابی از پاسخ‌های متکی بر مسیر تفکیک شود. مسیرهای صریح، امکان مشاهده و بازبینی روابط پیموده‌شده را فراهم می‌کنند؛ اجرای روش نیز به تنظیم مجدد پارامترهای مدل زبانی نیاز ندارد.

روش ToG-2 همین جهت‌گیری تعاملی را با اسناد متنی متصل به موجودیت‌ها گسترش می‌دهد [۱۱]. پس از پیونددهی موجودیت‌های پرسش و انتخاب نقطه‌های شروع، ابتدا قطعه‌هایی از اسناد مرتبط بازیابی می‌شوند. اگر همین اطلاعات برای پاسخ کافی باشند، نیازی به پیمایش بیشتر نیست. در غیر این صورت، جست‌وجوی روابط و موجودیت‌های همسایه آغاز می‌شود تا منابع متنی تازه‌ای در دسترس قرار گیرند. در این طراحی، گراف محدوده بازیابی را هدایت می‌کند و متن، جزئیاتی را فراهم می‌سازد که لزوماً در سه‌تایی‌ها ثبت نشده‌اند.

تعامل متن و گراف در ToG-2 دوطرفه است. قطعه‌های مربوط به موجودیت‌های نامزد با در نظر گرفتن پرسش و رابطه‌ای که به آن‌ها منتهی شده رتبه‌بندی می‌شوند. سپس امتیاز قطعه‌ها برای انتخاب موجودیت‌های مرحله بعد به کار می‌رود؛ بنابراین، ادامه پیمایش فقط بر نام موجودیت یا رابطه متکی نیست. در پایان هر دور، مسیرها، قطعه‌های برتر و سرنخ‌های مراحل پیشین به مدل داده می‌شوند. مدل یا پاسخ را تولید می‌کند، یا سرنخ‌های مفید را خلاصه می‌سازد و با بازتنظیم پرسش، جست‌وجو را تا حد تعیین‌شده ادامه می‌دهد.

در مجموع، ToG ساختاری ساده‌تر برای کاوش مسیرهای دانشی فراهم می‌کند و ToG-2 از متن برای تکمیل شواهد و هدایت دقیق‌تر کاوش بهره می‌گیرد. استفاده از نسخه دوم مستلزم ارتباط مشخص میان گراف و اسناد است و کیفیت این پیوندها بر بازیابی اثر دارد. در هر دو روش، افزایش عرض یا عمق می‌تواند شواهد بیشتری در دسترس قرار دهد، اما هزینه و زمان پاسخ را نیز تغییر می‌دهد. برای مقایسه در این پایان‌نامه، مسیرهای پیموده‌شده، شرط توقف، تعداد فراخوانی‌ها و شواهد نهایی ثبت خواهند شد تا کیفیت پاسخ در کنار نحوه دستیابی به آن بررسی شود.

۷-۲ مقایسه روش‌های بازیابی محور و عامل محور

تفاوت اصلی این دو خانواده در نحوه هدایت جست‌وجو است. در روش‌های بازیابی محور، الگوریتم بازیابی بر اساس پرسش، شواهد را انتخاب می‌کند و سپس آن‌ها را به مولد می‌سپارد. در روش‌های عامل محور، مدل زبانی با مشاهده شواهد هر مرحله درباره ادامه پیمایش و کافی بودن اطلاعات تصمیم می‌گیرد. بنابراین، صرف استفاده از مدل زبانی در ساخت گراف یا پالایش نامزدها، یک روش را عامل محور نمی‌کند؛ برای نمونه، مرحله بازشناسی در HippoRAG 2 بخشی از فرایند بازیابی است، اما در ToG-2 تصمیم‌های مدل بر ادامه کاوش گراف و متن اثر می‌گذارند [۱۱، ۱۳].

از نظر پوشش شواهد، بازیابی محور بودن به معنای محدود شدن به روابط مستقیم نیست. انتشار امتیاز در گراف یا استخراج یک زیرگراف متصل می‌تواند اطلاعات چندگامی را نیز گردآوری کند. مزیت روش عامل محور، امکان هدایت مرحله بعد با توجه به یافته‌های مرحله قبل است؛ این ویژگی زمانی مفید است که مفهوم واسط از ابتدا آشکار نباشد. در مقابل، انتخاب نامناسب یک رابطه یا حذف زودهنگام یک موجودیت می‌تواند ادامه جست‌وجو را محدود کند. در هر دو خانواده، پوشش گراف و کیفیت شناسایی مفاهیم اولیه بر شواهد قابل دسترس اثر دارند.

در توضیح‌پذیری نیز باید میان «شواهد انتخاب‌شده»، «مسیر پیمایش» و «توضیح پاسخ» تمایز گذاشت. زیرگراف خروجی G-Retriever نشان می‌دهد چه اطلاعاتی در اختیار مدل بوده است و مسیرهای ToG ترتیب روابط دنبال‌شده را آشکار می‌کنند [۱۴، ۱۵]. این آثار ثبت‌شده بازبینی پاسخ را آسان‌تر می‌کنند، اما به تنهایی نشان نمی‌دهند که تمام ادعاهای توضیح از همان شواهد نتیجه شده‌اند. همچنین، وجود یک مسیر در گراف با مرتبط بودن آن به پرسش یکسان نیست. از این رو، ردیابی‌پذیری جست‌وجو و وفاداری توضیح باید جداگانه ارزیابی شوند.

هزینه اجرا نیز به پیاده‌سازی هر روش وابسته است. در روش‌های بازیابی محور، بخشی از هزینه به ساخت نمایه یا آموزش مؤلفه گراف اختصاص دارد؛ روش‌های عامل محور معمولاً با افزایش گام‌های کاوش، فراخوانی‌های بیشتری در زمان پاسخ‌گویی دارند. تعداد فراخوانی به‌تنهایی معیار کافی نیست و طول ورودی و خروجی، اندازه مدل و زمان پردازش گراف نیز باید ثبت شوند. در مقایسه این پژوهش، داده و منابع دانش مشترک خواهند بود و تفاوت‌های لازم در نمایش گراف، آموزش و بودجه جست‌وجو گزارش می‌شوند. نتیجه مورد انتظار، مشخص شدن تناسب هر روش با نوع وظیفه و منابع در دسترس است؛ رتبه‌بندی نهایی به نتایج آزمایش‌ها وابسته خواهد بود.

۸-۲ استدلال مقید به گراف: روش GCR

روش GCR قید ساختاری را در زمان تولید مسیر اعمال می‌کند: مدل فقط می‌تواند دنباله‌ای بسازد که با یکی از مسیرهای مجاز گراف سازگار باشد [۱۶]. این روش، الگویی مستقل برای استدلال روی گراف دانش است و نباید آن را نسخه بعدی ToG-2 تلقی کرد. ارتباط آن با بحث پیشین در این است که انتخاب مسیر و تولید نمایش زبانی آن را به یکدیگر پیوند می‌دهد. چارچوب اصلی سه مرحله دارد: ساخت نمایه مسیرها، تولید مقید مسیر و پاسخ‌های نامزد، و ترکیب آن‌ها برای رسیدن به پاسخ نهایی. در مرحله نخست، موجودیت‌های مطرح‌شده در پرسش به گراف پیوند داده می‌شوند و مسیرهای آغازشده از آن‌ها تا عمقی مشخص استخراج می‌گردند. مقاله برای این کار از جست‌وجوی سطح‌اول استفاده می‌کند. مسیرها پس از تبدیل به رشته‌های قالب‌بندی‌شده و نشانه‌های زبانی، در یک درخت پیشوندی^۵ با نام KG-Trie ذخیره می‌شوند. پیشوندهای مشترک تنها یک بار در این ساختار قرار می‌گیرند و برای هر دنباله ناقص، ادامه‌های مجاز قابل بازیابی‌اند. بنابراین، نمایه شامل مسیرهای انتخاب‌شده در محدوده جست‌وجو است و لازم نیست همه مسیرهای ممکن گراف را در بر گیرد.

در مرحله رمزگشایی مقید^۶، مدل زبانی احتمال نشانه بعدی را محاسبه می‌کند، اما تنها نشانه‌هایی امکان انتخاب دارند که ادامه‌ای معتبر در KG-Trie بسازند. این قید در طول تولید مسیر حفظ می‌شود تا رابطه یا موجودیتی خارج از مسیرهای نمایه‌شده وارد آن نشود. پس از پایان مسیر، رمزگشایی عادی برای تولید یک پاسخ نامزد از سر گرفته می‌شود. در نتیجه، دامنه قید ساختاری مشخص است: قید مستقیماً بر مسیر اعمال می‌شود و تمام متن پاسخ را در بر نمی‌گیرد.

در طراحی مقاله، یک مدل زبانی سبک‌تر با نمونه‌های پرسش، مسیر و پاسخ برای این مرحله تنظیم می‌شود. سپس چند مسیر و پاسخ نامزد با جست‌وجوی پرتوی تولید و به یک مدل زبانی عمومی داده می‌شوند تا پاسخ نهایی را با استفاده از آن‌ها بسازد. مدل تخصصی، انتخاب مسیرهای مرتبط را می‌آموزد و مدل عمومی ترکیب شواهد را انجام می‌دهد. این تفکیک نیازمند دسترسی به فرایند رمزگشایی مدل نخست است؛ از این رو، امکانات اجرایی آن با روشی که صرفاً از طریق ارسال درخواست متنی به مدل کار می‌کند متفاوت است.

تعبیر «نبود توهم» در این مقاله به انطباق کامل مسیر تولیدشده با گراف اشاره دارد. این ویژگی برای کنترل روابط ساختگی مفید است، اما صحت خود گراف، ارتباط مسیر با پرسش یا درستی پاسخ نهایی

^۵Trie

^۶Constrained Decoding

را تضمین نمی‌کند. گراف ناقص، پیونددهی نادرست موجودیت‌ها و محدودیت عمق جست‌وجو همچنان می‌توانند شواهد لازم را از دسترس خارج کنند. افزون بر این، توضیح نهایی ممکن است برداشتی فراتر از مسیرها داشته باشد. بنابراین، در انطباق با سلامت روان، اعتبار ساختاری مسیر و پشتیبانی ادعاهای توضیح از متن ورودی دو موضوع مجزا خواهند بود.

آزمایش‌های مقاله عمدتاً بر پرسش و پاسخ گراف دانش انجام شده‌اند و قابلیت انتقال به گراف‌های دیگر نیز بررسی شده است. این نتایج مبنایی برای انتخاب GCR در مقایسه حاضر فراهم می‌کنند، اما عملکرد آن روی وظایف IMHI باید مستقلاً سنجیده شود. هزینه ساخت KG-Trie، تنظیم مدل تخصصی و اجرای دو مدل نیز در تحلیل کارایی منظور خواهد شد تا کاهش احتمالی رفت‌وبرگشت‌های جست‌وجو در کنار هزینه آماده‌سازی و تولید پاسخ بررسی شود.

۹-۲ کاربرد در سلامت روان و مبنای ارزیابی

کاربرد روش‌های مرور شده در این پژوهش، تولید برچسب و توضیح برای متن‌های سلامت روان است. در این وظیفه، پاسخ معمولاً یک موجودیت انتهایی در گراف نیست و باید با مجموعه برچسب‌های هر داده هماهنگ شود. مجموعه IMHI چنین مسئله‌ای را در قالب دستور و پاسخ سازمان‌دهی می‌کند و مبنای آموزش و ارزیابی مدل‌های MentalLLaMA بوده است [۱۰]. وظایف منتخب شامل تشخیص استرس در Dreddit، طبقه‌بندی وضعیت در T-SID، شناسایی عامل استرس در SAD و بررسی ابعاد بهزیستی در MultiWD هستند. این تنوع، امکان مقایسه روش‌ها در طبقه‌بندی دودویی و چندکلاسه، شناسایی عامل و تشخیص ابعاد بهزیستی را فراهم می‌کند.

در انتقال روش‌ها به این وظایف، متن فرد و دانش دامنه‌ای نقش‌های متفاوتی دارند. متن مشخص می‌کند چه تجربه یا نشانه‌ای گزارش شده است و گراف، روابط دانشی مربوط به مفاهیم آن را فراهم می‌کند. یک رابطه عمومی در گراف نمی‌تواند به‌تنهایی شهادی بر وجود همان وضعیت در فرد باشد. برای مثال، اگر متن فقط به دشواری خواب اشاره کند، وجود روابط مربوط به خستگی در گراف مجوز نسبت دادن خستگی گزارش‌نشده به نویسنده نیست. بنابراین، حفظ بافت، نفی و میزان قطعیت عبارت‌ها در استخراج مفاهیم و تولید توضیح اهمیت دارد.

ارزیابی برچسب‌ها با دقت، بازخوانی^۷ و امتیاز F1 انجام خواهد شد. دقت نسبت نمونه‌های درست

پیش‌بینی شده به همه نمونه‌های پیش‌بینی شده برای یک کلاس است و بازخوانی نسبت نمونه‌های درست شناسایی شده به همه نمونه‌های واقعی همان کلاس را نشان می‌دهد. امتیاز F1 میانگین هماهنگ دقت و بازخوانی است و زمانی بالا خواهد بود که هر دو معیار هم‌زمان مقدار مناسبی داشته باشند. برای یک کلاس، این معیارها به صورت زیر تعریف می‌شوند:

(۱-۲)

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}.$$

در این روابط، TP نمونه‌های مثبت درست، FP نمونه‌های منفی که به اشتباه مثبت تشخیص داده شده‌اند و FN نمونه‌های مثبت از دست رفته هستند. برای مجموعه‌های چند کلاسه، میانگین وزن دار هر معیار با وزن متناسب با تعداد نمونه‌های واقعی هر کلاس محاسبه می‌شود:

$$M_{\text{weighted}} = \sum_{c=1}^C \frac{n_c}{N} M_c, \quad (2-2)$$

که در آن M می‌تواند دقت، بازخوانی یا F1 کلاس c باشد؛ n تعداد نمونه‌های آن کلاس و N تعداد کل نمونه‌هاست. بنابراین، علاوه بر امتیازهای وزن دار، نتیجه هر کلاس نیز گزارش می‌شود تا ضعف عملکرد روی کلاس‌های کم‌نمونه پنهان نماند. این معیارها توافق خروجی با برچسب‌های مجموعه داده را می‌سنجند و نباید معادل اعتبار تشخیص بالینی تفسیر شوند.

برای توضیح‌ها، کیفیت کلی متن و پشتیبانی ادعاها جداگانه بررسی می‌شوند. در امتداد طرح پروپوزال، BERTScore برای سنجش شباهت معنایی توضیح تولیدشده به توضیح مرجع در نظر گرفته می‌شود؛ این معیار با مقایسه نمایش‌های برداری واژه‌ها، میزان هم‌پوشانی معنایی دو متن را برآورد می‌کند. توضیح‌های مرجع IMHI با کمک مدل زبانی تولید و ارزیابی شده‌اند، بنابراین شباهت به آن‌ها به تنهایی شاهد صحت همه ادعاها نیست. تطابق با متن فرد و دانش پشتیبان باید مستقل از این امتیاز سنجیده شود.

چارچوب GraphEval برای این بررسی، خروجی مدل را به سه تایی‌های ادعایی تبدیل می‌کند و سازگاری هر سه تایی را با متن پشتیبان، با استفاده از مدل استنتاج زبان طبیعی، می‌سنجد [۲۲]. سه تایی‌های ناسازگار نیز مشخص می‌شوند تا محل خطا قابل بازبینی باشد. در کاربرد حاضر، ادعاهای مربوط به فرد باید با متن ورودی و ادعاهای دانشی با منابع دامنه‌ای مربوط بررسی شوند. این سازوکار

با کنترل وجود یال‌های مسیر در گراف تفاوت دارد و نتیجه آن به دقت استخراج ادعا و ارزیاب وابسته است. نمونه‌هایی از خطاها نیز برای بررسی نفی، ابهام و تعمیم فراتر از شواهد به صورت کیفی تحلیل خواهند شد.

محور سوم، زمان پاسخ از دریافت ورودی تا تولید برچسب و توضیح، و مجموع نشانه‌های ورودی و خروجی در تمام فراخوانی‌هاست. هزینه ساخت گراف، نمایه‌سازی و آموزش از هزینه هر نمونه جدا گزارش می‌شود. استفاده از تقسیم‌های داده یکسان، حفظ مرز آموزش و آزمون و مشخص کردن بودجه منابع هر روش، مبنای مقایسه خواهد بود. این چارچوب نشان می‌دهد هر روش با چه هزینه‌ای به چه کیفیتی در برچسب و توضیح می‌رسد.

مرور این فصل نشان داد که روش‌های منتخب، نقش‌های متفاوتی به گراف می‌دهند: انتخاب شواهد در روش‌های بازیابی‌محور، هدایت جست‌وجوی مرحله‌ای در روش‌های عامل‌محور و محدود کردن تولید مسیر در GCR. این تفاوت‌ها مبنای بازیاده‌سازی و ارزیابی مشترک در سلامت روان خواهند بود. هدف آزمایش‌ها، سنجش اثر هر سازوکار بر درستی برچسب، پشتیبانی توضیح و هزینه اجراست. فصل بعد، جزئیات داده‌ها، آماده‌سازی گراف و پروتکل اجرای این مقایسه را مشخص می‌کند.

فصل سوم

چارچوب و پیاده‌سازی روش‌ها

۳-۱ چارچوب مشترک آزمایش‌ها

این پژوهش برای مقایسه روش‌های مختلف، یک چارچوب مشترک برای ورود داده، دسترسی به دانش و ثبت خروجی‌ها تعریف می‌کند. هدف از این چارچوب آن است که همه روش‌ها روی نمونه‌ها و منابع یکسان اجرا شوند و تفاوت نتایج تا حد امکان به شیوه‌بازیابی و استدلال هر روش مربوط باشد. آزمایش‌ها روی دو مجموعه داده DR و SWMH انجام شده‌اند و در اجرای نهایی به ترتیب ۷۰ و ۶۵ نمونه از آن‌ها بررسی شده است.

مدل زبانی اصلی همه آزمایش‌ها Gemma 4 31B است. این مدل به دلیل توانایی تولید پاسخ متنی و پشتیبانی از دستورهای ساختاریافته، برای تولید برچسب و توضیح در تمام روش‌ها به صورت یکسان به کار گرفته شده است. مشخصات معماری و ارزیابی‌های این خانواده مدل در گزارش فنی منتشرشده توسط Google DeepMind ارائه شده است [۲۳].

برای تعریف دقیق ورودی‌ها و خروجی‌های مورد انتظار هر فراخوانی مدل زبانی، از چارچوب DSPy استفاده شده است. این چارچوب امکان می‌دهد مشخصات هر فراخوانی به صورت ساختاریافته تعریف شود و پاسخ مدل نیز در قالبی قابل پردازش و بررسی دریافت گردد؛ بنابراین، ثبت خروجی‌ها و کنترل قالب پاسخ در همه روش‌ها یکسان انجام می‌شود. مستندات رسمی این چارچوب در پاورقی آمده است.^۱ برای تبدیل متن پرسش، نام موجودیت‌ها و قطعه‌های متنی به نمایش عددی، از مدل jina-embeddings-v4 استفاده شده است. این مدل بازنمایی برداری امکان مقایسه معنایی متن‌ها در فضای برداری را فراهم می‌کند و مبنای پیونددهی موجودیت‌ها و رتبه‌بندی شواهد متنی قرار می‌گیرد. جزئیات فنی مدل و ارزیابی‌های آن در مقاله معرفی Jina Embeddings v4 گزارش شده است [۲۴].

سه مؤلفه زیرساختی در همه روش‌ها مشترک‌اند. OpenRouter واسطه دسترسی به مدل زبانی است و درخواست‌های تولید پاسخ را به مدل انتخاب‌شده ارسال می‌کند. PostgreSQL برای نگهداری ساختار گراف، موجودیت‌ها، روابط و ارتباط آن‌ها با قطعه‌های منبع استفاده می‌شود. Milvus نیز پایگاه نمایه‌سازی برداری است و بردارهای موجودیت‌ها و قطعه‌های متنی را برای جست‌وجوی شباهت در اختیار روش‌ها قرار می‌دهد. جزئیات ساخت این گراف و نمایه‌های برداری در بخش بعدی توضیح داده می‌شود.

جریان مشترک اجرای هر نمونه با خواندن متن و برچسب واقعی از فایل مجموعه داده آغاز می‌شود. متن همراه با دستور مسئله و فهرست کامل کلاس‌های مجاز در اختیار روش قرار می‌گیرد. روش بر اساس

^۱مستندات رسمی چارچوب DSPy: dspy.ai

سازوکار خود، شواهد را از متن، نمایه برداری یا گراف بازیابی می‌کند و سپس مدل زبانی را برای انتخاب دقیقاً یک برچسب از میان کلاس‌های مجاز به کار می‌گیرد. علاوه بر برچسب، مدل باید توضیحی متنی درباره دلیل تصمیم ارائه کند. این توضیح در روش‌های گرافی و بازیابی‌محور باید تا حد امکان به شواهد انتخاب‌شده متکی باشد.

خروجی هر اجرا در قالب یک گزارش ردیابی ساختاریافته ذخیره می‌شود. این گزارش شامل متن و شناسه نمونه، برچسب واقعی، برچسب پیش‌بینی‌شده، توضیح، شواهد بازیابی‌شده و تصمیم‌های اصلی روش است. برای روش‌های مرحله‌ای، موجودیت‌ها، روابط، مسیرها، نامزدهای نگه‌داشته‌شده و موارد حذف‌شده نیز ثبت می‌شوند. در کنار اطلاعات محتوایی، تعداد نشانه‌های ورودی و خروجی مدل زبانی و زمان هر فراخوانی و زمان کل اجرا ذخیره می‌شود. در صورت تولید پاسخ خارج از قالب یا بروز خطای زیرساختی، وضعیت خطا نیز جداگانه ثبت می‌گردد.

برای حفظ مقایسه‌پذیری، کلاس‌های مجاز، متن ورودی، گراف دانش، نمایه‌های برداری، مدل بازنمایی برداری، مدل زبانی و قالب ارزیابی میان روش‌ها ثابت نگه داشته شده‌اند. تفاوت روش‌ها در مؤلفه‌ای است که شواهد را انتخاب و سازمان‌دهی می‌کند: برخی روش‌ها مستقیماً از متن استفاده می‌کنند، برخی قطعه‌های برداری را بازیابی می‌کنند و روش‌های گراف‌محور از روابط و مسیرهای گرافی نیز بهره می‌گیرند. بنابراین، چارچوب مشترک امکان می‌دهد اثر این تفاوت‌ها بر پیش‌بینی، توضیح‌پذیری و هزینه اجرا در فصل نتایج مقایسه شود.

۲-۳ ساخت گراف دانش و نمایه‌سازی برداری

منبع محتوایی گراف دانش، دو کتاب مرجع DSM-5-TR و DSM-5-TR Made Easy است. کتاب نخست، ویرایش بازنگری‌شده راهنمای تشخیصی و آماری اختلالات روانی است که طبقه‌بندی اختلالات، ملاک‌های تشخیصی و ویژگی‌های مرتبط با آن‌ها را ارائه می‌کند [۲۵]. کتاب دوم راهنمای بالینی تشخیص بر پایه همین ویرایش است و مفاهیم و ملاک‌های اختلالات را با بیانی کاربردی‌تر برای استفاده متخصصان توضیح می‌دهد [۲۶].

استخراج مفاهیم، موجودیت‌ها و روابط با روش KGGen انجام شده است [۲۱]. از آنجا که بازیابی شواهد متنی در زمان پاسخ‌گویی نیز ضروری است، ارتباط هر واقعیت گرافی با قطعه متنی منبع آن حفظ شده است. در نتیجه، هر رابطه علاوه بر دو موجودیت و نوع رابطه، به قطعه یا قطعه‌های متنی پشتیبان

نیز متصل می‌ماند.

برای هر موجودیت، افزون بر متن نام یا توضیح آن، نوع موجودیت نیز در گراف ذخیره شده است. در مجموع دوازده نوع برای سازمان‌دهی محتوای DSM در نظر گرفته شده است. چهار نوع اصلی شامل نشانه، مفهوم، اختلال و رفتار هستند و هشت نوع کمکی شامل ملاک تشخیصی، مشخصه، مدت، بیمار یا گروه هدف، برچسب نمونه، کد تشخیصی، موجودیت حل‌نشده و عنوان بخش می‌شوند. چهار نوع اصلی برای جست‌وجوی معنایی و پیمایش گراف نگه داشته شده‌اند، زیرا محتوای آن‌ها قابل مقایسه با پرسش است؛ در مقابل، نوع‌هایی مانند کد تشخیصی یا نام بیمار بیشتر نقش ساختاری و توصیفی دارند.

ساختار گراف در چهار جدول PostgreSQL نگهداری می‌شود. جدول entities شناسه، متن و نوع هر موجودیت را ذخیره می‌کند. جدول facts شناسه واقعیت، شناسه موجودیت مبدأ، رابطه و شناسه موجودیت مقصد را نگه می‌دارد. جدول mentions ارتباط میان هر واقعیت و قطعه‌های متن را ثبت می‌کند و جدول chunks شناسه و محتوای قطعه متنی را در خود دارد. بنابراین، مسیر گرافی و متن پشتیبان آن از طریق همین پیوندها قابل بازیابی است.

پس از یکپارچه‌سازی موجودیت‌های هم‌معنا، نام و متن موجودیت‌های نهایی متعلق به چهار نوع اصلی و همچنین متن قطعه‌های منبع با مدل jina-embeddings-v4 به بردار تبدیل شده‌اند. واقعیت‌ها، یعنی سه‌تایی‌های شامل موجودیت مبدأ، رابطه و موجودیت مقصد، نیز به صورت یک متن واحد بردارسازی شده‌اند. در نتیجه، در Milvus فقط سه مجموعه نگهداری می‌شود: موجودیت‌های نهایی چهار نوع اصلی، واقعیت‌های گراف و قطعه‌های متنی متناظر با منبع اصلی.

شناسه اصلی هر بردار در مجموعه‌های موجودیت و قطعه با شناسه متناظر در PostgreSQL یکسان است. به این ترتیب، جست‌وجوی شباهت در Milvus مستقیماً به شناسه موجودیت یا قطعه در PostgreSQL برمی‌گردد و جزئیات رابطه، مسیر گرافی و متن منبع از پایگاه رابطه‌ای خوانده می‌شود.

۳-۳ پیاده‌سازی روش‌های مورد مقایسه

۱-۳-۳ زنجیره فکر (CoT)

روش زنجیره فکر یکی از روش‌های پایه برای پاسخ‌گویی مستقیم به پرسش است. در این روش، مدل زبانی پیش از اعلام برچسب نهایی، مسئله را مرحله‌به‌مرحله بررسی می‌کند و سپس بر اساس همان بررسی، پاسخ و توضیح خود را تولید می‌کند. در این پژوهش، این روش بدون استفاده از گراف دانش یا بازیابی قطعه‌های متنی اجرا شده و نقش خط پایه را برای مقایسه با روش‌های بازیابی‌محور و گراف‌محور دارد.

برای پیاده‌سازی، از شیء ChainOfThought در چارچوب DSPy استفاده شد. مشخصات فراخوانی، شامل متن پرسش، مجموعه کامل برچسب‌های مجاز و قالب پاسخ، در یک امضای ساختاریافته تعریف شد و شیء یادشده این امضا را به فراخوانی مدل زبانی تبدیل کرد. خروجی نهایی شامل یک برچسب از میان گزینه‌های مجاز و توضیح متنی تصمیم است؛ بنابراین، پاسخ روش مستقیماً در قالب قابل ثبت در گزارش ردیابی ذخیره می‌شود و نیاز به پردازش دستی متن آزاد کاهش می‌یابد.

۲-۳-۳ Vanilla RAG

بازیابی تقویت‌شده با تولید، روشی است که پیش از پاسخ‌گویی مدل زبانی، قطعه‌های مرتبط با پرسش را از نمایه برداری بازیابی می‌کند و آن‌ها را به‌عنوان زمینه در اختیار مدل قرار می‌دهد. در این پژوهش، نسخه پایه این روش بدون استفاده از روابط گراف‌اف اجرا شد و تصمیم مدل فقط بر اساس پرسش و متن‌های بازیابی‌شده انجام گرفت.

برای همه نمونه‌ها، مقدار $k = 8$ در نظر گرفته شد؛ بنابراین، هشت قطعه متنی برتر به‌عنوان زمینه به دستور نهایی مدل زبانی افزوده شدند. افزون بر برچسب و توضیح، در خروجی این روش فیلد جداگانه‌ای برای ثبت شناسه قطعه‌هایی قرار گرفت که مدل در توضیح خود به آن‌ها استناد کرده است. این اطلاعات امکان شمارش میزان استفاده از هر قطعه در پاسخ‌ها و بررسی اعتبار استندهای مدل در مراحل بعدی را فراهم می‌کند.

۳-۳-۳ HippoRAG 2

در این روش، ابتدا مدل زبانی از متن پرسش حداکثر ۵ سه‌تایی شامل موجودیت مبدأ، رابطه و موجودیت مقصد را استخراج می‌کند. سپس متن هر سه‌تایی بردارسازی می‌شود و برای هر سه‌تایی، حداکثر ۳

واقعیت مرتبط از مجموعه واقعیت‌های گراف بازیابی می‌شود. واقعیت‌های بازیابی شده در ادامه با کمک مدل زبانی پالایش می‌شوند و موجودیت‌ها و قطعه‌های متنی حاصل، زمینه مرحله رتبه‌بندی را تشکیل می‌دهند.

در نسخه حاضر، رتبه‌بندی شخصی‌سازی شده یا PPR با پارامترهای تعیین شده برای این آزمایش انجام می‌شود. پارامترهای این مرحله شامل تعداد واقعیت‌های نگه‌داشته شده پس از پالایش، تعداد موجودیت‌های نهایی، تعداد قطعه‌های متنی زمینه، ضریب میرایی، شرط همگرایی و حداکثر تعداد تکرارها هستند. در این گزارش، حداکثر 10^6 قطعه در زمینه، ضریب میرایی 0.8، شرط همگرایی 10^{-6} و حداکثر 10^6 تکرار در نظر گرفته شده است.

پس از رتبه‌بندی، هشت قطعه برتر با همان امضای پاسخ‌گویی روش Vanilla RAG به مدل زبانی داده می‌شوند. بنابراین، خروجی نهایی شامل برچسب، توضیح و شناسه قطعه‌های استناد شده است؛ این بخش در عمل با مرحله نهایی Vanilla RAG یکسان است. امضاها کامل فراخوانی‌های ساختاریافته در پیوست «دستورهای مدل» ارائه می‌شوند.

۴-۳-۳ ToG-1

روش ToG-1 با پیمایش مرحله‌ای گراف دانش، موجودیت‌ها و روابط مرتبط با پرسش را گسترش می‌دهد و در هر مرحله شواهد تازه‌ای برای تصمیم‌گیری مدل زبانی فراهم می‌کند. این روش در آزمایش حاضر به عنوان یکی از روش‌های گراف‌محور اصلی با عرض و عمق جست‌وجوی برابر با ۵ اجرا شد.

در آغاز، مدل زبانی حداکثر 10^6 نام موجودیتی را از پرسش استخراج می‌کند. برای هر نام، سه نامزد نزدیک در Milvus بازیابی می‌شود. انتخاب گره‌های آغازین با یک سازوکار ترکیبی انجام می‌گیرد: ابتدا از فهرست نامزدهای هر موجودیت یک مورد انتخاب می‌شود تا هر موجودیت استخراج شده سهمی در مجموعه داشته باشد؛ سپس در دورهای بعدی، نامزدهای رتبه‌های بعدی همه فهرست‌ها به صورت انتخاب نوبتی بررسی می‌شوند. در هر انتخاب، شناسه‌های تکراری و نام‌های تکراری حذف می‌شوند، اما اگر حذف تکرار باعث خالی ماندن یک فهرست شود، نامزد تکراری برای حفظ پوشش آن فهرست مجاز است.

ابزار پارامترهای اصلی این اجرا عبارت‌اند از: عرض جست‌وجو برابر ۵، عمق جست‌وجو برابر ۵، حداکثر 10^6 نام استخراج شده، حداکثر 10^6 موجودیت موضوعی قابل استفاده و سه نامزد برداری برای هر نام. در ادامه، در هر عمق روابط نامزد با کمک مدل زبانی پالایش می‌شوند و حداکثر به اندازه عرض جست‌وجو گسترش می‌یابند. جست‌وجو یا با رسیدن به عمق نهایی پایان می‌یابد یا زمانی متوقف می‌شود که مدل

زبانی کافی بودن شواهد برای انتخاب برچسب را اعلام کند. جزئیات امضاهای فراخوانی و متن دستورهای این مراحل در پیوست «دستورهای مدل» ارائه شده است.

ToG-2 ۵-۳-۳

روش ToG-2 نسخه‌ای زمینه‌محورتر از پیمایش گراف است که علاوه بر مسیرهای گرافی، قطعه‌های متنی مرتبط با هر مسیر را نیز در رتبه‌بندی و تصمیم‌گیری مدل زبانی وارد می‌کند. این روش با عرض ۵ و عمق ۵ اجرا شد و در هر مرحله حداکثر ۱۰ قطعه متنی برتر از میان همه مسیرهای بررسی‌شده برای تشکیل زمینه نگه داشته شد.

برخلاف ToG-1 که هرس نامزدهای اضافی را با کمک تصمیم مدل زبانی انجام می‌دهد، در ToG-2 نامزدهای حاصل از گسترش روابط با شباهت کسینوسی میان پرسش و متن ترکیبی «مسیر استدلال به‌علاوه قطعه متن» رتبه‌بندی می‌شوند. امتیاز قطعه‌ها سپس برای هر موجودیت جمع می‌شود و موجودیت‌های برتر برای ادامه پیمایش انتخاب می‌شوند. چون هر مسیر به‌صورت مستقل امتیازدهی می‌شود، یک قطعه متنی ممکن است به دلیل برتری در دو مسیر متفاوت، بیش از یک بار در فهرست زمینه ظاهر شود.

در این روش، ارزیابی کافی بودن زمینه و تولید پاسخ در یک فراخوانی ساختاریافته انجام می‌شود؛ بنابراین مدل در هر مرحله هم‌زمان اعلام می‌کند که شواهد برای انتخاب یک برچسب کافی است یا نه و در صورت کافی بودن، همان‌جا برچسب و توضیح را تولید می‌کند. افزودن تدریجی قطعه‌های متنی مرتبط باعث می‌شود مدل در مراحل ابتدایی سریع‌تر به کفایت زمینه برسد. اگر تا عمق نهایی شواهد کافی نباشد، پاسخ نهایی در مرحله جداگانه پاسخ حداقلی تولید می‌شود. متن امضاهای فراخوانی و دستورهای این روش در پیوست «دستورهای مدل» ارائه شده است.

فصل چهارم

نتایج و تحلیل مقایسه‌ای

۱-۴ آمار گراف دانش و نمایه‌سازی برداری

برای توصیف اندازه و پوشش منبع دانش، آمار گراف PostgreSQL و مجموعه‌های برداری Milvus از پایگاه مورد استفاده استخراج شد. گراف شامل ۳۲۸۰۸ موجودیت، ۶۲۰۵۸ واقعیت و ۱۰۲۸۲ قطعه متنی است. جدول زیر توزیع موجودیت‌ها را بر اساس نوع نشان می‌دهد.

جدول ۱-۴: توزیع موجودیت‌های گراف دانش بر اساس نوع

نوع موجودیت	تعداد
نشانه	۶۷۳۵
مفهوم	۶۵۳۱
ملاک تشخیصی	۴۹۴۲
مشخصه	۳۰۸۹
مدت	۲۵۹۹
موجودیت حل‌نشده	۲۱۹۲
کد تشخیصی	۲۰۷۵
اختلال	۱۶۴۲
بیمار یا گروه هدف	۱۱۱۴
برچسب نمونه	۹۲۹
رفتار	۷۰۷
عنوان بخش	۲۵۳
جمع	۳۲۸۰۸

در جدول facts تعداد ۶۲۰۵۸ رابطه ذخیره شده است و جدول mentions ارتباط این واقعیت‌ها با قطعه‌های متن را نگهداری می‌کند. در نتیجه، هر ۱۰۲۸۲ قطعه متن دست‌کم از طریق یک اشاره به واقعیت‌های گراف متصل است.

جدول ۲-۴: آمار مجموعه‌های برداری Milvus

مجموعه برداری	تعداد بردار	بُعد بردار
canonical-seed-entities-v1 موجودیت‌های نهایی	۱۳۰۸۲	۱۲۸
raw-triples-v1 واقعیت‌ها	۴۱۶۵۴	۲۵۶
source-chunks-v1 قطعه‌های منبع	۱۰۲۸۲	۱۰۲۴

بردارهای موجودیت‌های نهایی، رابطه‌های نهایی، واقعیت‌ها و قطعه‌های منبع با مدل jina-embeddings-v4 تولید شده‌اند. شناسه موجودیت‌ها و قطعه‌ها میان PostgreSQL و Milvus مشترک است؛ بنابراین، نتیجه جست‌وجوی برداری مستقیماً به رکورد گراف یا متن منبع متناظر متصل می‌شود.

۲-۴ مقایسه نتایج پیش‌بینی در مجموعه‌داده‌ها

نتایج پیش‌بینی پنج روش در دو مجموعه‌داده در جدول‌های زیر گزارش شده است. جدول ۳-۴ نتایج کلان مجموعه‌داده DR و جدول ۴-۴ نتایج کلان مجموعه‌داده SWMH را نشان می‌دهند. برای هر روش، دقت کلی و میانگین معیارهای صحت، بازخوانی و F1-score به‌صورت کلان ارائه شده‌اند. میانگین کلان با وزن برابر برای همه برچسب‌ها محاسبه شده است؛ بنابراین، اثر برچسب‌های کم‌نمونه نیز در مقایسه حفظ می‌شود.

جدول ۳-۴: مقایسه نتایج پیش‌بینی روش‌ها در مجموعه‌داده DR

روش	تعداد	دقت کلی	میانگین صحت	میانگین بازخوانی	میانگین F1-score
Vanilla RAG	۷۰	68.57%	70.81%	77.03%	67.26%
HippoRAG 2	۷۰	70.00%	71.46%	77.99%	68.56%
CoT	۷۰	80.00%	77.08%	84.72%	77.81%
ToG-1	۷۰	75.71%	74.41%	81.84%	73.78%
ToG-2	۷۰	75.71%	74.41%	81.84%	73.78%

جدول ۴-۴: مقایسه نتایج پیش‌بینی روش‌ها در مجموعه‌داده SWMH

روش	تعداد	دقت کلی	میانگین صحت	میانگین بازخوانی	F1-score میانگین
Vanilla RAG	۶۵	66.15%	78.49%	65.81%	64.80%
HippoRAG 2	۶۵	64.62%	74.22%	64.12%	65.43%
CoT	۶۵	70.77%	75.06%	70.53%	71.03%
ToG-1	۶۵	70.77%	74.31%	70.64%	71.14%
ToG-2	۶۵	82.54%	82.66%	78.59%	80.31%

در مجموع دو مجموعه‌داده، روش ToG-2 بالاترین عملکرد کلی را نشان می‌دهد و پس از آن CoT و ToG-1 قرار می‌گیرند. با این حال، عملکرد روش‌ها میان دو مجموعه‌داده یکسان نیست؛ CoT در DR بهترین نتیجه را دارد، درحالی‌که ToG-2 در SWMH برتری محسوسی نشان می‌دهد. این تفاوت در بخش تحلیل توضیح‌پذیری و هزینه اجرا نیز بررسی خواهد شد.

برای مشاهده رفتار روش‌ها در هر برچسب، معیارهای تفکیک‌شده در جدول‌های ۴-۵ و ۴-۶ آمده‌اند؛ جدول نخست مربوط به DR و جدول دوم مربوط به SWMH است. ستون پشتیبانی، تعداد نمونه‌های واقعی هر برچسب را نشان می‌دهد.

جدول ۴-۵: معیارهای تفکیک‌شده برچسب‌ها در مجموعه‌داده DR

روش	برچسب	پشتیبانی	صحت	بازخوانی	F1-score
Vanilla RAG	خیر	۱۸	44.74%	94.44%	60.71%
Vanilla RAG	بله	۵۲	96.88%	59.62%	73.81%
HippoRAG 2	خیر	۱۸	45.95%	94.44%	61.82%
HippoRAG 2	بله	۵۲	96.97%	61.54%	75.29%
CoT	خیر	۱۸	56.67%	94.44%	70.83%
CoT	بله	۵۲	97.50%	75.00%	84.78%
ToG-1	خیر	۱۸	51.52%	94.44%	66.67%
ToG-1	بله	۵۲	97.30%	69.23%	80.90%
ToG-2	خیر	۱۸	51.52%	94.44%	66.67%
ToG-2	بله	۵۲	97.30%	69.23%	80.90%

جدول ۴-۶: معیارهای تفکیک‌شده برچسب‌ها در مجموعه داده SWMH

روش	برچسب	پشتیبانی	صحت	بازخوانی	F1-score
Vanilla RAG	اضطراب	۱۴	90.91%	71.43%	80.00%
Vanilla RAG	اختلال دوقطبی	۱۲	100.00%	66.67%	80.00%
Vanilla RAG	افسردگی	۱۲	47.37%	75.00%	58.06%
Vanilla RAG	بدون اختلال روانی	۱۴	54.17%	92.86%	68.42%
Vanilla RAG	خودکشی	۱۳	100.00%	23.08%	37.50%
HippoRAG 2	اضطراب	۱۴	83.33%	71.43%	76.92%
HippoRAG 2	اختلال دوقطبی	۱۲	100.00%	58.33%	73.68%
HippoRAG 2	افسردگی	۱۲	44.44%	66.67%	53.33%
HippoRAG 2	بدون اختلال روانی	۱۴	60.00%	85.71%	70.59%
HippoRAG 2	خودکشی	۱۳	83.33%	38.46%	52.63%
CoT	اضطراب	۱۴	70.59%	85.71%	77.42%
CoT	اختلال دوقطبی	۱۲	100.00%	66.67%	80.00%
CoT	افسردگی	۱۲	50.00%	75.00%	60.00%
CoT	بدون اختلال روانی	۱۴	76.92%	71.43%	74.07%
CoT	خودکشی	۱۳	77.78%	53.85%	63.64%
ToG-1	اضطراب	۱۴	72.22%	92.86%	81.25%
ToG-1	اختلال دوقطبی	۱۲	100.00%	83.33%	90.91%
ToG-1	افسردگی	۱۲	43.75%	58.33%	50.00%
ToG-1	بدون اختلال روانی	۱۴	88.89%	57.14%	69.57%
ToG-1	خودکشی	۱۳	66.67%	61.54%	64.00%
ToG-2	اضطراب	۱۹	100.00%	94.74%	97.30%
ToG-2	اختلال دوقطبی	۶	100.00%	83.33%	90.91%
ToG-2	افسردگی	۲۰	73.91%	85.00%	79.07%
ToG-2	بدون اختلال روانی	۱۱	72.73%	72.73%	72.73%
ToG-2	خودکشی	۷	66.67%	57.14%	61.54%

۳-۴ مقایسه توضیح‌پذیری روش‌ها

برای ارزیابی توضیح‌های تولیدشده، دو دیدگاه مکمل به کار گرفته شد. نخست، شباهت معنایی توضیح تولیدشده با توضیح مرجع با استفاده از امتیازدهی مبتنی بر BERTScore بررسی شد. دوم، ادعاهای بالینی موجود در توضیح‌ها با روش «ارزیابی سازگاری ادعاهای بالینی مبتنی بر گراف دانش» بررسی شدند؛ این روش از ایده‌های چارچوب GraphEval الهام گرفته و میزان پشتیبانی ادعاهای استخراج‌شده از گراف دانش و منابع آن را اندازه‌گیری می‌کند [۲۲]. نتایج این دو ارزیابی در دو زیربخش بعدی ارائه می‌شوند.

۱-۳-۴ شباهت معنایی توضیح‌ها

در این ارزیابی، توضیح تولیدشده و توضیح مرجع هر نمونه به بردار تبدیل و شباهت کسینوسی میان دو بردار محاسبه شد. این امتیاز یک تقریب مبتنی بر بردار کل توضیح است و با نسخه اصلی BERTScore که در سطح نشانه‌ها محاسبه می‌شود تفاوت دارد. مقدار بیشتر نشان‌دهنده شباهت معنایی بالاتر با توضیح مرجع است.

جدول ۴-۷: شباهت برداری توضیح‌های تولیدشده با توضیح مرجع

روش	تعداد رکورد	میانگین امتیاز	میان امتیاز
Vanilla RAG	۱۳۵	0.7535	0.7548
HippoRAG 2	۱۳۵	0.7451	0.7551
CoT	۱۳۵	0.7774	0.7832
ToG-1	۱۳۵	0.6611	0.6751
ToG-2	۱۳۵	0.7180	0.7232

امتیاز BERTScore به‌تنهایی معیار کاملی برای ارزیابی توضیح و استدلال مبتنی بر یک دانش یا توضیح مرجع نیست، زیرا عمدتاً شباهت سطحی دو متن را بر اساس واژه‌ها و موجودیت‌های مشابه اندازه‌گیری می‌کند. در نتیجه، ممکن است دو توضیح از نظر ادعاهای مطرح‌شده کاملاً متفاوت باشند، اما به دلیل شباهت واژگانی و معنایی امتیاز بالایی بگیرند. این محدودیت، ضرورت استفاده از ارزیابی‌های ریزدانه و ناظر بر ادعاهای توضیح را نشان می‌دهد.

۴-۳-۲ ارزیابی سازگاری ادعاهای بالینی مبتنی بر گراف دانش

روش GraphEval با هدف سنجش میزان وفاداری مدل زبانی به زمینه‌ای طراحی شده است که در ورودی در اختیار آن قرار می‌گیرد. هدف این پژوهش، ارزیابی یک مدل زبانی خاص از نظر وفاداری به ورودی آن نیست؛ بلکه می‌خواهیم توضیح‌های استدلالی روش‌های مختلف را بر اساس یک دانش مرجع، مانند کتاب DSM-5-TR، ارزیابی کنیم. به همین دلیل، در روش «ارزیابی سازگاری ادعاهای بالینی مبتنی بر گراف دانش»، ابتدا توضیح مدل با کمک یک مدل زبانی به مجموعه‌ای از سه‌تایی‌های موجودیت، رابطه و موجودیت شکسته می‌شود. در همان دستور، ادعاها به دو گروه ادعاهای بالینی و ادعاهای مربوط به مورد یا نویسنده تقسیم می‌شوند؛ زیرا ممکن است مدل ادعا کند «پست‌کننده احساس نیاز به دیگران می‌کند» که ادعایی مربوط به مورد و نه یک ادعای پزشکی است، اما در جای دیگر بگوید «احساس نیاز به دیگران نشانه افسردگی است» که یک ادعای پزشکی محسوب می‌شود. ادعای دوم باید در برابر منبع مرجع، مانند کتاب DSM-5-TR، بررسی شود تا مشخص شود آیا این منبع آن را پشتیبانی می‌کند یا نه. پس از استخراج ادعاها، فقط ادعاهای بالینی در مجموعه واقعیت‌های Milvus جست‌وجو می‌شوند و برای هر ادعا سه واقعیت مشابه بازگردانده می‌شود. سپس هر ادعا همراه با سه واقعیت بازیابی‌شده

به مدل زبانی داده می‌شود تا میزان پشتیبانی واقعیت‌ها از ادعا را در بازه صفر تا ۱۰ امتیازدهی کند. در این گزارش، نرخ پشتیبانی برابر با درصد ادعاهایی است که امتیاز پشتیبانی آن‌ها بیشتر از ۵ بوده است. نتایج این امتیازدهی در جدول ۴-۸ گزارش شده‌اند. این روش نیز مانند هر روش ارزیابی دیگری محدودیت‌هایی دارد که در بخش محدودیت‌های پژوهش بررسی خواهند شد.

جدول ۴-۸: نتایج ارزیابی سازگاری ادعاهای بالینی با گراف دانش

منبع	تعداد نمونه	تعداد ادعا	ادعاهای پشتیبانی‌شده	نرخ پشتیبانی	میانگین امتیاز از ۱۰
توضیح مرجع	۱۳۵	۵۷۱	۳۸۳	67.08%	6.21
Vanilla RAG	۱۳۵	۶۶۷	۴۵۸	68.67%	6.50
HippoRAG 2	۱۳۵	۵۷۳	۴۰۴	70.51%	6.79
CoT	۱۳۵	۶۰۷	۴۲۴	69.85%	6.63
ToG-1	۱۳۵	۴۱۹	۳۳۹	80.91%	7.87
ToG-2	۱۳۵	۴۲۴	۳۰۶	72.17%	6.78

از نظر شباهت معنایی، CoT بالاترین میانگین را دارد؛ اما از نظر سازگاری ادعاهای بالینی با گراف دانش، ToG-1 بیشترین نرخ پشتیبانی و بالاترین میانگین امتیاز را نشان می‌دهد. این نتیجه بیانگر آن است که شباهت به توضیح مرجع و اتکای قابل بررسی به شواهد گرافی دو جنبه متفاوت از توضیح‌پذیری هستند.

۴-۴ مقایسه هزینه محاسباتی و زمان اجرا

برای مقایسه هزینه محاسباتی، فقط میانگین مصرف منابع در هر نمونه گزارش شده است. معیارهای بررسی‌شده شامل میانگین نشانه‌های ورودی مدل زبانی، میانگین نشانه‌های خروجی، مجموع میانگین نشانه‌ها، میانگین تأخیر اجرای نمونه و میانگین تعداد فراخوانی‌های مدل زبانی است. در محاسبه میانگین توکن، خروجی‌هایی که مقدار ثبت‌شده آن‌ها صفر بوده است کنار گذاشته شدند؛ بنابراین، مقادیر جدول بر اساس اجراهای معتبر محاسبه شده‌اند.

جدول ۴-۹: میانگین مصرف توکن، تأخیر و فراخوانی مدل زبانی در هر نمونه

روش	میانگین توکن ورودی	میانگین توکن خروجی	میانگین کل توکن	میانگین تأخیر (میلی ثانیه)	میانگین فراخوانی مدل
Vanilla RAG	2331.01	157.59	2488.59	2032.70	1.00
HippoRAG 2	5216.00	543.55	5759.55	4568.80	2.97
CoT	628.92	137.55	766.47	1545.03	1.00
ToG-1	35382.01	10672.69	46054.70	430430.81	45.90
ToG-2	9681.34	603.96	10285.30	32362.88	3.59

بر اساس جدول ۴-۹، روش CoT کمترین مصرف توکن را دارد و Vanilla RAG نیز با یک فراخوانی مدل در هر نمونه، هزینه و تأخیر محدودی ایجاد می‌کند. HippoRAG 2 به دلیل چند مرحله بازایی و پالایش، هزینه بیشتری از Vanilla RAG دارد. ToG-1 پرهزینه‌ترین روش است، زیرا در هر عمق چندین فراخوانی برای پالایش رابطه‌ها و امتیازدهی موجودیت‌ها انجام می‌دهد. ToG-2 با ادغام بخشی از تصمیم‌ها و استفاده از رتبه‌بندی متنی، نسبت به ToG-1 کاهش محسوسی در مصرف توکن و تأخیر نشان می‌دهد، هرچند همچنان از روش‌های مستقیم و بازایی پایه پرهزینه‌تر است.

تأخیر گزارش‌شده برای ToG-1 و ToG-2 بر اساس اجرای نمونه محاسبه شده است و موازی‌سازی درون هر عمق را به‌صورت کامل فرض نمی‌کند. در این دو روش، فراخوانی‌های مربوط به چند رابطه یا چند موجودیت مستقل از یکدیگرند و می‌توان آن‌ها را هم‌زمان ارسال کرد؛ در نتیجه، زمان واقعی اجرای دسته‌ای می‌تواند از جمع زمان فراخوانی‌ها کمتر باشد. برای نمونه، اگر اجرای یک نمونه به‌صورت متوالی حدود ۲۰ دقیقه طول بکشد، با اجرای موازی فراخوانی‌های مستقل می‌توان زمان دیواری را تقریباً به ۵ دقیقه کاهش داد. این مقدار یک برآورد وابسته به ظرفیت هم‌زمانی سرویس، محدودیت نرخ درخواست و زمان کندترین فراخوانی است و به‌عنوان مقدار قطعی گزارش نمی‌شود.

۴-۵ جمع‌بندی

نتایج نشان دادند که عملکرد روش‌ها به مجموعه داده و نوع برچسب وابسته است و در این مقایسه، ToG-2 در نتایج کلی و CoT در شباهت معنایی توضیح‌ها عملکرد برجسته‌ای داشتند. روش‌های گراف‌محور، به‌ویژه ToG-1، در پشتیبانی ادعاهای بالینی با شواهد مرجع موفق‌تر بودند، اما هزینه محاسباتی و زمان اجرای بیشتری داشتند. در مقابل، روش‌های مستقیم و بازایی پایه سریع‌تر و کم‌هزینه‌تر بودند و این فصل موازنه میان دقت، توضیح‌پذیری و هزینه اجرا را نشان داد.

فصل پنجم

جمع‌بندی، محدودیت‌ها و مسیرهای آینده

۱-۵ مرور پژوهش انجام‌شده

این پژوهش با هدف بررسی نقش گراف دانش و بازیابی شواهد ساختاریافته در تولید پاسخ‌های قابل توضیح برای مسائل تشخیص اختلالات روانی انجام شد. دو مجموعه داده DR و SWMH برای ارزیابی انتخاب شدند و خروجی روش‌ها در قالب برچسب، توضیح و اطلاعات ردیابی ثبت شد.

منابع DSM-5-TR Made Easy و DSM-5-TR با روش KGGen به گراف دانش تبدیل شدند؛ موجودیت‌ها، روابط و قطعه‌های منبع در PostgreSQL و بردارهای آن‌ها در Milvus نگهداری شدند. بدین ترتیب، روش‌ها می‌توانستند هم از ساختار گراف و هم از متن منبع استفاده کنند.

پنج روش با مدل زبانی Gemma 4 31B مقایسه شدند: زنجیره فکر، Vanilla RAG، HippoRAG، ToG-1 و ToG-2. روش‌های نخست بر متن یا قطعه‌های بازیابی‌شده تکیه داشتند و دو روش آخر از مسیرهای گرافی نیز استفاده کردند.

در نتایج، ToG-2 عملکرد کلی بالاتری داشت و زنجیره فکر در شباهت معنایی توضیح‌ها برتر بود؛ ToG-1 نیز بیشترین پشتیبانی ادعاهای بالینی را نشان داد. روش‌های گراف‌محور هزینه و زمان بیشتری داشتند، اما امکان بررسی مستقیم‌تر توضیح‌ها بر اساس دانش مرجع را فراهم کردند. در مجموع، انتخاب روش به موازنه میان دقت، توضیح‌پذیری و هزینه بستگی دارد. این یافته‌ها نشان می‌دهند که ارزیابی یک روش نباید تنها بر اساس دقت پیش‌بینی انجام شود و کیفیت شواهد و هزینه اجرای آن نیز باید هم‌زمان در نظر گرفته شود. این چارچوب می‌تواند مبنایی برای آزمایش‌های آینده با پرسش‌های پیچیده‌تر و داده‌های بالینی غنی‌تر باشد.

۲-۵ محدودیت‌ها و ضعف‌های پژوهش

تناسب روش‌ها با ساختار مجموعه داده. روش‌های بررسی‌شده، به‌ویژه روش‌های گراف‌محور، برای پرسش‌های چندگامی و چندپرسی طراحی شده‌اند؛ درحالی‌که بسیاری از نمونه‌های این پژوهش از یک پست منفرد تشکیل می‌شوند و به پیمایش عمیق گراف نیاز ندارند. اگرچه توضیح‌پذیری یکی از انگیزه‌های استفاده از این روش‌ها بود، پیچیدگی اضافی آن‌ها برای چنین داده‌ای همیشه مزیت ایجاد نمی‌کند. برای نمونه، HippoRAG 2 در این مجموعه داده نه‌تنها توضیح‌پذیری بیشتری ایجاد نکرد، بلکه عملکرد پایین‌تری نیز نشان داد. بنابراین، بخشی از ظرفیت روش‌های گرافی در این آزمایش به دلیل ساده‌بودن ساختار پرسش‌ها به‌کار گرفته نشد. این محدودیت نشان می‌دهد که برای سنجش کامل مزیت روش‌های

چندگامی، باید مجموعه‌داده‌ای با روابط علی و شواهد پراکنده در چند بخش در اختیار داشت.

کفایت زمینه و کیفیت برچسب‌گذاری. در مجموعه‌داده‌های مورد استفاده، از روی یک پست کوتاه باید درباره وجود یا نوع یک اختلال روانی نتیجه‌گیری شود؛ در بسیاری از موارد، متن به‌تنهایی اطلاعات کافی برای چنین تصمیمی ندارد. بنابراین، بخشی از خطاها ممکن است ناشی از کمبود زمینه یا ابهام ذاتی نمونه‌ها باشد، نه ضعف روش‌های ارزیابی یا استدلال. این مسئله قابلیت اتکای برچسب‌ها و ارزیابی توضیح‌ها را نیز محدود می‌کند. همچنین، نبود اطلاعات بالینی تکمیلی مانع بررسی دقیق تفاوت میان نشانه موقت، تجربه شخصی و اختلال تشخیصی می‌شود.

دانش قبلی نامشخص مدل زبانی. در اجرای مدل زبانی، تضمینی وجود ندارد که مدل از قبل بخشی از داده‌های ارزیابی یا اطلاعات بسیار مشابه را در پارامترهای خود نداشته باشد. در این حالت، مشخص نیست پاسخ تولیدشده تا چه اندازه از گراف و قطعه‌های ارزیابی‌شده و تا چه اندازه از دانش ذخیره‌شده در خود مدل ناشی شده است. نبود دسترسی به فرایند آموزش مدل، تفکیک این دو منبع دانش را دشوار می‌کند. این موضوع می‌تواند بر تفسیر منصفانه مقایسه روش‌ها و نسبت‌دادن اثر مشاهده‌شده به سازوکار ارزیابی اثر بگذارد.

هزینه بالای مصرف توکن. روش‌های مرحله‌ای و گراف‌محور، به دلیل فراخوانی‌های متعدد مدل زبانی و ارسال زمینه‌های طولانی، توکن و زمان بیشتری مصرف می‌کنند. این هزینه، تعداد مدل‌ها و تنظیمات قابل آزمایش را محدود کرد و امکان بررسی گسترده‌تر مدل‌های زبانی و شرایط مختلف را کاهش داد. در نتیجه، مقایسه حاضر بر مجموعه محدودی از مدل و تنظیمات متمرکز باقی ماند. موازی‌سازی فراخوانی‌های مستقل می‌تواند بخشی از زمان را کاهش دهد، اما هزینه توکن و محدودیت‌های سرویس همچنان پابرجا می‌مانند.

محدودبودن ارزیابی به وظیفه پایین‌دستی. دامنه این پروژه بر انتقال و اجرای چند روش عمومی مطرح در ادبیات در یک حوزه مشخص، یعنی تشخیص اختلالات روانی، متمرکز بود. هر روش از اجزای مستقلی مانند ساخت گراف، ارزیابی، رتبه‌بندی و تولید پاسخ تشکیل می‌شود و کیفیت هر جزء می‌تواند جداگانه ارزیابی شود؛ برای مثال، کیفیت ساخت گراف دانش، دقت و فراخوانی زمینه‌های ارزیابی‌شده در روش‌های ارزیابی محور و عملکرد هر مرحله از ToG-1 و ToG-2. با این حال، در این پژوهش ارزیابی به

نتیجه وظیفه پایین‌دستی، یعنی پیش‌بینی برچسب و تولید توضیح، محدود شد و ارزیابی جامع تک‌تک اجزا انجام نگرفت.

تجمع خطا در ارزیابی ادعاهای بالینی. روش ارزیابی ادعاهای بالینی نیز مانند سایر روش‌های چندمرحله‌ای، در معرض تجمع خطا در زنجیره پردازش قرار دارد. این خطا می‌تواند از کفایت منابع انتخاب‌شده برای ساخت گراف، از جمله کتاب‌های DSM-5-TR، کیفیت مدل زبانی در استخراج ادعاها، توان مدل بازنمایی برداری و بازیابی در یافتن واقعیتهای مرتبط، و دقت مدل زبانی در قضاوت درباره میزان تطابق واقعیتهای بازیابی‌شده با ادعا ناشی شود. خطا در هر مرحله می‌تواند بر مرحله بعد اثر بگذارد و در نهایت بر امتیاز سازگاری کل توضیح اثر تجمعی داشته باشد.

۳-۵ پیشنهادهایی برای پژوهش‌های آینده

این پیشنهادها بر اساس مطالعه و بازپیااده‌سازی روش‌های بررسی‌شده شکل گرفته‌اند. هر یک از ضعف‌های مشاهده‌شده می‌تواند نقطه شروع پژوهش مستقلی برای بهبود داده، بازیابی، استدلال یا ارزیابی توضیح‌ها باشد.

۱-۳-۵ گسترش و بهبود مجموعه‌داده‌های تشخیص اختلالات روانی

مجموعه‌داده‌های مورد استفاده، با وجود تمرکز بر چند وظیفه، معمولاً از یک پست کوتاه برای نتیجه‌گیری درباره یک اختلال استفاده می‌کنند و اطلاعات زمینه‌ای، زمانی و سابقه بالینی کافی در اختیار ندارند. چنین ساختاری بخش کوچکی از اطلاعات یک مورد را پوشش می‌دهد و ارزیابی روش‌های چندگامی را دشوار می‌کند. ایجاد مجموعه‌داده‌هایی با روایت کامل‌تر، چند نوبت زمانی، سابقه و شواهد بالینی می‌تواند زمینه مناسب‌تری برای سنجش روش‌های گراف‌محور فراهم کند.

۲-۳-۵ تولید توضیح‌های بالینی با پشتیبانی علمی

بر اساس توضیحات گزارش‌شده برای مجموعه‌داده‌های مشابه، بخشی از توضیح‌ها با کمک مدل‌های زبانی بزرگ‌تر مانند GPT-3.5 Turbo تولید یا تکمیل شده‌اند. ارزیابی ادعاهای ما نیز نشان داد که فقط حدود ۶۵ درصد از ادعاهای استخراج‌شده با گراف دانش ساخته‌شده پشتیبانی می‌شوند. بنابراین، تولید

توضیحات‌های بالینی استدلال‌محور که هر ادعا را به منبع علمی مشخص پیوند دهند، می‌تواند کیفیت و قابلیت اعتماد این مجموعه‌داده‌ها را افزایش دهد.

۳-۳-۵ گسترش دامنه برچسب‌ها و تشخیص باز

تعداد برچسب‌های مجموعه‌داده‌ها محدود است، درحالی‌که منابعی مانند DSM-5-TR اختلال‌های بسیار بیشتری را پوشش می‌دهند. پژوهش‌های آینده می‌توانند مجموعه‌داده‌هایی با برچسب‌های گسترده‌تر و نمونه‌های متنوع‌تر ایجاد کنند و مسئله را از طبقه‌بندی بسته به تشخیص باز تغییر دهند. در تشخیص باز، مدل باید بتواند اختلال مرتبط را از میان دانش مرجع پیشنهاد کند، نه اینکه فقط یکی از چند برچسب از پیش تعیین‌شده را انتخاب کند.

۴-۳-۵ کاهش نویز در بازیابی و بهبود HippoRAG 2

در آزمایش حاضر، به‌طور میانگین فقط 1.2 قطعه از ۸ قطعه بازیابی‌شده در پاسخ نهایی HippoRAG 2 مورد استناد قرار گرفت؛ این مقدار برای Vanilla RAG حدود 1.8 قطعه بود. این نتیجه نشان می‌دهد که افزایش حجم نمایه و بازیابی قطعه‌های فراوان می‌تواند نویز را افزایش دهد و لازم است مجموعه‌های ارزیابی، بازیابی از منابع بزرگ و پرنویز را نیز ارزیابی کنند. در HippoRAG 2، پیمایش گراف ممکن است با افزودن مسیرها و قطعه‌های بیشتر، این نویز را تشدید کند؛ بنابراین، کنترل دامنه پیمایش و حذف زودهنگام زمینه‌های کم‌ارتباط مسیر مهمی برای پژوهش آینده است.

۵-۳-۵ کاهش هزینه و تعداد فراخوانی‌های ToG

تعداد فراخوانی‌های مدل زبانی در ToG-1 بسیار زیاد است و اگر بتوان این تعداد را کاهش داد، هزینه و زمان اجرا به‌طور محسوسی پایین می‌آید. اندازه‌گیری‌ها نشان دادند که این روش از نظر پشتیبانی ادعاهای مطرح‌شده، فاکچوال‌تر از بسیاری از روش‌های مقایسه‌شده است، اما هزینه محاسباتی آن قابل توجه باقی می‌ماند. روش GCR با استفاده از مدل‌های کوچک‌تر از حدود ۱۰ میلیارد پارامتر برای هرس موجودیت و رابطه، نمونه‌ای از تلاش برای کم‌هزینه‌کردن این فرایند است.

یک مسیر دیگر، جایگزینی مدل‌های زبانی مولد با مدل‌های سبک‌تر رمزگذارمحور برای امتیازدهی و هرس است؛ برای نمونه، خانواده NV-Embed به‌عنوان مدل‌های بازنمایی برداری عمومی می‌توانند برای

رتبه‌بندی سریع‌تر نامزدها بررسی شوند [۲۷]. همچنین، طراحی تابع‌های سبک یا هیوریستیک‌های اختصاصی برای هرس رابطه و موجودیت می‌تواند جایگزین بخشی از تولید پاسخ با مدل زبانی شود. از این دیدگاه، ToG نوعی جست‌وجوی محلی است که همسایه‌ها را با هزینه بالا امتیازدهی می‌کند و پژوهش آینده می‌تواند تابعی کم‌هزینه‌تر برای انتخاب مسیرهای مفید پیدا کند.

۵-۳-۶ ارزیابی عمومی ادعا و ارتباط شواهد

برای ارزیابی توهم و سازگاری مدل‌های زبانی با حقیقت، نیاز به روشی عمومی وجود دارد که در سطح ادعاهای مدل عمل کند و علاوه بر درست‌بودن هر ادعا، پیوند میان ادعا، واقعیت بازیابی‌شده و زمینه را نیز بسنجد. روش‌های موجود معمولاً ادعاها را جداگانه استخراج و صحت‌سنجی می‌کنند، اما پیوند میان چند ادعا و میزان ارتباط واقعیت‌های بازیابی‌شده با همان ادعاها را به‌صورت کامل ارزیابی نمی‌کنند. طراحی چنین ارزیابی رابطه‌محوری می‌تواند سنجش توضیح‌پذیری و وفاداری مدل را دقیق‌تر و قابل‌تعمیم‌تر کند.

۵-۴ سخن پایانی

این پژوهش چارچوبی برای مقایسه روش‌های زبانی، بازیابی‌محور و گراف‌محور در تشخیص اختلالات روانی ارائه کرد. نتایج نشان دادند که استفاده از گراف دانش می‌تواند بررسی‌پذیری ادعاها و پیوند آن‌ها با منابع مرجع را بهبود دهد، هرچند هزینه محاسباتی بیشتری ایجاد می‌کند. همچنین، مشخص شد که دقت پیش‌بینی به‌تنهایی برای قضاوت درباره کیفیت یک روش کافی نیست و توضیح‌پذیری و هزینه اجرا نیز باید هم‌زمان سنجیده شوند. محدودیت‌های داده و ارزیابی، مسیرهایی برای ساخت مجموعه‌های ارزیابی غنی‌تر و روش‌های کم‌هزینه‌تر فراهم می‌کنند. در نهایت، توسعه ارزیابی‌های ادعامحور می‌تواند به طراحی سامانه‌هایی کمک کند که پاسخ‌های دقیق‌تر، مستندتر و قابل‌اعتمادتر تولید می‌کنند.

پیوست اول

امضاهای ساختاریافته و دستورهای مدل

این پیوست، امضاهای ساختاریافته مورد استفاده برای فراخوانی مدل زبانی را ثبت می‌کند. استفاده از DSPy قالب ورودی و خروجی فراخوانی‌ها را ثابت و قابل بازتولید می‌کند.

آ-۱ زنجیره فکر و بازیابی متن

```
class AnswerWithCoT(dspy.Signature):
    question: str = dspy.InputField(desc="Original post and question with labels")
    valid_labels: list[str] = dspy.InputField(desc="Complete allowed labels")
    answer: str = dspy.OutputField(desc="Exactly one value from valid_labels")
```

```
program = dspy.ChainOfThought(AnswerWithCoT,
    rationale_field=dspy.OutputField(desc="Brief decisive reasoning"))
```

این امضا در روش‌های Vanilla RAG و HippoRAG 2 با شواهد بازیابی‌شده تکمیل می‌شود:

```
class AnswerFromPsychiatricEvidence(dspy.Signature):
    question: str = dspy.InputField(desc="Original post and question")
    evidence: list[dict[str, str]] = dspy.InputField(desc="Retrieved passages with IDs")
    valid_labels: list[str] = dspy.InputField(desc="Complete allowed labels")
    answer: str = dspy.OutputField(desc="Exactly one value from valid_labels")
    cited_passage_ids: list[str] = dspy.OutputField(desc="Useful passage IDs")
program = dspy.ChainOfThought(AnswerFromPsychiatricEvidence)
```

آ-۲ امضاهای روش HippoRAG 2

```
class GeneratePsychiatricFactQueries(dspy.Signature):
    post: str = dspy.InputField(desc="Psychiatric post or question")
    max_triples: int = dspy.InputField(desc="Maximum triples")
    triples: list[dict[str, str]] = dspy.OutputField(desc="Subject/predicate objects")

class FilterRetrievedFacts(dspy.Signature):
    question: str = dspy.InputField()
```

```
queries_json: str = dspy.InputField(desc="JSON retrieval queries")
candidates_json: str = dspy.InputField(desc="JSON candidates and ranks")
max_selected: int = dspy.InputField(desc="Maximum fact IDs")
selected_ids: list[str] = dspy.OutputField(desc="Selected IDs by usefulness")
```

آ-۳ امضاهای روش ToG-1

در پیاده‌سازی نهایی ToG-1 کلاس امضای جداگانه‌ای در DSPy تعریف نشد و استخراج موجودیت و تولید پاسخ با الگوهای مستقیم دستور انجام گرفت.

آ-۴ امضاهای روش ToG-2

```
class TopicEntityExtraction(dspy.Signature):
    post: str = dspy.InputField(desc="Complete post and classification question")
    allowed_labels: list[str] = dspy.InputField(desc="All possible classes")
    k: int = dspy.InputField(desc="Maximum entity names")
    entities: list[str] = dspy.OutputField(desc="Up to k distinct surface forms")

class TopicPrune(dspy.Signature):
    question: str = dspy.InputField()
    allowed_labels: list[str] = dspy.InputField()
    seed_nodes: str = dspy.InputField(desc="UUID to canonical-name mapping")
    width: int = dspy.InputField()
    selected_ids: list[str] = dspy.OutputField(desc="Subset of supplied UUIDs")

class CombinedRelationPrune(dspy.Signature):
    question: str = dspy.InputField()
    allowed_labels: list[str] = dspy.InputField()
    relation_options: str = dspy.InputField(desc="JSON relation options")
    width: int = dspy.InputField(desc="Maximum relations per topic")
    selected_option_ids: list[str] = dspy.OutputField(desc="Copied option IDs")
```

```
scores: list[float] = dspy.OutputField(desc="Relevance scores from 0 to 1")
explanation: str = dspy.OutputField(desc="Why selected relations help")

class SufficiencyAndAnswer(dspy.Signature):
    question: str = dspy.InputField(desc="Question and all classes")
    allowed_labels: list[str] = dspy.InputField()
    previous_clue: str = dspy.InputField()
    selected_triple_paths: str = dspy.InputField(desc="Directed paths")
    ranked_contexts: str = dspy.InputField(desc="Top-K chunks")
    sufficiency_explanation: str = dspy.OutputField()
    sufficient: bool = dspy.OutputField(desc="Whether evidence supports a class")
    answer_explanation: str = dspy.OutputField(desc="Explanation or empty")
    label: str = dspy.OutputField(desc="Exact class or empty")
    clue: str = dspy.OutputField(desc="Missing evidence or empty")

class QueryReformulation(dspy.Signature):
    question: str = dspy.InputField()
    allowed_labels: list[str] = dspy.InputField()
    clue: str = dspy.InputField()
    selected_triple_paths: str = dspy.InputField()
    ranked_contexts: str = dspy.InputField()
    needed_evidence: str = dspy.OutputField()
    query: str = dspy.OutputField(desc="Reformulated retrieval query")

class BestEffortAnswer(dspy.Signature):
    question: str = dspy.InputField()
    allowed_labels: list[str] = dspy.InputField()
    previous_clue: str = dspy.InputField()
    selected_triple_paths: str = dspy.InputField()
    ranked_contexts: str = dspy.InputField()
    label: str = dspy.OutputField(desc="Exact class or empty")
    explanation: str = dspy.OutputField()
```

آ-۵ ارزیابی ادعاهای بالینی

```
class ExtractClaims(dspy.Signature):
    explanation: str = dspy.InputField()
    case_entities: list[dict[str, str]] = dspy.OutputField()
    clinical_entities: list[dict[str, str]] = dspy.OutputField()
    case_relations: list[dict[str, str]] = dspy.OutputField()
    clinical_relations: list[dict[str, str]] = dspy.OutputField()

class Judge(dspy.Signature):
    generated_clinical_triple: str = dspy.InputField()
    retrieved_knowledge_graph_facts: str = dspy.InputField()
    support_score: str = dspy.OutputField(desc="Integer from 0 to 10")
    reasoning: str = dspy.OutputField(desc="Brief support reasoning")

extractor = dspy.Predict(ExtractClaims)
judge = dspy.Predict(Judge)
```

تمام امضاهای DSPy مورد استفاده در این پژوهش در این پیوست ثبت شده‌اند. جزئیات اجرای نمونه‌ها در پیوست «نمونه اجرای گام‌به‌گام روش‌ها» آمده است.

پیوست دوم

نمونه اجرای گام به گام روش‌ها

این پیوست، اجرای یک نمونه مشترک از پنج روش را ثبت می‌کند. شناسه نمونه، برچسب واقعی، متن ورودی، تصمیم‌های میانی، زمینه‌های انتخاب‌شده و پاسخ نهایی گزارش شده‌اند.

ب-۱ نمونه مشترک

```
sample_id: dr-test-029c26d1b1461025
gold label: yes
post excerpt: "I get more high strung, anxious and depressed every day ...
               Living is becoming a chore."
```

ب-۲ روش Vanilla RAG

```
pipeline:
passage_retrieval -> reranking -> answer_generation
passage_retrieval: 50 candidates
reranking: top 10 candidates
answer input: top 5 evidence passages
P1: "Seemed sad or depressed for several hours?"
P2: "Feeling down, depressed, or hopeless?"
P3/P5: clinical depression examples
answer: yes
cited_passage_ids: [P1, P2]
```

توضیح روش بر اساس دو قطعه نخست است: متن نمونه به‌صراحت از افسردگی روزانه و دشوار شدن زندگی سخن می‌گوید و قطعه‌های بازیابی‌شده این توصیف را با خلق افسرده و ناامیدی مرتبط می‌کنند.

ب-۳ روش HippoRAG 2

```
pipeline:
fact_generation -> fact_filtering -> fact_retrieval -> seed_weighting
-> PPR -> passage_ranking -> answer_generation
queries:
```

```
anxiety --can co-occur with--> depression
feeling high strung --is associated with--> anxiety
depressive mood --is a symptom of--> depression
living is a chore --may indicate--> depression
retrieved fact candidates: 20
selected facts: 12
initial passages: 6
ranked passage candidates: 20
answer: yes
cited_passage_ids: []
evidence_passage_ids: [P1, P2, P3, P4, P5]
```

در این نمونه، واقعیت‌های استخراج‌شده به صورت سه تایی تولید شدند. پس از پالایش و بازیابی، قطعه‌های مرتبط با خلق افسرده و ناامیدی در رتبه‌های بالاتر قرار گرفتند و پاسخ نهایی «بله» بود.

ب-۴ روش زنجیره فکر CoT

```
pipeline:
question + valid_labels -> cot_generation -> answer
retrieval: none
graph traversal: none
LLM calls: 1
answer: yes
```

مدل بر پایه مشاهده مستقیم «افسردگی هر روزه» و دشوار شدن زندگی، برچسب «بله» را انتخاب کرد؛ در این روش هیچ بازیابی متن یا پیمایش گرافی انجام نشد.

ب-۵ روش ToG-1

```
pipeline:
topic_entity_extraction -> graph traversal -> answer_generation
topic entity: depressed
```

retrieved triplet: (Depressed, manifests_with, negative mood)

answer prompt: original post + triplet + allowed labels

answer: yes

موجودیت «افسرده» از متن استخراج شد و سه تایی مرتبط با خلق منفی از گراف بازیابی گردید. مدل با ترکیب متن اصلی و مسیر گرافی، برچسب «بله» را تولید کرد.

ب-۶ روش ToG-2

pipeline:

TopicEntityExtraction -> TopicPrune -> CombinedRelationPrune

-> graph traversal -> context ranking -> SufficiencyAndAnswer

entities: [high strung, anxious, depressed, depression]

seed entities: 10

PPR iterations: 26

calls: 1_extract, 2_topic_prune, 3_relation_prune, 4_sufficiency

ranked contexts:

chunk 6596f07f: marked depressed mood

chunk 3e47f1d7: hopeless daily / severe depression assessment

answer: yes

stopping_reason: llm_sufficient

selected paths: none in this sample

در این نمونه، پس از استخراج و هرس موجودیت‌ها، قطعه‌های مرتبط رتبه‌بندی شدند. مدل زبانی کفایت زمینه را تأیید کرد و حلقه با پاسخ «بله» پایان یافت.

ب-۷ نمونه استخراج ادعا از توضیح ToG-2

case claims:

MCASE_1: the poster -- reports -> depressed every day

MCASE_2: the poster -- reports -> living is becoming a chore

clinical claims:

MCLINICAL_1: depressed every day -- aligns with -> marked depressed mood

MCLINICAL_2: living is a chore -- aligns with -> marked depressed mood

MCLINICAL_3: depressed every day -- aligns with -> hopeless daily

MCLINICAL_4: living is a chore -- aligns with -> hopeless daily

در ارزیابی توضیح، ادعاهای مربوط به شخص از ادعاهای بالینی جدا شدند و فقط ادعاهای بالینی با فکتهای مجموعه دانش مقایسه شدند.

منابع و مراجع

- [1] World Health Organization. World Mental Health Report: Transforming Mental Health for All. World Health Organization, Geneva, 2022.
- [2] Kupfer, David J., Kuhl, Emily A., and Regier, Darrel A. Dsm-5: Classification and criteria changes. World Psychiatry, 12(2):92–98, 2013.
- [3] Shen, Guangyao, Jia, Jia, Nie, Liqiang, Feng, Fuli, Zhang, Cunjun, Hu, Tianrui, Chua, Tat-Seng, and Zhu, Wenwu. Depression detection via harvesting social media: A multimodal dictionary learning solution. in Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, pp. 3838–3844, 2017.
- [4] Sarkar, Somayeh, Alhamadani, Ali, Alkulaib, Lulwa, and Lu, Cheng-Te. Predicting depression and anxiety on reddit: A multi-task learning approach. in Proceedings of the 2022 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining, pp. 427–435, 2023.
- [5] Joyce, Daniel W., Kormilitzin, Andrey, Smith, Katherine A., and Cipriani, Andrea. Explainable artificial intelligence for mental health through transparency and interpretability for understandability. npj Digital Medicine, 6(1):6, 2023.
- [6] World Health Organization. Ethics and Governance of Artificial Intelligence for Health. World Health Organization, Geneva, 2021.

- [7] World Health Organization. Who calls for safe and ethical ai for health. WHO News Release, 2023.
- [8] Lewis, Patrick, Perez, Ethan, Piktus, Aleksandra, Petroni, Fabio, Karpukhin, Vladimir, Goyal, Naman, Kuttler, Heinrich, Lewis, Mike, Yih, Wen-tau, Rocktaschel, Tim, Riedel, Sebastian, and Kiela, Douwe. Retrieval-augmented generation for knowledge-intensive nlp tasks. in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [9] Yang, Kailai, Ji, Shaoxiong, Zhang, Tianlin, Xie, Qianqian, Kuang, Ziyang, and Ananiadou, Sophia. Towards interpretable mental health analysis with large language models. in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 6056–6077, 2023.
- [10] Yang, Kailai, Zhang, Tianlin, Kuang, Ziyang, Xie, Qianqian, Huang, Jimin, and Ananiadou, Sophia. Mentalllama: Interpretable mental health analysis on social media with large language models. in *Proceedings of the ACM Web Conference 2024*, pp. 4489–4500, 2024.
- [11] Ma, Shengjie, Xu, Chengjin, Jiang, Xuhui, Li, Muzhi, Qu, Huaren, Yang, Cehao, Mao, Jiaxin, and Guo, Jian. Think-on-graph 2.0: Deep and faithful large language model reasoning with knowledge-guided retrieval augmented generation. in *International Conference on Learning Representations*, 2025.
- [12] Zhuang, Luyao, Chen, Shengyuan, Xiao, Yilin, Zhou, Huachi, Zhang, Yujing, Chen, Hao, Zhang, Qinggang, and Huang, Xiao. Linearrag: Linear graph retrieval augmented generation on large-scale corpora. in *International Conference on Learning Representations*, 2026.
- [13] Gutiérrez, Bernal Jiménez, Shu, Yiheng, Qi, Weijian, Zhou, Sizhe, and Su, Yu. From rag to memory: Non-parametric continual learning for large language models. in *Pro-*

- ceedings of the 42nd International Conference on Machine Learning, vol. 267 of Proceedings of Machine Learning Research, 2025.
- [14] He, Xiaoxin, Tian, Yijun, Sun, Yifei, Chawla, Nitesh V., Laurent, Thomas, LeCun, Yann, Bresson, Xavier, and Hooi, Bryan. G-retriever: Retrieval-augmented generation for textual graph understanding and question answering. in Advances in Neural Information Processing Systems, vol. 37, pp. 132876–132907, 2024.
- [15] Sun, Jiashuo, Xu, Chengjin, Tang, Luming, Wang, Saizhuo, Lin, Chen, Gong, Yao, Ni, Lionel M., Shum, Heung-Yeung, and Guo, Jian. Think-on-graph: Deep and responsible reasoning of large language model on knowledge graph. in International Conference on Learning Representations, 2024.
- [16] Luo, Linhao, Zhao, Zicheng, Haffari, Gholamreza, Li, Yuan-Fang, Gong, Chen, and Pan, Shirui. Graph-constrained reasoning: Faithful reasoning on knowledge graphs with large language models. in Proceedings of the 42nd International Conference on Machine Learning, vol. 267 of Proceedings of Machine Learning Research, 2025.
- [17] Orabi, Ahmed Hussein, Buddhitha, Prasadith, Orabi, Mahmoud Hussein, and Inkpen, Diana. Deep learning for depression detection of twitter users. in Proceedings of the Fifth Workshop on Computational Linguistics and Clinical Psychology, pp. 88–97, 2018.
- [18] Lin, Chenhao, Hu, Pengwei, Su, Hui, Li, Shaochun, Mei, Jing, Zhou, Jie, and Leung, Henry. SenseMood: Depression detection on social media. in Proceedings of the 2020 International Conference on Multimedia Retrieval, pp. 407–411, 2020.
- [19] Lan, Xiaochong, Han, Zhiguang, Cheng, Yiming, Sheng, Li, Feng, Jie, Gao, Chen, and Li, Yong. Depression detection on social media with large language models. in Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: Industry Track, pp. 2155–2171, 2025.

- [20] Gao, Shan, Yu, Kaixian, Yang, Yue, Yu, Sheng, Shi, Chenglong, Wang, Xueqin, Tang, Niansheng, and Zhu, Hongtu. Large language model powered knowledge graph construction for mental health exploration. *Nature Communications*, 16:7526, 2025.
- [21] Mo, Belinda, Yu, Kyssen, Kazdan, Joshua, Cabezas, Joan, Mpala, Proud, Yu, Lisa, Cundy, Chris, Kanatsoulis, Charilaos, and Koyejo, Sanmi. KGGen: Extracting knowledge graphs from plain text with language models. *arXiv preprint arXiv:2502.09956*, version 2, 2025.
- [22] Sansford, Hannah, Richardson, Nicholas, Petric Maretic, Hermina, and Nait Saada, Juba. GraphEval: A knowledge-graph based LLM hallucination evaluation framework. *arXiv preprint arXiv:2407.10793*, 2024.
- [23] Google DeepMind. Gemma 4 technical report. *arXiv preprint arXiv:2607.02770*, 2026.
- [24] G’unther, Michael, Milliken, Louis, Wang, Jonathan, Arora, Alexander, F’urstenau, Hagen, Sturua, Saba, Wang, Han, Xiao, Chia-Hsiang, G’unther, Sophie, Welbl, Johannes, Ni, Jianmo, Wiegand, Michael, Xiao, Yulong, Savkov, Aleksandar, Wang, Xue, Yu, Daniel, Zhu, Chen, Ma, Zhuyun, et al. Jina embeddings v4: Universal embeddings for multimodal multilingual retrieval. in *Proceedings of the First Conference on Language Modeling*, 2025.
- [25] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders: DSM-5-TR*. American Psychiatric Association Publishing, 5th, text revision ed., 2022.
- [26] Morrison, James. *DSM-5-TR Made Easy: The Clinician’s Guide to Diagnosis*. The Guilford Press, 2022.
- [27] Lee, Chankyu, Roy, Rajarshi, Xu, Mengyao, Raiman, Jonathan, Shoeybi, Mohammad, Catanzaro, Bryan, and Ping, Wei. NV-Embed: Improved techniques for training LLMs

as generalist embedding models. in International Conference on Learning Representations, 2025.

Abstract

The increasing prevalence of mental disorders highlights the need for accurate, reliable, and explainable tools that support the detection process. Large language models can generate diagnostic labels together with textual explanations; however, factual hallucinations and the lack of explicit knowledge grounding limit their use in this sensitive domain. This study reproduces, adapts, and compares graph-based methods for explainable mental health detection. The selected methods represent retrieval-based, agent-based, and constrained reasoning paradigms, allowing the role of domain knowledge graphs in supporting reasoning and reducing unsupported claims to be examined. Experiments will be conducted on selected tasks from the IMHI dataset. The methods will be compared in terms of prediction accuracy, explanation quality and faithfulness, response time, and token cost. The generated explanations will also be analyzed at the claim and structural-relation levels using the GraphEval framework.

Keywords:

Mental Health, Explainable Detection, Large Language Models, Knowledge Graphs, Graph-based Evaluation



**Amirkabir University of Technology
(Tehran Polytechnic)**

Department of Computer Engineering

Bachelor Thesis

Explainable Mental Health Detection via Large Language Models and Domain Knowledge Graphs

By

Alireza Hooshyari

Supervisor

Dr. Mohammad Rahmati

September 2026